



机械科学与技术

Mechanical Science and Technology for Aerospace Engineering

ISSN 1003-8728, CN 61-1114/TH

《机械科学与技术》网络首发论文

题目： 互联空气悬架整车平顺性智能控制方法研究
作者： 余一凡，陈双
DOI： 10.13433/j.cnki.1003-8728.20230272
网络首发日期： 2023-06-02
引用格式： 余一凡，陈双. 互联空气悬架整车平顺性智能控制方法研究[J/OL]. 机械科学与技术. <https://doi.org/10.13433/j.cnki.1003-8728.20230272>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

DOI:10.13433/j.cnki.1003-8728.20230272

互联空气悬架整车平顺性智能控制方法研究

余一凡, 陈双*

(辽宁工业大学 汽车与交通工程学院, 锦州 121000)

摘要: 为提高互联空气悬架整车平顺性, 提出一种改进的灰狼算法, 该算法首先利用指数函数改进收敛因子非线性化, 增强算法广度搜索和深度搜索能力; 其次为防止灰狼种群多样性遭到破坏, 利用 Chebyshev 混沌映射方法来初始化灰狼种群; 接着提出动态权重法提高狼群中 α 狼的权重比例; 最后利用改进灰狼算法的最优解作为 BP 神经网络控制器初始权值并利用 AMESim-Matlab 联合仿真分析。研究结果表明: 该算法对于车身加速度的改善率达到 39.5%。有效提高了互联空气悬架整车平顺性。

关键词: 互联空气悬架; BP 神经网络; PID 控制; 改进灰狼算法

中图分类号: U463.33 **文献标识码:** A

Research on Intelligence Control Methods of Vehicle Ride Comfort of Interconnected Air Suspension

Yu Yifan, Chen Shuang*

(Automotive and Traffic Engineering, Liaoning University of Technology, Liaoning 121000, China)

Abstract: To improve the overall smoothness of the connected air suspension, an improved gray wolf algorithm is proposed, which firstly uses the exponential function to improve the convergence factor nonlinearization to enhance the algorithm's breadth search and depth search capability; secondly, to prevent the gray wolf population diversity from being destroyed, the Chebyshev chaos mapping method is used to initialize the gray wolf population; then the dynamic weight method is proposed to increase the weight proportion of alpha wolves in the wolf population. Finally, the optimal solution of the improved gray wolf algorithm is used as the initial weights of the BP neural network controller and analyzed by the AMESim-Matlab joint simulation. The research results show that the improvement rate of the algorithm for body acceleration reaches 39.5%. It effectively improves the overall smoothness of the connected air suspension.

Key words: interconnected air suspension; BP neural network; PID control; improving gray wolf algorithm

基金项目: 国家自然科学基金资助项目(51675257); 辽宁省教育厅项目(JJL202015402)

作者简介: 余一凡(1997-), 硕士研究生, 研究方向为汽车系统动力学研究, 邮箱: 1076192042@qq.com

***通讯作者:** 陈双(1979-), 教授, 硕士生导师, 邮箱: cslxy74@163.com

0 引言

随着人们生活水平的不断改善,人们对于汽车的平顺性能提出更高要求,由于空气悬架与传统悬架相比能够有效改善车辆行驶平顺性,对高频振动有很好隔振、消声能力,在一些高档轿车中较为普遍^[1-3],而互联形式的出现解决了单个悬架独自工作局面,使得各悬架之间能够相互配合,进一步优化汽车平顺性。江洪等^[4]构建四角互联空气悬架七自由度整车模型,利用 Matlab/Simulink 进行仿真分析,结果表明互联空气悬架相较于普通空气悬架,车身加速度改善率达到 22.5%,有效提高了汽车平顺性;程振扬等^[5]基于 BP 神经网络提出一种自适应 PID 控制算法,利用相应评价指标进行时域和频域分析,结果表明利用该算法车身加速度降低约 58%;张建强等^[6]在 BP 神经网络 PID 基础上,提出将神经网络状态变量模糊化,通过 BP 神经网络生成新的模糊规则,从而调整控制器参数,结果表明相较于模糊 PID,该算法能进一步降低 2% 的车身加速度值。

常规 BP 神经网络 PID 由于其初始权重在 $[-1,1]$ 中随机取值,存在很大偶然性,所以很可能出现局部最优解以及收敛速度过慢等问题^[7]。通过神经网络来建立模糊 PID 控制,虽然能在一定程度上减小车身加速度,但是 BP 神经网络建立模糊矩阵难度较大且需要一定的先验条件^[8]。对于 BP 神经网络的优化主要分为两个方向^[9]:一是通过将神经网络学习速率动态化,从而解决收敛速度过慢及产生结果振荡问题;二是优化权值初始值及其修正问题,从而解决神经网络局部最优问题。本文提出一种改进灰狼算法(Improved Grey Wolf Optimizer IGWO)用于解决 BP 神经网络权值初始值问题。改进灰狼算法^[10]已被多位学者证实相较于遗传算法^[11]、粒子群算法^[12-13]、麻雀搜索算法^[14],其具有较强地寻找最优解能力。本文从非线性收敛因子、初始化灰狼种群及动态权重三方面进行算法改进,最终将 IGWO 最优解作为神经网络初始权值。

1 整车互联空气悬架建模

1.1 整车七自由度动力学模型

建立汽车动力学模型并对模型进行以下假设和简化:(1)整车为左右关于纵平面对称分布且车辆匀速直线行驶;(2)簧载质量为刚性;(3)轮胎只有垂向运动自由度。如图 1 所示,其中悬架部分以总悬架力形式表示。




图 1 互联空气悬架整车动力学模型

$$\left. \begin{aligned} m_{t11} \ddot{z}_{t11} &= K_{11}(q_{11} - z_{t11}) - F_{11} + m_{bf}g/2, \\ m_{t12} \ddot{z}_{t12} &= K_{12}(q_{12} - z_{t12}) - F_{12} + m_{bf}g/2, \\ m_{t21} \ddot{z}_{t21} &= K_{21}(q_{21} - z_{t21}) - F_{21} + m_{br}g/2, \\ m_{t22} \ddot{z}_{t22} &= K_{22}(q_{22} - z_{t22}) - F_{22} + m_{br}g/2, \\ m_b \ddot{z}_b &= F_{11} + F_{12} + F_{21} + F_{22} - m_b g, \\ J_x \ddot{\theta} &= T/2(-F_{11} + F_{12} - F_{21} + F_{22}), \\ J_y \ddot{\varphi} &= l_f(F_{21} + F_{22}) - l_r(F_{11} + F_{12}), \end{aligned} \right\} \quad (1)$$

其中,符号下标数字 11、12、21、22 分别表示左前、右前、左后、右后轮; m 为非簧载质量; K 为轮胎垂向刚度; z_t 为车轮垂向位移; m_b 为簧载质量; z_b 为簧载质量垂向位移; F 为各车轮处总悬架力; q 为各车轮处路面垂向激励; θ 为车身侧倾角; φ 为车身俯仰角; J_x 、 J_y 分别为簧载质量绕着 x 轴、 y 轴的转动惯量; l_f 、 l_r 分别为前、后轴到 y 轴水平距离; T 为车辆轮距; m_{bf} 、 m_{br} 分别为前、后轴载荷。 $K_{\omega f}$ 、 $K_{\omega r}$ 分别为前、后轴横向稳定杆刚度。

总悬架力包括三部分:空气弹簧力、

减振器阻尼力以及前后横向稳定杆作用力,三者合力即为互联空气悬架对簧载质量作用力,公式为:

$$\left. \begin{aligned} F_{11} &= (P_{11} - P_0)A_{11} + C_{11}\dot{f}_{d11} - \frac{K_{\omega f}}{T}(\varphi - \frac{z_{11} - z_{12}}{T}), \\ F_{12} &= (P_{12} - P_0)A_{12} + C_{12}\dot{f}_{d12} + \frac{K_{\omega f}}{T}(\varphi - \frac{z_{11} - z_{12}}{T}), \\ F_{21} &= (P_{21} - P_0)A_{21} + C_{21}\dot{f}_{d21} + \frac{K_{\omega r}}{T}(\varphi - \frac{z_{13} - z_{14}}{T}), \\ F_{22} &= (P_{22} - P_0)A_{22} + C_{22}\dot{f}_{d22} - \frac{K_{\omega r}}{T}(\varphi - \frac{z_{13} - z_{14}}{T}), \end{aligned} \right\} \quad (2)$$

其中, P_{11} 、 P_{12} 、 P_{21} 、 P_{22} 为左前、右前、左后、右后处空气弹簧内部气体瞬时气压; P_0 为大气压力; C_{11} 、 $\dot{f}_{d11}$ 、 C_{12} 、 $\dot{f}_{d12}$ 、 C_{21} 、 $\dot{f}_{d21}$ 、 C_{22} 、 $\dot{f}_{d22}$ 为左前、右前、左后、右后处减振器阻尼系数及减振器处动行程变化率; A_{11} 、 A_{12} 、 A_{21} 、 A_{22} 为左前、右前、左右、右后处空气弹簧气囊有效面积。

四个车轮处簧载质量加速度表达式为:

$$\left. \begin{aligned} \ddot{z}_{b11} &= \frac{F_{11} - \frac{m_{bf}}{2}g}{\frac{m_{bf}}{2}} = \frac{2F_{11}}{m_{bf}} - 1, \\ \ddot{z}_{b12} &= \frac{F_{12} - \frac{m_{bf}}{2}g}{\frac{m_{bf}}{2}} = \frac{2F_{12}}{m_{bf}} - 1, \\ \ddot{z}_{b21} &= \frac{F_{21} - \frac{m_{br}}{2}g}{\frac{m_{br}}{2}} = \frac{2F_{21}}{m_{br}} - 1, \\ \ddot{z}_{b22} &= \frac{F_{22} - \frac{m_{br}}{2}g}{\frac{m_{br}}{2}} = \frac{2F_{22}}{m_{br}} - 1, \end{aligned} \right\} \quad (3)$$

1.2 整车互联空气悬架建模

AMESim 软件是一款性能十分优异的仿真软件,为用户提供了较为完善的联合

仿真环境及解决方案^[15],通过该软件可以不必将所有方程式一一列出,仅通过鼠标拖拽,将各子模型对应接口相连即可,大大简化了模型复杂性。本文利用 AMESim 软件 Vehicle Dynamics 库中相关子模型包括底盘模型、转向系统、动力传动系统、制动系统、互联空气悬架系统、道路模型、轮胎模型等搭建整车互联空气悬架系统模型。

1.2.1 底盘模型

由于 AMESim 软件中七自由度底盘模型在车轮、悬架布置方面存在局限性,建模中将十五自由度整车模型来代替七自由度动力学模型。选取 AMESim 软件 Demo 库中 VDCAR15DOF1 作为底盘模型。

1.2.2 转向系统

假设:(1)将角位移直接施加于转向盘;(2)转向盘转角与车轮转角比值为恒定。利用信号库中 UD00 模拟方向盘转角,该信号是分段线性信号源,能够模拟各种方向盘转角输入情况。

1.2.3 动力传动系统

假设:(1)发动机输出扭矩为分段函数;(2)变速器中速度过渡时间忽略不计;(3)动力传输过程中无损耗。利用 AMESim 软件中增益信号 GA00 用来模拟变速器速度变化功能,差速器模型选择 TRVDDIOA 模型。

1.2.4 制动系统

假设:(1)采用固定比值制动力分配系统;(2)制动时制动力进行分配以后直接传到制动器上;(3)忽略人员反应时间以及制动间隙。

1.2.5 互联空气悬架系统

假设:(1)空气弹簧内部气体满足理想气体状态方程;(2)四个气囊有效面积为常数;(3)只考虑气囊体积变化而产生的垂向运动,忽略体积变化对径向运动影响;(4)气体在管路中流动为等熵过程,忽略因流动而产生的损耗。利用 AMESim 软件 PCD 库中气缸 PNRP17 来模拟空气弹簧垂向位移变化,用该库中带热交换的可变容积气动室 PNCH012 来模拟空气弹簧内部体积和压强变化,用恒定体积气动室

PNCH023 来模拟大气压的作用。

1.2.6 道路模型

为方便建模,假设此时路面附着系数为 1。随机路面选取 AMESim 软件中 VDROAD03 模型,通过输入相应参数来调整路面等级。

1.2.7 轮胎模型

本文轮胎模型选择“魔术公式”轮胎模型。基于上述各子模型的搭建,

本文运用 AMESim 软件建立整车互联空气悬架系统模型,如图 2 所示。




图 2 整车互联空气悬架系统模型

1.3 电磁阀开闭控制规则

互联形式的切换通过电磁阀开闭来完成,空气悬架互联形式共有四种^[16-17],如图 3 所示,当四个电磁阀均不通电时为非互联悬架,为互联形式中特殊情况;当电磁阀 1、3 通电工作而电磁阀 2、4 断电时为横向互联悬架进行工作;当电磁阀 2、4 通电工

作而电磁阀 1、3 断电时为纵向互联悬架;当电磁阀 1、2、3、4 都处于通电状态时为四角互联悬架。




图3 互联空气悬架结构图

通过改变互联形式来控制空气弹簧内部气体流向，当一侧侧倾刚度不足以抵抗路面激励所带来的侧倾力矩，有时适当开启电磁阀往往能提高车身抗侧倾性能。互联形式可以影响空气悬架侧倾刚度以及俯仰刚度，减小由于路面冲击带来的车身侧倾运动及俯仰运动。但当出现一些特殊工况，如汽车加减速、转向等，则必须关闭互联状态^[18]。本文提出一种带约束条件的电磁阀开闭频率控制规则，控制规则如下：

$$\begin{cases} (P_{11} - P_{12}) \cdot \theta > [(P_{11} - P_{12}) \cdot \theta]_{C-M} & \text{电磁阀1通电} \\ (P_{11} - P_{12}) \cdot \theta < [(P_{11} - P_{12}) \cdot \theta]_{C-M} & \text{电磁阀1断电} \end{cases} \quad (4)$$

$$\begin{cases} (P_{12} - P_{22}) \cdot \varphi > [(P_{12} - P_{22}) \cdot \varphi]_{C-M} & \text{电磁阀2通电} \\ (P_{12} - P_{22}) \cdot \varphi < [(P_{12} - P_{22}) \cdot \varphi]_{C-M} & \text{电磁阀2断电} \end{cases} \quad (5)$$

$$\begin{cases} (P_{21} - P_{22}) \cdot \theta > [(P_{21} - P_{22}) \cdot \theta]_{C-M} & \text{电磁阀3通电} \\ (P_{21} - P_{22}) \cdot \theta < [(P_{21} - P_{22}) \cdot \theta]_{C-M} & \text{电磁阀3断电} \end{cases} \quad (6)$$

$$\begin{cases} (P_{11} - P_{21}) \cdot \varphi > [(P_{11} - P_{21}) \cdot \varphi]_{C-M} & \text{电磁阀4通电} \\ (P_{11} - P_{21}) \cdot \varphi < [(P_{11} - P_{21}) \cdot \varphi]_{C-M} & \text{电磁阀4断电} \end{cases} \quad (7)$$

其中， $[(P_{11} - P_{12}) \cdot \theta]_{C-M}$ 为在 C 级路面上前轴气压差值与车身侧倾角乘积的中位数值； $[(P_{21} - P_{22}) \cdot \theta]_{C-M}$ 为在 C 级路面上后轴气压差值与车身侧倾角乘积的中位数值； $[(P_{11} - P_{21}) \cdot \varphi]_{C-M}$ 、 $[(P_{12} - P_{22}) \cdot \varphi]_{C-M}$ 分别为在 C 级路面上车辆左侧、车辆右侧气压差值与车身俯仰角乘积的中位数值，保证该值不会因数据波动而有过大变化。

上述控制规则间接对空气弹簧两侧压

差值与侧倾角乘积进行界定，并没有对进入电磁阀开闭控制规则直接加以限制。提出以悬架动行程及前轮转角作为进入开闭控制规则的约束条件，当满足该条件时，可以触发电磁阀控制规则，不满足时就不执行控制规则，这样可以大大减小电磁阀开闭频率，具体约束规则如下：

1) 当车辆前轮转角 δ 大于频率控制系统所设定的处于转向工况下前轮转角阈值 δ_0 时，控制系统根据转角大小判定车辆正处于转向工况，系统不会执行电磁阀切换控制规则；但当前轮转角 δ 小于频率控制系统所设定的处于转向工况下前轮转角阈值 δ_0 时，系统判定车辆正处于非转向工况，如变道超车引起的稍大转角波动等，此时执行电磁阀切换规则，提高车辆侧倾、俯仰性能。

2) 当汽车判定为非转向工况时，将四个车轮处悬架动行程均方根值中最大值与约束条件下悬架动行程均方根值最小值 fd_{0rms} 作比较，若此时车辆悬架动行程均方根值 fd_{rms} 大于频率控制系统所设定的最小均方根值 fd_{0rms} 时，系统判定当前路面条件较差，为提高车辆乘坐舒适性，系统执行电磁阀切换控制规则，满足切换条件时电磁阀进行切换控制。

2 IGWO-BP 神经网络 PID 算法

2.1 灰狼算法

灰狼算法 (Grey Wolf Optimizer GWO) 是由 Seyedali Mirjalili 等人于 2014 年提出用以模拟自然界中灰狼群体狩猎和领导行为的一种元启发式优化算法，其中狼群被分为四种类型： α 狼、 β 狼、 δ 狼、 ω 狼，各狼在狼群中地位依次减小。该算法主要分为包围猎物和狩猎两部分。包围阶段最重要是位置更新，通过判断与猎物距离来实时更新自己位置，缩小包围半径，达到最佳狩猎位置；在狩猎阶段， α 狼起主要领导作用， β 狼、 δ 狼起辅助作用， ω 狼通过上述三种类型的灰狼位置来更新它们位置。常规 GWO 算法有时会产生局部最优解，这会使算法收敛效果变差，优化效率降低。本文将对 GWO 算法进行改进优化，解决局部最优解问题。

2.2 算法改进

2.2.1 基于指数规律变化的非线性收敛因子

对于寻优能力好的算法，其特点可以总结为：前期进行广度层面搜索，寻优进

程平稳过渡用以增强其勘探能力, 适合全局搜索; 在后期进行深度层面搜索, 寻优进程急速下降用以增强其局部开采能力, 适合局部搜索。寻优算法需要避免早期收敛, 后期陷入局部最优的局面。所以前期要求广度搜索所占比例大, 后期要求深度搜索所占比例大。

常规 GWO 算法中代表其广度搜索与深度搜索比例变量是收敛因子 a , 其广度搜索: 深度搜索=1: 1。本文提出一种非线性收敛因子:

$$a = 2 * \left(\frac{\lambda^{\frac{t}{t_{\max}}} - \lambda}{1 - \lambda} \right)^k, \quad (8)$$

其中, t 为当前迭代次数; $t_{\max}$ 为最大迭代次数; λ 为非线性调节系数; k 为衰减指数。本文 λ 取 300; $t_{\max}$ 取 500; k 取 2。

非线性收敛因子 a 的变化图如图 4 所示。




图4 两种收敛因子变化图

2.2.2 Chebyshev 混沌映射

常规 GWO 算法中, 通常利用 $\text{rand}()$ 函数进行初始种群的随机选择, 但这会导致灰狼种群多样性遭到破坏, 最后造成寻优结果不理想。而混沌映射恰恰能够弥补这种缺陷, 混沌映射具有遍历性以及不重复性, 能够在局部最优解中挣脱, 避免破坏数据多样性。目前主要有 Tent 混沌映射^[19]、Iterative 混沌映射^[20]。本文引用一种 Chebyshev 混沌映射^[21]来初始化种群。

Chebyshev 映射表达式为:

$$x_{n+1} = \cos(k \arccos x_n), x_n \in [-1, 1], \quad (9)$$

通过映射表达式可知, 当 $k \geq 2$ 时, 无论初始值选择如何相近, 迭代出来的数列都是互不相关, 于是就说明该映射在 $[-1, 1]$ 内是混沌和遍历的。Chebyshev 混沌映射分岔图如图 5 所示, 当 $k=4$ 时, Chebyshev 混沌值如图 6 所示。




图5 Chebyshev 混沌映射分岔图




图6 Chebyshev 混沌值图

2.2.3 动态权重策略

在 GWO 算法中, 剩余灰狼个体是通过 α 狼、 β 狼、 δ 狼位置来更新自己所在位置, 其具体数学表达式为:

$$D_\alpha(t) = |\vec{C}_1 \cdot \vec{X}_\alpha(t) - \vec{X}(t)| \quad (10)$$

$$D_\beta(t) = |\vec{C}_2 \cdot \vec{X}_\beta(t) - \vec{X}(t)| \quad (11)$$

$$D_\delta(t) = |\vec{C}_3 \cdot \vec{X}_\delta(t) - \vec{X}(t)| \quad (12)$$

其中, $\vec{X}_\alpha(t)$ 、 $\vec{X}_\beta(t)$ 、 $\vec{X}_\delta(t)$ 分别表示此时 α 狼、 β 狼、 δ 狼具体位置; $\vec{C}_1$ 、 $\vec{C}_2$ 、 $\vec{C}_3$ 为随机向量; $\vec{X}(t)$ 为此时 ω 狼位置。

通过式 (10) ~ (12) 计算此时 ω 狼距离 α 狼、 β 狼、 δ 狼的方位为:

$$\vec{X}_1(t) = \vec{X}_\alpha(t) - \vec{A}_1 \cdot D_\alpha(t) \quad (13)$$

$$\vec{X}_2(t) = \vec{X}_\beta(t) - \vec{A}_2 \cdot D_\beta(t) \quad (14)$$

$$\vec{X}_3(t) = \vec{X}_\delta(t) - \vec{A}_3 \cdot D_\delta(t) \quad (15)$$

由 (13) ~ (15) 得出 ω 狼最终位置为:

$$\vec{X}(t+1) = \frac{[\vec{X}_1(t) + \vec{X}_2(t) + \vec{X}_3(t)]}{3} \quad (16)$$

各阶层灰狼位置更新以及相对位置变化如图 7 所示。




图 7 灰狼位置更新示意图

通过式 (16) 表明最终灰狼的位置与 α 狼、 β 狼、 δ 狼有关, 且各权重均为 1/3, 不难发现, 在此种权重下, 不能很好凸显出 α 狼绝对地位。本文提出一种基于最大适应度变化的动态化权重策略, 保证在任何情况下, α 狼对灰狼位置影响最大, 其次是 β 狼, 最后才是 δ 狼。

$$\left. \begin{aligned} w_1 &= \frac{|f_\alpha| + |f_\beta| + |f_\delta|}{\text{MIN}(\text{fitness}(x))}, \\ w_2 &= \frac{|f_\alpha| + |f_\beta| + |f_\delta|}{\text{fitness}(x)}, \\ w_3 &= \frac{|f_\alpha| + |f_\beta| + |f_\delta|}{\text{MAX}(\text{fitness}(x))}, \\ \text{fitness}(x) &= [|f_\alpha|, |f_\beta|, |f_\delta|] \end{aligned} \right\} \quad (17)$$

$\text{MIN}(\text{fitness}) < \text{fitness}(x) < \text{MAX}(\text{fitness})$;
; $|f_\alpha|$ 、 $|f_\beta|$ 、 $|f_\delta|$ 为对应 α 狼、 β 狼、 δ 狼适应度绝对值。通过加上不同权重系数来改变对 ω 狼位置的影响。即式 (16) 变为:

$$\vec{X}(t+1) = \frac{[w_1 \cdot \vec{X}_1(t) + w_2 \cdot \vec{X}_2(t) + w_3 \cdot \vec{X}_3(t)]}{3} \quad (18)$$

2.3 IGWO-BP 神经网络 PID 控制算法

在常规 PID 控制器控制车身加速度中, 其 K_P 、 K_I 、 K_D 数值往往都是通过经验调试得到, 具有很大的随机性, 可能导致汽车平顺性优化效果并不是特别明显, 于是引入 BP 神经网络正向传播信息与反向传播误差的特点进行在线调节 K_P 、 K_I 、 K_D , 不断利用梯度下降原则减小误差, 直至满足需求, 但是该算法存在陷入局部最优解的缺陷。于是本文提出 IGWO 算法用以更新神经网络初始权值。其系统结构图如图 8 所示。图中 rin 为期望输出值, yout 为系统实际输出值,




图 8 IGWO-BP 神经网络 PID 系统结构图

PID 控制器一般分为位置式 PID 控制器和增量式 PID 控制器, 其中位置式 PID 是通过当前位置与期望所要达到位置之间的偏差来进行 PID 控制; 增量式 PID 是近几次位置误差增量, 与位置式相比, 并不存在误差的累加, 所以更容易通过加权来获得比较好的控制效果。所以选用增量式 PID 来进行算法优化, 其公式为:

$$u(k) = u(k-1) + K_p[e(k) - e(k-1)] + K_I e(k) + K_D[e(k) - 2e(k-1) + e(k-2)] \quad (19)$$

BP 神经网络结构如图 9 所示, 选择三层神经网络结构, 输入层为 $x_1 = \text{rin}(k)$ 、 $x_2 = y(k)$ 、 $x_3 = e(k)$ 、 $x_4 = 1$ 。其中 x_1 和 x_2 分别为第 k 次系统期望输出与实际输出; x_3 为对应两者之间第 k 次误差; x_4 为稳定神经网络常数, 输出层为 K_P 、 K_I 、 K_D 数值。对于隐含层来说, 节点数过少会产生较大误差, 优化结果不理想, 过多可能会导致过拟合现象, 结果也会变差, 一般根据经验公式 (式 (20)) 求得隐含层节点数。

$$m = \sqrt{n+l} + a \quad (20)$$

式中 a 是人为选定的[1,10]之间常数, n 和 l 分别为输入层和输出层的节点数, 所得结果即为隐函数所需的节点数, 本文取 $n=4$, $l=3$, $a=2$, 按照节点数能少则少原则, 取 $m=5$ 。即 BP 神经网络结构为 4-5-3。




图9 BP神经网络PID结构图

2.3.1 BP神经网络正向传播信息

神经网络输入层的输入为 x_j , 由于不使用激活函数, 输入层只能为线性变换, 即输出为:

$$O_j^{(1)} = x_j \quad (j=1, 2, 3, 4) \quad (21)$$

神经网络隐含层在第 k 次传播后输入、输出分别为:

$$\left. \begin{aligned} net_i^{(2)}(k) &= \sum_{j=1}^4 w_{ij}^{(2)} O_j^{(1)} + \theta_i^{(2)}, \\ O_i^{(2)}(k) &= f[net_i^{(2)}(k)], \\ (i &= 1, 2, 3, 4, 5) \end{aligned} \right\} \quad (22)$$

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (23)$$

其中带有上标的 (1)、(2)、(3) 表示网络结构中的输入层、隐含层、输出层; $w_{ij}^{(2)}$ 、 $\theta_i^{(2)}$ 分别表示网络隐含层的连接权值以及阈值 (偏置); $f(x)$ 为隐含层的激活函数 Sigmoid 函数。

神经网络输出层在第 k 次传播后的输入、输出分别为:

$$\left. \begin{aligned} net_l^{(3)}(k) &= \sum_{i=1}^5 w_{li}^{(3)} O_i^{(2)} + \theta_l^{(3)}, \\ O_l^{(3)}(k) &= g[net_l^{(3)}(k)], \\ (l &= 1, 2, 3) \end{aligned} \right\} \quad (24)$$

$$g(x) = \frac{e^x}{e^x + e^{-x}} \quad (25)$$

式中 $w_{li}^{(3)}$ 、 $\theta_l^{(3)}$ 分别表示网络输出层的连接权值以及阈值 (偏置); $g(x)$ 为输出层的激活函数 Sigmoid 函数。

2.3.2 神经网络反向传播误差

取误差的平方作为性能指标函数:

$$E(k) = \frac{1}{2} [rin(k) - yout(k)]^2 \quad (26)$$

神经网络的误差反向传播主要是为了更新网络中的连接权值, 从而使得性能指标函数 $E(k)$ 最小, 其中由于每个神经元单独设置阈值等价于在每一层加入一个没有输入, 输出恒为 1 的偏置神经元, 下一层的神经元的偏置等价于这个偏置神经元输出的权值, 所以这里只需要调整每一层的神经元连接权重就能等效的调整阈值 (偏置), 此处利用带有惯性项的梯度下降方法对权重进行调整。输出层连接权重调整公式为:

$$\left. \begin{aligned} \Delta w_{li}^{(3)}(k) &= \eta \delta_l^{(3)} O_i^{(2)}(k) + \alpha \Delta w_{li}^{(3)}(k-1) \\ \delta_l^{(3)} &= e(k) \cdot \text{sgn}[\frac{\partial y(k)}{\partial u(k)}] \cdot \frac{\partial u(k)}{\partial O_l^{(3)}(k)} \cdot g'[net_l^{(3)}(k)] \end{aligned} \right\} \quad (27)$$

其中 $g'(x) = g(x)[1 - g(x)]$ 。

隐含层连接权重调整公式为:

$$\left. \begin{aligned} \Delta w_{ij}^{(2)}(k) &= \eta \delta_i^{(2)} O_j^{(1)}(k) + \alpha \Delta w_{ij}^{(2)}(k-1) \\ \delta_i^{(2)} &= f'[net_i^{(2)}(k)] \cdot \sum_{l=1}^3 \delta_l^{(3)} \cdot w_{li}^{(3)}(k) \end{aligned} \right\} \quad (28)$$

其中 $f'(x) = [1 - \frac{f^2(x)}{2}]$ 。

2.4 IGWO-BP-PID 控制器算法描述

基于 IGWO-BP-PID 控制器的平顺性优化过程可以分为两部分: 一部分是利用

IGWO 算法进行神经网络初始权值的确定；第二部分为利用所确定的初始权值进行 BP 神经网络学习，确定 PID 控制器的参数值。

2.4.1 BP 神经网络初始权值 w_i 、 w_o 的确定

Step1 首先初始化 IGWO 的算法参数，如种群数量、最大种群迭代次数、调节系数 λ 、衰减指数 k 、变量维数以及 α 、 A 、 C 等参数值，

Step2 利用 Chebyshev 混沌映射方法对灰狼种群进行初始化。

Step3 利用式(8)进行收敛因子的非线性化，选择适应度函数与优化目标一致，即车身加速度均方根值为适应度函数(式(29))，计算个体的适应度值并取当中值最小的三个，分别为 α 狼、 β 狼、 δ 狼并利用式(18)进行权值动态调整。

$$fitness = [\lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T \ddot{z}^2(t) dt]^{\frac{1}{2}}, \quad (29)$$

Step4 按照式(18)来更新 ω 狼所需前进的步长与方向，确定猎物位置。

Step5 判断是否达到最大迭代次数，若满足则输出此时 α 狼所在位置，即为 IGWO 算法寻到的最优解并将其作为 BP 神经网络的初始权值，若不满足则继续跳回 Step 3。

2.4.2 BP 神经网络在线控制 K_p 、 K_I 、 K_D

Step1 将上述寻优结果作为神经网络的初始权值 w_i 和 w_o 。

Step2 利用 BP 神经网络进行更新 x_2 、 x_3 ，并将更新值依据 min-max (式(30))进行归一化处理作为网络输入。

$$x^* = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (30)$$

式中 x^* 表示已经归一化后的值； $\max(x)$ 、 $\min(x)$ 分别为数据的最大值、最小值。

Step3 通过式(19)来计算 PID 控制器的输出 $u(k)$ 。

Step4 通过式(27)进行输出层权值的自我调节，通过式(28)进行隐含层权值的自我更新。

Step5 判断误差是否符合要求，符合即输出此时的控制器输出 $u(k)$ ，不符合则继

续跳回 Step2。

综上。基于 IGWO-BP-PID 优化算法的流程如图 10 所示。




图 10 IGWO-BP-PID 计算流程

3 仿真实验

为验证所提出的 IGWO-BP 神经网络对互联空气悬架平顺性优化是否有效，利用 Matlab 搭建考虑约束条件的电磁阀频率控制器以及基于 IGWO-BP-PID 算法的车身加速度优化控制器，并通过 AMESim 软件中的联合仿真接口 SimuCosim，进行 AMESim-Matlab 联合仿真。

IGWO 算法所需参数中， $\lambda = 300$ ， $k = 2$ ，最大迭代次数 $t_{\max} = 500$ ，狼群初始种群设置为 30，Chebyshev 混沌映射中系数取 4，又因为 BP 神经网络的隐含层权值为 5×4 矩阵，输出层权值为 3×5 矩阵。故选择变量维数为 35 维。于是经过多次迭代后，适应度曲线如图 11 所示，可以看出整体适应度值在不断下降，说明 IGWO 算法是有效果的，在迭代 300 次左右系统趋于稳定，并将此时 α 狼所在位置为最优解作为 BP 神经网络的初始权值，其权值为：




图 11 适应度值变化图

$$w_i = \begin{bmatrix} 0.1557 & 0.2577 & 0.2060 & 0.3235 \\ -0.4643 & 0.2431 & -0.4682 & 0.1948 \\ 0.3491 & -0.1078 & -0.2231 & -0.1829 \\ 0.4340 & 0.1555 & -0.4538 & 0.4502 \\ 0.1787 & -0.3288 & -0.4029 & -0.4656 \end{bmatrix}$$
$$w_0 = \begin{bmatrix} -0.0613 & 0.2952 & -0.0544 & 0.2547 & 0.1551 \\ -0.1184 & -0.3131 & 0.1463 & -0.2240 & -0.3374 \\ 0.2655 & -0.0102 & 0.2094 & 0.1797 & -0.3810 \end{bmatrix}$$

整车相关模型参数如表 1 所示。

表 1 整车模型参数

参数	数值	参数	数值
m_b/kg	1 300	$k_{t21}, k_{t22}/\text{N/m}$	200 000
m_{b1}/kg	728	T/m	1.566
m_{b2}/kg	572	l_f/m	1.05
$m_{t11}, m_{t12}/\text{kg}$	18	l_r/m	1.55
$m_{t21}, m_{t22}/\text{kg}$	14	A/m^2	0.023 8
$J_x/\text{kg}\cdot\text{m}^2$	250	$C/\text{N}\cdot\text{s}\cdot\text{m}^{-1}$	1 400
$J_y/\text{kg}\cdot\text{m}^2$	1 000	$k_{\phi f}/(\text{N}\cdot\text{m})/\text{rad}$	11 000
$k_{t11}, k_{t12}/\text{N/m}$	200 000	$k_{\phi r}/(\text{N}\cdot\text{m})/\text{rad}$	10 000

利用 AMESim-Matlab 进行联合仿真分

析，车速为 10m/s，路面输入选择 C 级路面。以前左轮为例，得出改进后 PID 参数变化图如图 12 所示，优化前后车辆前左轮处的各项性能指标对比图如图 13-15 所示，各性能指标均方值如表 2 所示。




图 12 PID 参数变化图





图 13 左前车身加速度及功率谱密度






图 14 左前悬架动行程及功率谱密度

图 15 左前轮动载荷及功率谱密度

表 2 性能指标均方根值

性能指标	优化前	优化后	优化率 /%
车身加速度/ (m/s ²)	0.470 8	0.284 6	39.5
悬架动行程 /m	0.011 72	0.010 85	0.074
轮胎动载荷 /N	3 001.326	3 288.161	-9.5

由表 2 可知：相较于常规互联空气悬架，在采用 IGWO-BP 神经网络 PID 优化算法控制器作用下，虽然轮胎动载荷提高 9.5%，但是使得车身加速度降低 39.5%，具有较好优化效果。综上，汽车平顺性相较于常规互联空气悬架有较大改善。

4 结论

(1) 在常规 GWO 算法基础上提出基于指数变化规律的非线性收敛因子、Chebyshev 混沌映射、动态权重法等三个方面改进算法，设计 IGWO-BP 神经网络 PID 算法控制器，结果表明所设计的算法控制器对于车身加速度优化具有一定效果。

(2) 考虑悬架动行程均方根值与前轮转角作为电磁阀开闭控制规则，可以实现不同互联形式之间的切换。

(3) 运用 AMESim-Matlab 进行联合仿真分析，其结果表明：在保证安全的前提下，增大了轮胎动载荷换来车身加速度

减少 39.5%，有效提高了汽车平顺性。

[参考文献]

[1] 潘公宇,王万青.双横臂空气悬架主动外倾和前束的应用仿真研究[J].重庆理工大学学报(自然科学),2020,v.34;NO. 424(03):1-9.
Pan G Y, Wang W Q. Applied Simulation Study on Active Tilting and Front Beam of Double-Wisher Air Suspension[J].Journal of Chongqing University of Technology (Natural Science),2020,v.34; NO. 424(03):1-9.

[2] 江洪,王鹏程,李仲兴.基于智能体理论的空气悬架车身高度智能控制系统研究[J].重庆理工大学学报(自然科学),2019,v.33;No.402(04):17-25.
Jiang H, Wang P C, Li Z X. Research on Air Suspension Body Height Intelligent Control System Based on Agent Theory[J].Journal of Chongqing University of Technology (Natural Science), 2019, v.33; No.402(04):17-25.

[3] 王文林,侯之超,邹军.汽车空气悬架研究进展:零部件与系统[J].汽车安全与节能学报,2018,9(01):11-24.
Wang W L, Hou Z C, Zou J. Journal of automotive safety and energy-saving, 2018,9(01):11-24.

[4] 江洪,钱宽,朱超.四角互联空气悬架系统平顺

- 性与消扭特性[J].西南交通大学学报,2015,50(06):1106-1113.
- Jiang H, Qian K, Zhu C. Smoothness and torsion dissipation characteristics of four-corner interconnected air suspension system[J]. Journal of Southwest Jiaotong University, 2015,50(06):1106-1113.
- [5] 程振扬,杨明,吴心杰,等.基于 BP 神经网络 PID 控制的主动悬架仿真分析[J].农业装备与车辆工程,2022,60(02):130-134.
- Cheng Z Y, Yang M., Wu X J, et al. Simulation analysis of active suspension based on BP neural network PID control[J]. Agricultural Equipment and Vehicle Engineering,2022,60(02):130-134.
- [6] 张建强,时岩,冯海峰.基于 BP 神经网络模糊 PID 的主动悬架控制研究[J].制造业自动化,2019,41(02):58-61+76.
- Zhang J Q, Shi Y, Feng H F. Research on active suspension control based on BP neural network fuzzy PID[J]. Manufacturing Automation, 2019,41(02):58-61+76.
- [7] 王洪远,史国栋.人工神经网络技术及其应用[M].北京:中国石化出版社,2002:3436.
- Wang H Y, Shi G D. Artificial neural network technology and its applications [M]. Beijing: China Petrochemical Press, 2002: 3436.
- [8] 田丰福,杨金玉.基于模糊神经 PID 控制的汽车主动悬架平顺性分析与测试[J].实验室研究与探索,2017,36(05):44-47.
- Tian F F, Yang J Y. Analysis and testing of auto active suspension smoothness based on fuzzy neural PID control[J]. Laboratory Research and Exploration,2017,36(05):44-47.
- [9] 马巨海,焦宗旭,徐程琳,等.基于神经网络 PID 控制的聚合温控负荷优化调度[J].燕山大学学报,2019,43(5):417-422.
- Ma J H, Jiao Z X, Xu C L, et al. Optimal scheduling of aggregated temperature-controlled loads based on neural network PID control[J]. Journal of Yanshan University,2019,43(5):417-422.
- [10] Mirjalili S, Mirjalili S M, Lewis A D. Grey Wolf Optimizer[J]. Advances in Engineering Software, 2014.
- [11] 王抒怀,马廉洁,闫坤杰,等.基于 GA-BP 算法优化陶瓷加工参数及材料属性[J].组合机床与自动化加工技术,2022(04):171-174+179.
- Wang Y H, Ma L J, Yan K J, et al. Optimization of ceramic processing parameters and material properties based on GA-BP algorithm[J]. Combined Machine Tools and Automatic Machining Technology,2022(04):171-174+179.
- [12] 崔乃丹.基于粒子群优化算法与 BP 神经网络的高铁客运量预测算法[J].自动化技术与应用,2022,41(04):148-150.
- Cui N D. High-speed railway passenger traffic prediction algorithm based on particle swarm optimization algorithm and BP neural network[J]. Automation Technology and Applications,2022,41(04):148-150.
- [13] 董晶,张利民,张燕超,等.基于 PSO-BP 神经网络的转炉炼钢碳含量预测[J].华北理工大学学报(自然科学版),2022,44(01):16-23.
- Dong J, Zhang L M, Zhang Y C, et al. Carbon content prediction in converter steelmaking based on PSO-BP neural network[J]. Journal of North China University of Technology (Natural Science Edition),2022,44(01):16-23.
- [14] Sharma D M, Sharma S, Sharma M. Desert Sparrow Optimization Algorithm for Permutation Flowshop Scheduling Problems[J]. International Journal of Mathematics in Operational Research, 2020, 1(1):1.
- [15] 付永领,齐海涛.系统建模和仿真实例教程[M].北京:北京航空航天大学出版社,2011.
- Fu Y L, Qi H T. System modeling and simulation example tutorial [M]. Beijing: Beijing University of Aeronautics and Astronautics Press, 2011.
- [16] 张潇.四角互联空气悬架及其互联状态控制方法研究[D].江苏大学,2019.
- Zhang X. Research on four-corner interconnected air suspension and its interconnected state control method [D]. Jiangsu University,2019.
- [17] 张云,周孔亢,钱宽.互联空气悬架对整车振动性能的影响[J].江苏大学学报(自然科学版),2017,38(04):410-415.

- Zhang Y, Zhou K K, Qian K. Effect of interconnected air suspension on the vibration performance of the whole vehicle[J]. Journal of Jiangsu University (Natural Science Edition), 2017,38(04):410-415.
- [18] Mittal N, Singh U, Sohi B S . Modified Grey Wolf Optimizer for Global Engineering Optimization[C]// Hindawi. Hindawi, 2016:1-16.
- [19] 滕志军,吕金玲,郭力文,等.一种基于 Tent 映射的混合灰狼优化的改进算法[J].哈尔滨工业大学学报,2018,50(11):40-49.
- Teng Z J, Lü J L, Guo L W, et al. An improved algorithm for hybrid gray wolf optimization based on Tent mapping[J]. Journal of Harbin Institute of Technology,2018,50(11):40-49.
- [20] 王梦娜,王秋萍,王晓峰.基于 Iterative 映射和单纯形法的改进灰狼优化算法[J].计算机应用,2018,38(S2):16-20+54.
- Wang M N, Wang Q P, Wang X F. Improved gray wolf optimization algorithm based on Iterative mapping and simplex method[J]. Computer Applications,2018,38(S2):16-20+54.
- [21] Safaai-Jazi, A. Modified Chebyshev arrays[J]. IEE Proceedings - Microwaves Antennas and Propagation,2002,145(1):45-48.