

分 类 号: U461.1

单位代码: 10183

研究生学号: 2021422055

密 级: 公开



吉 林 大 学

硕士学位论文

(学术学位)

分布式线控底盘车辆车轮转角传感器故障诊断与车辆状态估计研究

Research on wheel steer angle sensor fault diagnosis and
vehicle state estimation for distributed drive-by-wire chassis

作者姓名: 王紫煦

专 业: 车辆工程

研究方向: 汽车动力学仿真与控制

指导教师: 郑宏宇 教授

培养单位: 汽车工程学院

2024 年 6 月

分布式线控底盘车辆车轮转角传感器故障诊断与车辆状态估计研究

Research on wheel steer angle sensor fault diagnosis and
vehicle state estimation for distributed drive-by-wire
chassis

作者姓名：王紫煦

专业名称：车辆工程

指导教师：郑宏宇 教授

学位类别：工学硕士

论文答辩日期：2024 年 5 月 25 日

摘要

在汽车线控技术的高速发展背景下,分布式线控底盘车辆在结构布置和车辆状态感知等方面相对于传统车辆具有较大优势,为研究智能驾驶新技术提供了良好的平台。可靠、准确、实时的获取行驶过程中车辆状态是实现车辆智能控制算法、保证车辆行驶安全的前提。然而,车辆行驶中很多关键车辆状态参数受噪声、测量难度等因素影响无法直接或通过低成本的传感器测量。利用分布式线控底盘车辆具有能够获取更多车辆行驶状态信息的特点,建立车辆状态估计算法已经成为准确获取车辆行驶状态的主要技术途径。车辆状态估计算法的基本思想主要是结合车辆动力学模型和现有车载传感器测量值对汽车行驶状态进行估计。在车辆状态估计算法的设计中,准确的车轮转角信息对保证车辆状态估计算法有效性和车辆控制算法正常工作有着重要影响。但是,由于车轮转角传感器受环境影响易发生故障,如何在车轮转角传感器故障时准确诊断,并在传感器故障后仍能保证准确获取车轮转角值对分布式线控底盘车辆行驶安全具有重要意义。另一方面,基于模型的车辆状态估计算法在车辆质量参数变化情况下存在准确性降低的问题,对车辆行驶安全存在一定影响。

因此,针对分布式线控底盘车辆能够感知更多车辆状态参数的特点,为保证车辆行驶安全。本文依托国家重点研发计划项目“多系统高效集成轮毂电机行动模块与整车转矩矢量分配技术”(项目编号:2021YFB2500703)和吉林省科技发展计划项目“线控一体化底盘电动汽车自动换道决策与控制研究”(项目编号:20230101121JC),围绕分布式线控底盘车辆车轮转角传感器故障诊断和车辆状态估计等展开研究,具体包括以下几个方面的研究工作:

(1) 分布式线控底盘车辆模型的建立:首先,为准确、有效的设计车辆状态估计器,本文建立了分布式线控底盘车辆非线性动力学模型。选取典型分布式线控底盘车辆行驶特征工况与 CarSim 软件中的车辆模型进行仿真对比,验证模型准确性。

(2) 车轮转角传感器故障诊断算法的建立:为准确诊断车轮转角传感器故障并在传感器故障情况下准确获取车轮转角,保证车辆行驶安全性。首先,建立

线控转向电机数学模型，基于扩展卡尔曼滤波算法建立车轮转角估计器；然后，通过残差卡方检验法诊断车轮转角传感器故障，当识别到传感器故障后，向车辆状态估计算法输出车轮转角估计值；最后，为验证算法有效性，分析典型传感器常见故障形式，并基于 MATLAB/Simulink 搭建仿真实验平台，验证传感器在不同故障条件下的车轮转角估计算法准确性和故障诊断算法有效性。

（3）车辆状态估计算法的设计：结合分布式线控底盘车辆四轮转角和驱动转矩可知的特点，针对车辆质量参数变化对车辆状态估计算法精度的影响问题。首先，建立融合了递归最小二乘算法和 K-最邻近算法的车辆质量估计器，通过车辆质量融合估计策略实时估计车辆质量，保证车辆质量估计精度；其次，搭建了基于双无迹粒子滤波的分布式线控底盘车辆状态估计器的双观测器架构算法，以实现对车辆状态参数的准确观测。其中，估计算法模型中车辆质量参数通过融合车辆质量估计器实时估计获取，避免由于车辆质量参数变化造成的车辆状态估计精度下降；然后，设计了 K-最邻近算法数据集自更新策略，通过收集行驶过程中车辆数据，更新数据集和算法模型，从而提高 K-最邻近算法估计精度；最后，基于 CarSim 和 MATLAB/Simulink 联合仿真平台搭建算法模型并建立仿真工况验证算法准确性和有效性。

（4）基于驾驶模拟器仿真实验算法验证：为进一步验证本文所建立的分布式线控底盘车辆传感器故障诊断和车辆状态估计算法有效性和实时性，搭建驾驶模拟器仿真实验台并进行仿真试验验证。在 CarSim 软件设置车辆模型和对应仿真环境，并通过 NI PXI 实时采集数据。基于驾驶模拟器在传感器正常和传感器故障情况下对本文所建立的算法进行验证，实验结果表明算法实时性和准确性较好。同时，验证了本文所建立的 K-最邻近节点算法数据集自更新与算法自学习策略的有效性。

关键词：

分布式线控底盘车辆，传感器故障诊断，车辆状态估计，车辆质量估计，双无迹粒子滤波算法

ABSTRACT

Under the background of the rapid development of automobile drive-by-wire technology, distributed drive-by-wire chassis vehicles have great advantages over traditional vehicles in structural layout and vehicle state perception, which provides a good platform for the research of new intelligent driving technology. Reliable, accurate and real-time acquisition of vehicle state during driving is the premise of realizing vehicle intelligent control algorithm and ensuring vehicle driving safety. However, many key vehicle status parameters cannot be measured directly or by low-cost sensors due to noise, measurement difficulty and other factors. Since distributed drive-by-wire chassis vehicles can obtain more information of vehicle driving state, the establishment of vehicle state estimation algorithm has become the main technical approach to accurately obtain vehicle driving state. The basic idea of the vehicle state estimation algorithm is to estimate the driving state of the vehicle by combining the vehicle dynamics model and the measured values of the existing vehicle sensors. In the design of vehicle state estimation algorithm, accurate wheel Angle information plays an important role in ensuring the effectiveness of vehicle state estimation algorithm and the normal operation of vehicle control algorithm. However, the wheel Angle sensor is prone to failure under the influence of the environment, how to accurately diagnose the wheel Angle sensor failure and ensure the accurate acquisition of wheel Angle value after the sensor failure is of great significance to the safety of the distributed wire-controlled chassis vehicle. On the other hand, the model-based vehicle state estimation algorithm has the problem of decreasing accuracy when vehicle mass parameters change, which has a certain impact on vehicle driving safety.

Therefore, in order to ensure vehicle safety, the distributed drive-by-wire chassis vehicle can sense more vehicle state parameters. This paper relies on the national key research and development program "Multi-system Efficient Integration of In-wheel Motor Action Module and Vehicle Torque Vector Distribution Technology" (Project

Number: 2021YFB2500703) and the Jilin Province Science and Technology Development Plan Projects "Research on decision-making and control of automatic lane change of electric vehicle with X-by-Wire chassis" (Project Number: 20230101121JC), focuses on fault diagnosis and vehicle state estimation of wheel Angle sensor of distributed drive-by-wire chassis, including the following aspects:

(1) Establishment of distributed drive-by-wire vehicle model: First, in order to accurately and effectively design a vehicle state estimator, this paper establishes a distributed drive-by-wire vehicle nonlinear dynamic model. The driving characteristics of a typical distributed drive-by-wire chassis vehicle were simulated and compared with the vehicle model in CarSim software to verify the accuracy of the model.

(2) Establishment of wheel Angle sensor fault diagnosis algorithm: in order to accurately diagnose wheel Angle sensor fault and accurately obtain wheel Angle in case of sensor fault, ensure vehicle safety. Firstly, the mathematical model of steering-by-wire motor is established, and the wheel Angle estimator is established based on extended Kalman filter algorithm. Then, the residual Chi-square test method is used to diagnose the wheel Angle sensor fault. When the sensor fault is identified, the wheel Angle estimate is output to the vehicle state estimation algorithm. Finally, in order to verify the effectiveness of the algorithm, the common fault forms of typical sensors were analyzed, and a simulation experiment platform was built based on MATLAB/Simulink to verify the accuracy of the sensor wheel Angle estimation algorithm and the effectiveness of the fault diagnosis algorithm under different fault conditions.

(3) Design of vehicle state estimation algorithm: Combined with the known characteristics of distributed drive-by-wire chassis vehicle four-wheel Angle and drive torque, aiming at the impact of vehicle mass parameter changes on the accuracy of vehicle state estimation algorithm. Firstly, a vehicle mass estimator based on recursive least squares algorithm and K-nearest neighbor algorithm is established to estimate

the vehicle mass in real time through the vehicle mass fusion estimation strategy to ensure the accuracy of vehicle mass estimation. Secondly, a dual observer architecture algorithm based on a distributed drive-by-wire chassis vehicle state estimator with dual untracked particle filter is built to achieve accurate observation of vehicle state parameters. Among them, the vehicle mass parameters in the estimation algorithm model are obtained by the real-time estimation of the vehicle mass estimator to avoid the deterioration of the vehicle state estimation accuracy caused by the change of vehicle mass parameters. Then, the K-nearest neighbor algorithm data set self-updating strategy is designed. By collecting vehicle data during driving, the data set and algorithm model are updated to improve the estimation accuracy of K-nearest neighbor algorithm. Finally, based on CarSim and MATLAB/Simulink co-simulation platform, the algorithm model is built and the simulation conditions are established to verify the accuracy and effectiveness of the algorithm.

(4) Algorithm verification based on driving simulator simulation experiment: In order to further verify the effectiveness and real-time performance of the distributed drive-by-wire chassis vehicle sensor fault diagnosis and vehicle state estimation algorithm established in this paper, a driving simulator simulation experiment platform was built and simulation tests were conducted. The vehicle model and corresponding simulation environment are set up in CarSim software, and the data are collected in real time through NI PXI. Based on the driving simulator, the proposed algorithm is verified under the condition of normal sensor and fault sensor. The experimental results show that the algorithm has good real-time performance and accuracy. At the same time, the validity of the K-nearest neighbor algorithm data set self-updating and algorithm self-learning strategy established in this paper is verified.

Key Words:

Distributed Drive-by-wire Chassis Vehicle, Sensor Fault Diagnosis, Vehicle State Estimation, Vehicle Mass Estimation, Dual Unscented Particle Filter Algorithm

目 录

第 1 章 绪论.....	1
1.1 选题背景及研究意义.....	1
1.2 分布式线控底盘车辆技术简介	3
1.2.1 本文研究的分布式线控底盘车辆关键技术	4
1.2.2 线控底盘车辆发展概况.....	7
1.3 车辆状态估计算法研究现状	9
1.3.1 基于学习的车辆状态估计算法研究现状	10
1.3.2 基于模型的车辆状态估计算法研究现状	12
1.4 传感器故障诊断研究介绍	19
1.5 本文主要研究内容.....	22
第 2 章 分布式线控底盘车辆模型建立	25
2.1 分布式线控底盘车辆非线性动力学模型建立	25
2.1.1 模型假设.....	25
2.1.2 非线性车辆动力学模型.....	26
2.2 轮胎侧偏模型.....	28
2.2.1 轮胎模型简介.....	29
2.2.2 Pacejka 轮胎模型	29
2.3 CarSim 车辆模型	30
2.4 模型准确性仿真验证.....	31
2.4.1 低速四轮转角正弦输入仿真.....	32
2.4.2 中速前轮转角正弦输入仿真.....	33
2.4.3 高速四轮转角阶跃输入仿真.....	34
2.5 本章小结.....	36
第 3 章 分布式线控底盘车辆车轮转角传感器故障诊断算法研究	37
3.1 分布式线控底盘车辆车轮转角传感器故障诊断算法框架	37
3.2 基于扩展卡尔曼滤波的转向电机转角传感器故障诊断算法设计	38
3.2.1 转角电机数学模型建立.....	39
3.2.2 扩展卡尔曼滤波算法建立.....	40
3.2.3 基于残差卡方检验的传感器故障诊断策略	42
3.3 传感器常见故障分析.....	43
3.4 传感器故障诊断算法仿真验证	45
3.4.1 基于 EKF 的分布式线控底盘车辆车轮转角估计算法验证.....	46
3.4.2 传感器卡死仿真实验验证.....	46

3.4.3 传感器增益变化仿真实验验证.....	47
3.4.4 传感器偏差仿真实验验证.....	48
3.5 本章小结.....	49
第 4 章 分布式线控底盘车辆状态估计算法研究	51
4.1 分布式线控底盘车辆状态估计算法框架	51
4.2 车辆纵向动力学模型.....	52
4.3 KNN 与 RLS 融合车辆质量估计算法建立	55
4.3.1 KNN 算法建立	55
4.3.2 RLS 算法建立	56
4.3.3 车辆质量融合策略.....	57
4.4 基于 DUPF 的分布式线控底盘车辆状态估计算法建立	60
4.4.1 UPF 算法建立	61
4.4.2 计算 Sigma 点集	63
4.4.3 重采样算法.....	64
4.5 车辆状态估计算法仿真实验验证	65
4.5.1 KNN 数据集收集与分析	66
4.5.2 车辆状态估计算法验证.....	70
4.6 本章小结.....	75
第 5 章 驾驶模拟器仿真实验验证	77
5.1 驾驶模拟器仿真实验设备	77
5.1.1 NI PXI 工控机.....	78
5.1.2 转向和踏板总成.....	78
5.2 驾驶模拟器实验算法验证	78
5.2.1 传感器正常情况下车辆状态估计实验	79
5.2.2 传感器故障下车辆状态估计实验.....	86
5.3 本章小结.....	91
第 6 章 全文总结与展望	93
6.1 全文总结.....	93
6.2 研究展望.....	94
参考文献.....	97

第1章 绪论

1.1 选题背景及研究意义

汽车保有量不断增加和我国城市化的不断发展加剧了城市交通拥堵的问题。开发出一种高效、灵活、适应未来城市复杂的交通环境的智能车辆驾驶平台并保证这种车辆的行驶安全成为了未来汽车的重要研究方向^[1]。如图 1.1 所示，为近七年我国汽车产销量，2023 年，我国汽车产量与销量分别达到 3016.1 万辆和 3009.4 万辆，首次双双突破 3000 万辆，连续三年上升并且连续 15 年位居全球第一^[2]。在世界最大汽车消费市场的加持下，随着人工智能、移动互联、通信工程、大数据和云计算等相关高新产业的快速发展，车辆智能化的研究也被带动成为当今工业界与学界中的研究热点^[3,4]。




图 1.1 2017-2023 年我国汽车产销量

线控技术是一种通过线缆传输控制信号控制执行器执行动作的传动方案。目前，由线控技术代替传统机械结构连接以控制车辆的线控底盘汽车已经成为了当前的研究热点^[5,6]。作为一种多传感器、高可控自由度系统，分布式线控底盘车

辆相对于传统车辆具有可以实现对每个车轮的转角、驱动力矩和制动力矩准确且独立控制和获取的优势^[7]。如图 1.2 所示，分布式线控底盘车辆相对与传统车辆的结构优势成为了分布式线控底盘车辆能够实现如原地掉头、蟹行等高灵活度的特殊工况的前提，以满足日益复杂的城市行驶条件^[8,9]。




图 1.2 分布式线控底盘车辆行驶工况示意图

随着对分布式线控底盘车辆控制系统相关研究的逐渐深入，准确获取车辆横摆角速度、纵向速度等车辆状态参数成为各种车辆主动安全控制系统在分布式线控底盘车辆上成功应用的前提。但是，由于车辆传感器的测量成本和测量水平等多方面的影响，很多重要的车辆状态参数无法准确、直接或低成本的测量。因此，通过状态估计理论对汽车行驶状态参数进行估计成为了一种可行、有效的方法。

车辆状态估计主要是利用已有的车载传感器，基于车辆动力学模型和估计理论对难以直接测量、测量成本昂贵、传感器测量准确度较低或传感器噪声较大的车辆参数进行估计^[10]。车辆状态参数估计结果的准确性会直接影响整车底盘控制系统的控制精度，影响车辆行驶的安全性^[11]。分布式线控底盘车辆相较于传统车辆所具有的各车轮转角、驱动力矩和车轮转速的精确可控可知的优势对分布式线控底盘车辆实现更为全面、准确车辆状态估计具有较大的优势。

然而，另一方面，由于分布式线控底盘车辆所配备的传感器数量也相对于传统车辆显著增加。因此，如何保证在各种行驶条件或故障环境下都能获得准确的车辆行驶参数对于分布式线控底盘车辆的行驶安全具有重要意义。同时，分布式

线控底盘车辆车轮转角传感器处于相对缺乏车身保护的车辆外部环境,从而易受到环境因素的影响,出现如卡死、漂移、突变和信号中断等多种类型的故障^[12]。鉴于这些潜在风险,通过传感器故障诊断方法排查车轮转角传感器故障,替代传感器冗余容错,并执行相应的容错控制方案成为了一种既能增加分布式线控底盘安全性,又能降低车辆成本的研究方向^[13,14]。

1.2 分布式线控底盘车辆技术简介

随着线控技术和汽车智能化、电气化的发展,由电机独立控制的四轮独立驱动、四轮独立转向、四轮独立制动、四轮电控悬架组成的分布式线控底盘车辆由于其广阔的发展潜能和性能优势成为了当前的研究热点^[15]。越来越多的研究表明,分布式线控底盘汽车的高灵活性能够一定程度上应对城市化发展对交通空间的挤压的问题,并能够为无人驾驶车辆的研究提供更多发展方向的可能性^[16,17]。本文所研究的分布式线控底盘车辆的基本结构如图 1.3 所示,其线控技术相关硬件主要包括由四个轮边电机及传感器和方向盘总成和路感电机等构成的分布式线控转向系统;由四个轮毂电机及其传感器和踏板总成等构成的分布式线控驱动系统;及其它整车控制器和相关附件等。




图 1.3 本文研究的分布式线控底盘车辆基本架构

对于传统车辆,车轮转角、驱动转矩等车辆行驶关键参数需要通过如转向齿条位移传感器、转向齿轮转角传感器和轮速传感器等其它传感器进行解算,无法

直接测量。因此，车辆状态估计算法计算过程中会由于传感器参数解算过程中的机械摩擦和模型误差降低估计结果准确性。分布式线控底盘车辆由于其相对于传统车辆具有冗余控制和多传感器优势，能够通过传感器直接获取车轮转角、车轮驱动转矩等执行器参数。因此，针对分布式线控底盘车辆的车辆状态估计相关研究相对于传统车辆具有参数精度优势。

1.2.1 本文研究的分布式线控底盘车辆关键技术

线控技术起源于对飞机的控制系统中将飞行员操作转化为电信号输入控制器控制飞机飞行。分布式线控底盘车辆通过相似的方式，利用相似的控制方式获取驾驶员操纵意图，实现汽车转向、制动、驱动等功能，取代传统汽车靠机械或液压传递控制信号的方式^[18]。

（一）分布式线控转向系统结构原理及关键技术

分布式线控转向系统在结构上取消传统车辆转向系统中方向盘与转向器齿轮间的传动轴，通过线控转向系统(Steer-By-Wire, SBW)控制器实现上下两部分模块间的通信^[19]。

部分传统车辆车轮转角测量方式和分布式线控底盘车轮转角测量方式示意如图 1.4 所示。对于传统车辆车轮转角测量方式包括（1）通过齿轮齿条位移传感器解算车轮转角；（2）通过转向器齿轮转角传感器解算车轮转角（3）通过主销转角传感器解算车轮转角等。这些传统车辆车轮转角测量方式大多需要通过对其它传感测量值进行解算间接获取车轮转角。但分布式线控转向系统在结构上可以将车轮转角传感器安装至转向电机附近，从而能够对车轮转角直接测量。这种传感器布置形式降低了由于主销角度、机械摩擦、传动误差带来的车轮转角测量值的不准确度，提高基于车轮转角测量值建立的线控转向系统控制算法和车辆状态估计算法的准确性，保证车辆行驶安全。




图 1.4 传统车辆车轮转角测量方案与分布式线控转向车轮转角测量方案示意图

分布式线控转向系统主要由方向盘总成、转向执行系统总成、传感器和 SBW 控制器及其它辅助系统组成。分布式线控转向系统能够实现从方向盘总成接收方向盘转向信号输入 SBW 控制器。而 SBW 控制器需要从车辆其它系统传感器和车辆状态估计算法获得的车辆车速、路面附着信息等车辆实时状态，基于控制器中预编写的路感算法给路感电机传递相应的转矩指令，模拟路感力矩；同时，SBW 控制器根据传感器和车辆状态估计算法解算当前行驶工况、车速、驾驶员转向意图等计算前轮期望转角，完成对四个车轮转向电机的伺服控制，保证车辆的转向性能。当车轮转角传感器出现故障时，为保证转向执行系统总成伺服控制闭环，车轮转角传感器故障诊断算法快速诊断故障，并实现对车轮转角的准确估计。因此，对于分布式线控转向系统，准确、实时的车辆状态估计算法和保证车轮转角传感器工作稳定的传感器故障诊断算法是 SBW 系统正常工作的基础之一。

目前, 针对四轮独立转向的线控转向系统的关键技术研究焦点主要包括^[20]: (1) 传感器技术; (2) 主动转向技术; (3) 路感模拟技术; (4) 容错控制技术; (5) 变传动比技术 (6) 四轮协同转向技术等。

(二) 分布式线控驱动系统结构原理及关键技术

如图 1.5 所示为分布式线控驱动车辆和集中式驱动电动汽车的驱动系统示意图。分布式线控驱动系统在结构上相较于集中式驱动电动汽车的主要区别为, 在四个车轮的轮边系统结构上各集成了一个可以通过电控系统独立控制的驱动电机, 整车控制器基于车辆状态估计算法获取车辆状态参数和路面信息调整分配四轮驱动转矩, 从而提高车辆动力性能和车辆行驶稳定性^[21,22]。




图 1.5 分布式线控驱动车辆与集中式驱动电动汽车驱动系统结构示意图

相较于传统集中驱动式电动汽车具有以下优势: (1) 更高的汽车主动安全控制精确性; (2) 更高的车辆底盘布置灵活性; (3) 一体化控制车辆发展的重要组成部分; (4) 各车轮的准确驱动力矩和制动力矩感知与控制; (5) 更高的车辆行驶稳定性^[23]。

分布式线控驱动技术是未来智能网联汽车发展的关键平台, 目前其研究的关键技术与难点主要有: (1) 新构型的悬架系统 (2) 轮毂电机驱动系统 (3) 整车控制技术 (4) 线控底盘协同技术^[24]。

1.2.2 线控底盘车辆发展概况

进入 21 世纪以来，线控底盘车辆的相关产品雏形逐渐出现在各种汽车展会之中。日本日产公司分别于 2005 年、2007 年和 2011 年发布了采用线控四轮独立驱动的电动汽车 PIVO、PIVO 2 和 PIVO 3 概念车^[25,26]。美国特斯拉公司于 2019 年发布、2023 年上市的 Cybertruck 采用线控转向系统，省略了方向盘与转向器间的机械连接，在车辆行驶时调整方向盘与转向器间传动比，提高车辆灵活性。在国内，长城汽车公司 2021 年 6 月发布基于 GEEP 4.0 全新的智慧线控底盘架构，整合了线控转向、线控制动、线控悬架等 5 个核心底盘系统，涵盖车辆六自由度控制^[27]。比亚迪公司 2023 年发布了“云辇”智能车身控制系统和“易四方”动力系统，系统化处理车辆垂向方向控制问题和抑制车身姿态变化的同时，实现四驱动电机独立控制，基于“云辇”和“易四方”发布了仰望系列汽车^[28,29]。



(a) Nissan PIVO



(b) Tesla Cybertruck



(c) 长城汽车智慧线控底盘



(d) 比亚迪仰望系列

图 1.6 国内外企业线控车辆产品

各高校与研究机构对于线控底盘车辆的研究主要在于关键驾驶条件下的各底盘控制算法的协调控制、传感器和执行器故障的容错控制以及与上层运动规划相结合的综合控制^[30]。通过协同控制线控底盘车辆各个线控子系统，发挥各线控子系统的性能优势，提升车辆在多维运动耦合下的安全性^[31]。

目前，国内外各高校也研发出了多种线控底盘样车。如图 1.7（a）所示，美国俄亥俄州立大学的 Junming Wang 团队研发了四轮独立驱动电动汽车 GEV，并基于该车进行四轮独立驱动车辆动力学控制等方向的研究^[32]。如图 1.7（b）所示，美国斯坦福大学的 Chris Gerdes 团队研发了 X1 线控底盘平台，主要用于研究自动驾驶车辆的伦理学，自动驾驶车辆的运动规划，极限工况下的车辆稳定性控制和驾驶员辅助与增强系统^[33,34]。图 1.7（c）为吉林大学宗长富教授团队搭建的全线控四轮独立电动汽车 UFEV，该车具有四轮独立驱动、转向、制动能力，并基于该车进行了线控底盘车辆行驶稳定性和车辆状态估计的相关研究^[35]。湖南大学的张邦基教授团队设计了如图 1.7（d）所示的一种全矢量线控底盘系统，能够实现蟹行、原地转向、车身姿态调控等目标^[36]。



（a）GEV 线控底盘



（b）X1 线控底盘



(c) UFEV 线控底盘



(d) 全矢量线控底盘系统

图 1.7 国内外高校线控底盘科研平台

综上，基于分布式线控底盘车辆的研究发展与现状可以看出：

(1) 分布式线控底盘车辆作为一种新兴的研究平台，具有更多的执行器与传感器，使分布式线控底盘车辆具有高可控自由度、高灵活性的特点，目前已经成为企业界和各高校的研究热点。

(2) 本节所介绍分布式线控底盘车辆相对于传统车辆能够获取更多的车辆状态参数为车辆状态估计算法的进一步研究提供了基础。同时，保证车辆传感器的工作正常、实时诊断传感器故障是准确获取车辆状态的前提。另一方面，保证分布式线控底盘车辆行驶稳定的控制算法也需要通过准确、实时的车辆状态估计算法和车轮转角故障诊断算法实现算法闭环和冗余容错。

因此，考虑分布式线控底盘车辆相对与传统车辆的机械结构优势和关键研究技术，为保证获取车辆状态信息的准确性和车辆行驶安全性。本文以分布式线控底盘车轮转角传感器故障诊断和车辆状态估计为主要研究内容。

1.3 车辆状态估计算法研究现状

分布式线控底盘车辆具有多执行器、高冗余控制的特性，使得分布式线控底盘车辆相较于传统车辆配备了更多先进的传感器，以实现对自身车辆状态的准确感知，并辅助智能驾驶系统以实现在复杂环境下的辅助驾驶^[37,38]。高效准确的获取车辆动态参数是未来智能驾驶汽车及其安全系统能否确保车辆行驶安全的重要影响因素^[39,40]。相对于使用更加精准但昂贵的传感器，为实现对分布式线控底

盘车辆的准确控制、降低车辆制造成本，通过车辆状态估计方法获取准确的车辆状态信息是目前较为常用的方法^[41,42]。目前针对车辆状态估计的相关算法研究主要可以分为基于学习的方法和基于模型的方法^[43,44]。

1.3.1 基于学习的车辆状态估计算法研究现状

基于学习的车辆状态估计算法主要包括基于数据的统计学的方法和基于神经网络的方法^[45]。其中，循环神经网络(Recurrent Neural Network, RNN)和长短时记忆网络(Long Short-Term Memory, LSTM)等处理时序数据较为准确的神经网络算法已经被广泛应用于车辆状态估计、环境感知、驾驶员认知行为、车辆轨迹跟踪控制和 SOC 估计等与车辆相关的领域中^[46]。




图 1.8 RNN 算法示意图




图 1.9 LSTM 算法示意图

图 1.8 为 RNN 算法按照时间展开的形式, RNN 算法通过自带反馈的神经元, 能够实现对任意长度的时序数据的处理。图 1.9 为 LSTM 算法按照时间展开的形式, 其通过增加输入门限、遗忘门限和输出门限, 从而实现在模型参数固定的情况下的不同时刻积分尺度的动态变化, 避免算法出现梯度消失和梯度膨胀的问题。

在国内, 华南师范大学的李伟善等提出了一种基于优化支持向量机 (Support Vector Machine, SVM) 的电池荷电状态(State-of-Charge, SOC)的估计方法, 通过仿真实验与基于人工神经网络的 SOC 估计方法进行对比, 验证所提出的算法具有更好的准确性和简便性^[47]。

江苏大学的蔡英凤等提出了一种基于数据驱动和高效神经网络结构相结合的车辆状态预测估计算法, 通过观测车辆动态参数的信息特性, 利用时间数据构造隐含参数的等效状态, 能够在多种特殊工况下实现高精度 4 步长的车辆状态预测估计^[48]。

吉林大学的高振海等提出了一种基于混合神经网络的车辆运动状态估计算法, 基于多个标准工况建立数据集, 解决了现有车辆状态估计算法对车辆动力学模型精度的依赖性问题。通过典型试车测试工况进行神经网络训练和试验验证, 相比于传统算法, 混合神经网络车辆状态估计算法在应对路面附着系数变化具有良好的鲁棒性^[49]。

南京航空航天大学 Zhang Bo 等提出了一种基于堆栈双向长短期记忆递归神经网络算法融合全球定位系统(Global Position System, GPS)的车辆侧向速度估计方法, 仿真结果表明与仅考虑车载传感器测量值作为车辆侧向速度值的方法相比, 该文所提出的方法具有更好的准确性, 并且在 GPS 中断情况下的依旧对车辆侧向速度具有较高的估计精度^[50]。

上海纽约大学的 Chu Qunyi 等为解决商用车制动力分配相关问题, 通过随机森林法对实际采集的商用车整车信息进行特征筛选, 并离线训练广义回归神经网络, 在线估计车辆状态参数, 并基于车辆状态估计结果建立四轮制动力分配算法, 通过仿真实验验证了算法的有效性^[51]。

中国北方车辆研究所的郑阳俊等提出了一种基于深度强化学习算法(Deep Reinforcement Learning, DRL)的针对四轮独立驱动电动汽车侧向车速估计方法。

基于所建立的奖励函数和训练场景,通过 MATLAB/Simulink 软件搭建算法并进行算法训练。通过收集实际行驶工况下的数据建立仿真实验,证明算法相较于扩展卡尔曼滤波算法精度提高了 40%^[52]。

在国外,加拿大麦克马斯特大学的 Ephrem Chemali 等基于 LSTM 算法和 RNN 算法在自学习电池参数训练模型后,将电池参数测量值与电池 SOC 相映射,实现对不同温度条件下的锂电池的 SOC 进行实时估计,并通过实验验证算法的准确性^[53]。

新加坡南洋理工大学的 Xing Yang 等针对电动汽车制动压力的动态估计问题,提出了一种基于 LSTM-RNN 的时间序列模型,通过控制器局域网络(Controller Area Network, CAN)收集传感器信号,实时迭代估计未来速度,并将该信号与车辆其它状态值融合,精确估计车辆制动压力值^[54]。

韩国大邱庆北科学技术院的 Shin Jongho 等提出了一种基于 RNN 算法的将车辆信息攻击检测与识别和轮速传感器的车速估计相结合的新方法,以提高在车辆遭受违反汽车信息物理系统的限制的攻击下的车辆安全性^[55]。

意大利那不勒斯费德里科第二大学的 Guido Napolitano 等基于神经网络技术估计车辆纵向速度,并通过光学传感器提供的车辆质心处车辆状态测量值进行比较验证,在该文所建立的测试条件下,人工神经网络估计值均具有良好的精度^[56]。

1.3.2 基于模型的车辆状态估计算法研究现状

基于模型的车辆状态估计算法相较于基于学习的车辆状态估计算法起步更早,发展更为成熟。其具有较强的鲁棒性而在学界收到了广泛的关注^[57]。目前,基于模型的车辆状态估计算法中,较为常用的为基于卡尔曼及其衍生算法的车辆状态估计算法。而粒子滤波、龙伯格算法、 H_∞ 滤波算法等非基于卡尔曼滤波的车辆状态估计算法由于具有处理高阶非线性系统和非高斯噪声系统的状态估计问题相对于卡尔曼滤波算法具有较好的性能,也渐渐成为学界和工业界的研究热点^[58,59]。目前常用的基于模型的车辆状态估计算法及其基本特点如表 1.1 所示。

表 1.1 常用滤波算法的特点

算法名称	算法特点
卡尔曼滤波	能够处理服从高斯噪声的线性系统目标状态的最优估计问题
扩展卡尔曼滤波	能够处理非强非线性系统的状态估计问题，对非线性系统在观测值附近采用泰勒展开法线性化，保留一阶近似项。
无迹卡尔曼滤波	通过无迹变换实现观测变量均值和协方差在非线性系统状态方程中传递问题，相较于扩展卡尔曼滤波算法，能够处理更高阶非线性系统的状态估计问题。
粒子滤波	采用随机采样方式近似随机变量概率密度函数，相较于卡尔曼滤波算法具有不受噪声模型限制的优势。
无迹粒子滤波	采用无迹变换改进随机采样方法处理粒子分布，解决了粒子滤波算法的例子枯竭问题，但同时计算量相较于其它算法较大

（一）传统车辆的基于模型的状态估计算法研究现状

目前基于表 1.1 中所述算法的传统车辆的状态估计算法研究较为成熟，主要集中在与车辆纵向速度、侧向速度、纵向加速度、侧向加速度、横摆角速度、轮胎力等影响车辆底盘控制算法的相关方向。目前，针对传统车辆状态估计的部分相关研究有：

在国内，吉林大学的宗长富等采用扩展卡尔曼滤波(Extended Kalman Filter, EKF)算法，融合方向盘转角、纵向加速度、侧向加速度信息，估计车辆纵向速度、横摆角速度和质心侧偏角，并通过离线仿真实验验证算法的有效性^[60,61]。

同济大学的 Xia xin 等基于惯性测量单元(Inertial Measurement Unit, IMU)和车辆传感器，搭建基于卡尔曼算法估计车辆偏航误差和车辆速度误差，并通过直线加速、减速实车试验验证算法的准确性^[62]。

湖南大学的 Cui Qingjia 等为提高自动驾驶车辆在高速条件下轨迹跟踪的稳定性和准确性，将基于无迹卡尔曼滤波算法(Unscented Kalman Filter, UKF)的轮胎-路面附着系数估计器集成在基于模型预测控制(Model Predictive Control, MPC)算法的车辆轨迹跟踪系统中，并通过仿真试验证明这种集成控制器能够实现提高智能车辆的高速条件下的轨迹跟踪的准确性和车辆稳定性^[63]。

武汉理工大学的 Liu Daoyuan 等提出了一种精细重采样无迹粒子滤波算法 (Unscented Particle Filter, UPF) 来估计车辆轮胎侧偏角和车辆横摆角速度, 并通过仿真实验证明其鲁棒性高于 UKF 算法, 同时误差值波动方差小于顺序重要重采样粒子滤波算法^[64]。

湖南大学的 Xiao Zhu 等针对一些车辆传感器噪声的非高斯分布问题, 利用广义误差分布 (Generalized Error Distribution, GED) 算法, 提出了一种非高斯粒子滤波器, 并利用遗传算子重采样 (Genetic Operator Resampling, GOR) 方法提高粒子滤波器的效率, 实车实验证明, 该算法在处理非高斯噪声的车辆状态估计问题中, 优于现有的其它算法^[65]。

吉林大学的汤泽鹏建立高斯过程回归模型估计车辆轮胎关键状态, 同时设计了轮胎力直接估计模型, 在车辆正常驾驶和极限工况下算法均具有良好的准确性和鲁棒性。进一步应用轮胎智能技术基于轮胎内震动频率信息建立轮胎侧偏角估计模型^[66]。

在国外, 德国博世公司的 Antonov 等针对无法直接通过传感器测量的车辆状态参数, 设计了一种 UKF 算法, UKF 算法基于非线性随机估计技术, 将车辆平面双轨模型与轮胎魔术公式相结合, 在考虑轮胎垂向刚度的情况下估计轮胎载荷, 仿真试验证明该算法具有较好的精确性和鲁棒性^[67]。

英国考文垂大学的 Wenzel 等提出了双扩展卡尔曼滤波 (Dual Extended Kalman Filter, DEKF) 算法实现车辆状态与车辆参数的组合估计, 该算法将车辆状态估计和车辆参数估计问题通过两个 EKF 分别处理, 并且当车辆参数估计准确时关闭车辆参数估计器, 从而提高算法效率^[68]。

意大利米兰理工大学的 Mattia Bersani 等通过实车实验对比研究了 EKF 和 UKF 算法在实车侧向速度和车辆航向角以及车辆位置估计中的性能, 并通过光学传感器对其性能进行了评估^[69]。

意大利萨伦托大学的 Giulio Reina 等建立了一种基于 EKF 算法的车辆参数估计框架, 利用车辆常见的传感器测量参数, 提高车辆行驶安全性和自动驾驶水平。通过仿真实验验证了 EKF 算法在自适应驾驶辅助系统和车辆控制器发展方向的研究潜力^[70]。

英国谢菲尔德哈勒姆大学的 Basilio Lenzo 等研究了一种基于粒子滤波算法的针对具有后轮转向能力的车辆的轮胎侧偏角估计方法,该方法只需基于常用的车辆传感器及轮胎模型,并通过仿真实验验证算法有效性^[71]。

美国俄亥俄州立大学的 Zhang Guoguang 等针对车辆横摆角速度估计的问题,提出了一种基于类龙伯格算法的车辆状态观测算法的鲁棒增益调度观测器,并通过实车试验,验证了算法在不同的车辆行驶场景下的信号校正和对传感器偏差估计和识别的能力^[72]。

澳大利亚维也纳应用科技大学的 Wilfried Wöber 等建立了一种基于贝叶斯滤波算法的而车辆运动参数估计方法。通过建立黑盒模型,利用随机变量表征车辆参数,扩展车辆运动学参数的概率视角。通过仿真试验验证算法可以在较少的车辆运动学假设的情况下准确估计车辆参数^[73]。

西班牙马德里卡洛斯三世大学的 Beatriz L. Boada 等设计了一种基于 H_∞ 滤波算法和神经网络相结合的车辆侧倾角估计器,估计器考虑了模型的不确定性以及衰减外部干扰的影响,通过接收车上传感器信号实现对车身侧倾角的估计,实验结果表明该算法的有效性^[74]。

英国萨里大学的 Aymen Alshawi 等提出了一种新的 UKF 算法以实现自适应协方差矩阵情况下准确估计车辆纵向速度和侧向速度,从而准确估计轮胎侧偏角、滑移角和滑移率以及极端假释条件下路面附着系数的变化^[75]。

(二) 分布式线控底盘车辆的基于模型的状态估计算法研究现状

分布式线控底盘车辆作为一种高冗余控制,高自由度的车辆底盘系统,其动力学模型是高阶非线性的,且相对于传统车辆复杂度更高。仅仅依靠卡尔曼滤波算法与扩展卡尔曼滤波算法难以解决分布式线控底盘车辆的状态估计问题。随着分布式线控底盘车辆的不断发展,针对其车辆状态估计的相关研究也成为了研究热点。目前,车辆状态估计的相关研究主要基于 UKF 算法和 UPF 算法。

重庆大学的舒红宇等设计了针对四轮独立转向车辆的底盘控制器。通过 UKF 算法实现对轮胎侧偏角、纵向速度和轮胎力的估计,提高参数估计准确性。结合所设计的基于模型预测控制算法(Model Predictive Control, MPC)的车辆底盘控制算法,提高车辆行驶安全性^[76]。

清华大学的 Chu Wenbo 等基于分布式驱动车辆建立了基于 UPF 算法的车辆状态估计器,实现对车辆轮胎侧向力、车辆纵向速度、侧向速度和横摆角速度的实时估计,并通过仿真实验验证了算法的有效性和鲁棒性^[77]。

北京理工大学的 Zhu Junjun 等提出了一种基于改进粒子滤波算法的轮毂电机驱动车辆的车辆状态估计器。实现在复杂噪声和传感器故障条件下对车辆状态和参数进行高精度和鲁棒性估计。通过仿真实验证明该算法性能由于无迹卡尔曼滤波算法和粒子滤波算法^[78]。

南京航空航天大学 Chen Xiang 等针对四轮独立驱动电动汽车的轮胎-路面峰值附着系数估计问题,设计了一种自适应平方根容积卡尔曼滤波算法,该文所提出的算法可以解决 EKF 在系统强非线性区域准确性低的问题,实验和仿真结果表明,该估计方法在不同的驾驶条件下都能取得良好的性能^[79]。

江苏大学的 Chen Te 等针对四轮独立驱动电动汽车转矩分配和稳定性控制,提出了一种融合电动驱动轮模型的自适应高阶滑膜观测器(High-order Sliding Mode Observer, HSMO)的纵向力观测器,并在所估计的纵向力结果的基础上,基于强跟踪滤波器同时估计车辆侧向速度和横摆角速度^[80]。

(三) 分布式线控底盘车辆的基于双观测器架构的状态估计算法研究现状

另一方面,为充分发挥分布式线控底盘车辆具有的多参数可精确可控、可知、可计算的优势,一些研究人员考虑采用两个观测器处理不同的车辆状态向量,相互协同观测车辆状态信息,减少了模型参数不确定性等对算法精度产生的干扰,提高分布式线控底盘车辆被观测量的估计精度。

武汉理工大学的 Pei Xiaofei 等针对 8×8 分布式驱动电动汽车的车辆状态估计问题,提出了一种基于双无迹卡尔曼滤波算法的车辆状态估计器,仿真结果表明,该双无迹卡尔曼滤波车辆状态估计器对多轴分布式电动汽车的状态和关键参数具有较高的估计精度^[81]。

北京理工大学的 Wang Zhenpo 等将基于三自由度车辆动力学模型的鲁棒无迹卡尔曼滤波估计器和基于运动学模型的扩展卡尔曼滤波估计器结合起来,提出了一种针对传感器测量噪声和异常值的四轮独立驱动电动汽车侧滑角估计方法,并在在典型车辆机动工况验证了算法准确性和鲁棒性^[82]。

（四）车辆质量估计算法研究现状

基于模型的车辆状态估计算法的主要思想是建立车辆模型和传感器测量值的融合估计。因此,准确的模型参数对车辆状态估计算法的准确性具有直接影响。目前,这种算法在状态估计过程中通常将车辆质量视为固定值,在车辆行驶过程中不会发生较大变化。但在车辆多次行驶之间,随着乘员与货物质量的变化,将车辆质量视为定值的车辆状态估计算法精度会降低,进而影响车辆行驶安全。另一方面,由于车辆质量与车辆部件负载和使用寿命相关,因此,车辆质量的准确信息在商用车的车队运载管理相关研究中也十分重要。

车辆质量的获取通常通过地磅或动态称重等方式,但对于多数应用场景这种方法较为繁琐。而虽然部分车辆稳定性控制算法会对车辆质量进行预估,但是其估计结果通常为当前车辆的质量所处范围,无法直接应用为车辆状态估计算法的车辆模型质量参数。因此通过状态估计方法获取车辆质量,在车辆行驶过程中对车辆质量实时估计具有一定的可行性。因此,通过估计理论,实时估计车辆质量具有一定的研究意义^[83]。

丹麦的丹麦技术大学的 Jensen Kenneth 等基于车辆纵向动力学模型采用具有遗忘因子的递推最小二乘滤波算法和普通递归最小二乘算法估计车辆质量,通过 CAN 总线获取车辆基本数据,并进行了实车试验进行算法验证^[84]

南京理工大学的 Wang Beijia 等设计了一种车辆质量估计误差修正方法,测量车辆后悬架变形基础上提出基于车辆传感器的车辆质量估计算法,并通过仿真实验验证算法有效性^[85]。

中山大学的 Zhang hui 等提出了自适应扩展卡尔曼滤波器,通过学习车辆状态间的非线性动力学,对车辆质量进行准确的预估计;其次,在比较神经网络实时输入数据和训练数据的基础上,设计权重调整模块,并设计了自适应规律^[86]。

清华大学的 Chu Wenbo 等设计了一种高通滤波器提取车辆纵向驱动力和加速度的高频信息,然后采用递推最小二乘算法的对车辆质量进行估计。仿真和实验结果表明,该方法能较准确地估计车辆质量^[87]。

目前,基于递归最小二乘算法的车辆质量估计算法应用较为广泛和成熟。但由于多数车辆质量估计算法是基于车辆纵向动力学模型建立的,当车辆转向过程

中算法精度会降低。同时，将车辆质量估计算法应用至车辆状态估计算法，改善模型变化对车辆行驶状态估计精度的相关研究不够完善。

综合以上对车辆状态估计的研究现状分析可以得出：

(1) 目前，针对车辆状态估计应用较为广泛、算法发展较为成熟的是基于模型的车辆状态估计算法。同时，针对传统车辆的车辆状态估计器的研究较为广泛与成熟，但对分布式线控底盘车辆，充分发挥其四轮驱动转矩和转角可知优势的车辆状态估计算法还有待进一步研究。而采用两个观测器架构可以充分发挥分布式线控底盘车辆的优势，实现对车辆状态的准确估计的研究方向具有较大的研究意义。

(2) 基于模型的车辆状态估计算法对模型的准确性要求较高，但在模型参数发生变化时，会带来算法精确性降低的问题。多数基于模型的车辆状态估计算法在研究过程中将车辆模型的质量参数直接作为定值处理。而在车辆多次行驶过程间，由于乘员及货物数量增减，车辆质量会发生较大变化，影响车辆状态估计算法精度。目前车辆质量估计算法研究较为全面，但将车辆质量估计算法与车辆状态估计算法结合，降低车辆质量变化对车辆状态估计算法精度的影响的相关方向有待进一步研究。

(3) 目前，车辆质量估计算法的相关研究主要基于车辆纵向动力学模型建立，在车辆转向过程中算法精度降低。因此，如何保证车辆质量估计精度在分布式线控底盘车辆多种行驶工况下的准确性还需要进一步研究。

因此，本文以分布式线控底盘车辆为研究对象，充分利用四轮驱动转矩和转角精确可测的优势，建立了基于双无迹粒子滤波算法(Dual Unscented Particle Filter, DUPF)的分布式线控底盘车辆状态估计器，对车辆行驶状态进行估计。同时，考虑车辆质量变化对车辆状态估计精度的影响，建立了融合策略基于 K-最邻近算法(K-Nearest Neighbors, KNN)和递推最小二乘算法(Recursive Least Squares, RLS)建立车辆质量融合估计算法。该算法架构能够减小转向过程对基于 RLS 算法精度的影响。进一步，为避免训练 KNN 算法时数据集匮乏影响算法精度，本文对车辆质量融合估计算法设计了数据集自更新和模型自学习功能，降低算法数据集建立成本。

1.4 传感器故障诊断研究介绍

车载传感器广泛用于获取多种车辆状态信息和信号,为实现车辆智能控制提供了重要的支持。分布式线控底盘车辆相较于传统车辆具有更多的电控执行器,和更高的可控自由度,也就相对于传统车辆需要更多的传感器对车辆参数进行实时监测,保证车辆的行驶安全。分布式线控底盘车辆具有四轮独立转向的特点,各车轮转角值对准确估计车辆状态、实现车辆稳定性控制具有重要意义。




图 1.10 分布式线控底盘结构示意图

传统车辆的车轮转角的测量难度较高,通常情况下只能通过传感器间接测量并通过阿克曼转向关系或主销角度关系进行解算^[88]。如图 1.10 所示分布式线控底盘车辆由于其结构优势,可以将车轮转角传感器安装在转向电机附近,对车轮转角进行直接的测量与解算。

但是,分布式线控底盘车辆车轮转角传感器位于车身之外,靠近转向电机,易受外部环境影响产生污染和损害^[89]。同时,基于模型的车辆状态估计算法的基本思路是针对传感器信号值和估计值的数据最优融合,准确的车轮转角传感器测量值对车辆状态估计的精度有直接影响。因此,有关如何保证车轮转角传感器的

准确性和稳定性,并在传感器故障情况下对车轮转角进行实时估计的传感器故障诊断研究成为了分布式线控底盘车辆行驶安全中至关重要的研究。

故障诊断理论的相关研究起源于美国麻省理工学院的 Beard Richard Vernon 提出基于系统内部重构的系统闭环稳定与观测器输出值对比判断故障的思想^[90]。经过多年的发展,目前故障诊断的相关研究主要分为基于模型的方法、基于知识的方法和基于数据的方法^[91]。

(一) 基于模型的传感器故障诊断算法

美国麻省理工学院的 Alan Willsky 等提出了将动态过程模型应用于分析输入和输出信号的理念^[92]。模型系统信号与实际系统信号之间的差异被定义为“残差”。残差信号中含有丰富的故障信息,可以根据适当的决策函数或决策规则进行故障诊断。这是最早的故障检测方法,其原理是检测模型系统的行为是否与实际系统的行为一致。该方法通常与对故障量的估计方法一起用于构建传感器故障诊断过程。通过建立监测模型并选择决策函数或诊断规则,将残差的评估函数与选定的残差阈值进行比较,从而检测到变化并判断传感器系统故障^[93]。基于模型的传感器故障诊断算法是一种重要且具有挑战性的方法,目前仍是故障诊断理论研究的热点方向^[94]。

哈尔滨工业大学的朱平等基于线性模型建立了基于模型的传感器故障诊断方法,实现了对多传感器系统的精确定位,并通过对二阶系统传感器故障诊断进行仿真实验,验证了其具有一定的工程应用价值^[95]。

(二) 基于知识的传感器故障诊断算法

由于不同的传感器故障类型之间的复杂性和差异性,许多复杂控制系统很难获得精确的数学模型。为此,基于知识的故障诊断方法应运而生。该方法不需要定量的数学模型,而是使用专家系统来定位和诊断传感器故障。使用专家系统可以分析系统推理机中的模糊逻辑关系和现有历史数据。历史故障信息和专家知识用于诊断传感器是否存在故障。根据推理机的不同,基于知识的传感器故障诊断方法可以分为基于规则的诊断方法专家系统和基于模糊推理的诊断专家系统^[96]。由于知识的有限性、规则的单一重复性和诊断功能定义的主观性,基于知识的故障诊断方法还不够完善。

美国 NASA 的 Jonny Carlos 等提出了一个专家系统, 该系统使用面向对象建模、规则和语义网络来处理传感器故障, 同时对传感器故障下的系统故障检测进行建模。通过与基于神经网络的传感器故障诊断方法相比, 表征了基于知识的传感器故障诊断算法额外的功能^[97]。

(三) 基于学习的传感器故障诊断算法

近年来, 计算机技术的发展为传感器故障诊断技术提供了新的理论基础。数据驱动的传感器故障诊断方法是一种新兴的方法。美国德州大学达拉斯分校的 Mehrdad Heydarzadeh 等人将传感器故障诊断的研究扩展到了数据驱动方法^[98]。该方法将传感器故障识别问题视为模式识别问题。基于数据处理, 获取传感器故障样本数据并进行训练以获得分类器, 根据分类规则匹配数据^[99]。但是同时, 这种新型的故障诊断方法也存在着缺乏故障数据、工业开发过程中集成思想等问题需要解决^[100]。

意大利佩鲁贾大学的 Nicholas Cartocci 等提出了一种通用鲁棒数据驱动多传感器故障检测方法, 并提出了一种基于故障幅值重构的故障传感器序列隔离方法。通过多个飞行数据记录进行仿真验证, 并于其它算法进行了比较, 验证了算法有效性^[101]。

同济大学的吴光强等基于逐步回归算法建立变速器传感器模型, 对残差序列分解后提取各个节点的香农熵作为特征值, 使用概率神经网络对传感器故障特征值进行识别, 通过硬件在环实验验证了该算法正确率达到 98.5%, 算法具有一定的普适性^[102]。

通过以上对传感器故障诊断的研究结果与发展可以看出:

(1) 分布式线控底盘车辆由于其结构优势, 可以利用车轮转角传感器直接测量车轮转角, 避免解算过程中带来的测量误差。另一方面, 车轮转角传感器不受车身保护, 且靠近转向电机, 易受外部环境因素影响造成故障。

(2) 目前针对传感器故障诊断的研究中, 基于数据的传感器故障诊断方法具有较大的研究潜力, 但受限于分布式线控底盘车辆发展历程较短, 缺乏传感器故障数据。基于知识的传感器故障诊断方法也具有知识的有限性和模式单一性等缺点。基于模型的传感器故障诊断方法在传统车辆及其它工业应用方面发展较为

成熟，具有应用于分布式线控底盘车轮转角传感器故障诊断的可行性。

因此，本文建立分布式线控底盘车辆转向电机数学模型，通过残差卡方检验方法对比基于 EKF 算法车轮转角估计值与车轮转角传感器测量值识别车轮转角传感器故障。同时，当故障诊断算法识别到车轮转角传感器故障时输出车轮转角估计值，从而保证分布式线控底盘车辆状态估计准确性。

1.5 本文主要研究内容

随着对分布式线控底盘车辆的相关研究不断深入，开发一种充分利用分布式线控底盘车辆的四轮转角和驱动转矩精确可知的优势的车辆状态估计算法有待进一步研究；同时，分布式线控底盘车辆相对与传统车辆，可以将车轮转角传感器安装至转向电机，从而避免通过其它传感器值解算而造成的测量误差。但安装至车身环境以外转向电机附近的车轮转角传感器易受到外部环境的影响而造成一定损害。如何通过建立传感器故障诊断算法，对车轮转角传感器进行实时故障诊断并在传感器故障情况下依然能够获取车轮转角值，对保证车辆行驶安全性具有重要意义；另一方面，基于模型的车辆状态估计算法中车辆质量的准确性对车辆状态估计结果具有较大影响。而基于模型的车辆状态估计算法的研究一般将车辆质量视为已知并且不会变化的常数。当车辆多次行驶间车辆乘员与货物的变化会改变车辆质量从而影响车辆状态估计算法精度。将车辆质量估计算法和车辆状态估计算法相结合，从而降低模型不确定性对估计精度的相关研究有待进一步研究。

因此，本文以分布式线控底盘车辆为研究平台，首先搭建基于扩展卡尔曼滤波算法和卡方检验法的车轮转角传感器故障诊断算法，识别车轮转角传感器故障，并在传感器故障情况下估计车轮转角值，保证车辆行驶安全性。其次，建立基于双无迹粒子滤波算法的车辆状态估计算法，充分利用分布式线控底盘车辆四轮转角转矩精确可知的优势，通过双观测器算法架构降低模型不确定度和模型误差对车辆状态估计精度的影响。最后，针对基于模型的车辆估计算法的车辆质量参数变化降低车辆状态估计精度的问题，建立具有自更新数据集功能的融合 K-最邻近算法和递归最小二乘算法的车辆质量估计器。保证获取准确的车辆质量参数的同时，解决了基于递归最小二乘算法的车辆质量估计器在车辆转向过程中估计精

度降低的问题。

本文的研究内容与全文架构如下：

第1章为绪论，对分布式线控底盘车辆的研究发展、车辆状态估计的研究历程和传感器故障诊断的相关方法进行介绍。针对如何保证基于模型的分布式线控底盘车辆状态估计算法在车辆质量变化下的保证车辆状态估计的准确性和准确、可靠、及时的识别分布式线控底盘车辆车轮转角传感器识别传感器故障，提出本文的主要工作和研究内容。

第2章对分布式线控底盘车辆系统进行动力学建模。建立分布式线控底盘车辆非线性动力学模型和 Pacejka 轮胎模型。设计仿真实验工况将本文所建立的分布式线控底盘车辆模型与 CarSim 软件的整车动力学模型进行对比验证，从而保证后续章节建立的基于此非线性动力学模型的分布式线控底盘车辆状态估计算法的模型准确性。

第3章搭建分布式线控底盘车辆车轮转角传感器故障诊断算法。首先，介绍了本文所建立的传感器故障诊断框架，搭建分布式线控底盘车辆转角电机数学模型。其次，基于转向电机数学模型建立基于扩展卡尔曼滤波算法的分布式线控底盘车辆转角估计算法，并利用残差卡方检验法对比车轮转角估计值与车轮转角传感器测量值。最后，介绍了传感器故障分类及特点，进行仿真实验验证验证算法有效性。

第4章建立分布式线控底盘车辆状态估计算法。首先，介绍了 KNN 算法与 RLS 算法的基本原理。建立融合 KNN 和 RLS 算法对分布式线控底盘车辆质量估计算法框架。其次，建立了基于双无迹粒子滤波的分布式线控底盘车辆状态估计算法，采用双观测器架构降低模型不确定性对车辆状态估计精度的影响。然后，为提高算法准确度和鲁棒性，对 KNN 与 RLS 车辆质量融合估计算法设计了数据集更新功能。最后，介绍了 KNN 数据集的建立方法，并通过仿真实验对车辆质量融合估计算法和分布式线控底盘车辆状态估计算法进行验证。

第5章为进一步验证本文所提出的分布式线控底盘车辆传感器故障诊断和车辆状态估计算法的准确性和实时性，基于实验室转向系统硬件搭建了分布式线控底盘车辆系统驾驶模拟器。介绍驾驶模拟器仿真实验硬件设备及其基本功能。将

传感器故障诊断和车辆状态估计算法基于代码生成方式嵌入 NI PXI 工控机中，通过模拟器方向盘与油门踏板输入驾驶指令进行传感器正常情况下和传感器故障情况下的车辆状态估计算法仿真实验验证。

第 6 章对全文工作进行总结，并对后续研究内容和研究方向进行展望。

本文技术路线框架图如图 1.11 所示。




图 1.11 本文技术路线框架图

第2章 分布式线控底盘车辆模型建立

准确的车辆模型是基于模型的分布式线控底盘车辆状态估计算法基础。分布式线控底盘车辆动力学模型是一种复杂的高阶非线性系统。因此,本章在保证准确性的前提下基于合理的模型假设,建立分布式线控底盘车辆非线性动力学模型。通过与 CarSim 车辆模型进行对比,验证车辆模型准确性。从而保证后续章节所建立的基于模型的车辆状态估计算法的模型准确性。

2.1 分布式线控底盘车辆非线性动力学模型建立

2.1.1 模型假设

根据第1章对具有四轮独立线控转向和四轮独立驱动模块的分布式线控底盘车辆的介绍,本文将按照算法需求搭建分布式线控底盘车辆系统动力学模型。为简化算法模型复杂度,本文对采用降阶建模的方法对模型进行简化。模型简化假设如下:

(1) 本文主要研究分布式线控底盘车辆行驶过程中的传感器故障诊断和车辆状态估计,模型主要针对于车辆底盘执行器部分。因此,省略线控转向系统中方向盘总成和线控驱动制动系统中的踏板总成等驾驶员输入部分;

(2) 为简化模型、易于仿真分析,同时在保证模型准确性的情况下,建模时忽略制动盘、电机转子等旋转件工作过程中所产生的摩擦力和摩擦力矩;

(3) 假设驱动电机和转向电机等外特性不受环境温度等影响,在建立分布式线控底盘车辆状态估计其模型时视为线性定常元件,并将电机简化为直流电机。

(4) 本文假设车辆行驶于平坦路面,车辆行驶平面与水平面平行,不考虑车轮垂向运动并忽略车辆悬架位移变化对车辆轮荷、载荷转移的影响。

(5) 忽略车辆在车身侧倾和车辆在垂直方向上的运动对车辆纵向、侧向和横摆方向上的动力学影响。

2.1.2 非线性车辆动力学模型

第4章所建立的基于DUPF算法的车辆状态估计算法是一种基于模型的车辆状态估计器，算法需依据一个车辆动力学参考模型建立，模型准确性对车辆状态估计结果的精度有较大影响。本章所建立的非线性车辆动力学模型主要考虑车辆纵向、侧向以及横摆三个运动自由度，并引入上节所考虑模型简化假设。如图2.1所示为在车身坐标系下建立的分布式线控底盘车辆非线性动力学模型。




图 2.1 分布式线控底盘车辆非线性动力学模型

图 2.1 中，在轮胎坐标系下 α_{ij} 为轮胎侧偏角， δ_{ij} 为车轮转角， X, Y 为车身坐标系下轮心处 X, Y 方向分力， F_{xij}, F_{yij} 为轮胎坐标系下的轮胎纵向力和侧向力， θ_{ij} 为车轮实际行驶朝向角，（其中 i 为 l, r ，代表左轮和右轮； j 为 f, r ，代表前轮和后轮）。在车身坐标系下， V_x 为车辆质心纵向速度， a_x 为车辆质心纵向加速度， V_y 为车辆质心侧向速度， β 为车辆质心侧偏角。轮胎力与车身坐标系下纵向力和侧向力关系为：

$$\begin{bmatrix} X_{ij} \\ Y_{ij} \end{bmatrix} = \begin{bmatrix} \cos \delta_{ij} & -\sin \delta_{ij} \\ \sin \delta_{ij} & \cos \delta_{ij} \end{bmatrix} \begin{bmatrix} F_{xij} \\ F_{yij} \end{bmatrix} \dots\dots\dots (2.1)$$

由于本文所研究的分布式线控底盘车辆由轮毂电机直接驱动车轮，电控驱动系统响应速度快，轮胎驱动力矩可以通过车辆控制系统精确获得。则轮胎纵向力可以表示为：

$$F_{xij} = \frac{T_w - T_f - J\dot{\omega}}{R_w} \dots\dots\dots (2.2)$$

式（2.2）中， J 为轮胎和轮边总成中旋转部件转动惯量， T_w 为驱动力矩， T_f 为轮胎摩擦力矩， $\dot{\omega}$ 为轮胎转动角速度， R_w 为轮胎滚动半径。

由于车辆行驶时，侧向力作用于轮胎时轮胎会发生一定形变，使得轮胎实际行驶方向与车轮转角之间存在偏差。因此，对于轮胎侧向力，轮胎侧偏角和车轮转角之间关系为：

$$\alpha_{ij} = -\delta_{ij} + \theta_{ij} \dots\dots\dots (2.3)$$

车身坐标系下，分布式线控底盘车辆质心侧偏角可由车辆质心纵向速度和侧向速度表示为：

$$\beta = \arctan\left(\frac{V_y}{V_x}\right) \dots\dots\dots (2.4)$$

除轮胎力外，分布式线控底盘车辆在行驶过程中受到的空气阻力为：

$$F_d = \frac{1}{2} \rho C_d A v_x^2 \dots\dots\dots (2.5)$$

式（2.5）中 ρ 为当前车辆行驶环境中空气密度通常情况下为定值，本文取空气密度 $\rho = 12.9kg/m^3$ 。 C_d 为空气阻力系数，本文取 $C_d = 0.3$ 。 A 为车辆迎风面积，本文取 $A = 2.4m^2$ 。则分布式线控底盘车辆纵向、侧向、横摆方向动力学方程为：

$$\left\{ \begin{array}{l} ma_x = m(\dot{V}_x - \dot{\phi}V_y) = \sum_{i=l}^r \sum_{j=f}^r X_{ij} - F_d \\ ma_y = m(\dot{V}_y - \dot{\phi}V_x) = \sum_{i=l}^r \sum_{j=f}^r Y_{ij} \dots\dots\dots (2.6) \\ I_z \ddot{\phi} = \frac{t}{2}(-X_{lf} + X_{rf} - X_{lr} + X_{rr}) \\ \quad + l_f(Y_{lf} + Y_{rf}) - l_r(Y_{lr} + Y_{rr}) \end{array} \right.$$

其中， $\dot{\phi}$ 为车辆横摆角速度， m 为车辆总质量， l_f ， l_r 为车辆质心与车辆前轴和后轴的距离。

在考虑轮荷转移情况下，各车轮所受垂向力如式(2.7)所示：

$$\left\{ \begin{array}{l} F_{zlf} = \frac{mgl_r}{2(l_f + l_r)} - \frac{m_s a_x h_s}{2(l_f + l_r)} - \frac{m_s a_y h_s}{t_f} \\ F_{zrf} = \frac{mgl_r}{2(l_f + l_r)} - \frac{m_s a_x h_s}{2(l_f + l_r)} + \frac{m_s a_y h_s}{t_f} \dots\dots\dots (2.7) \\ F_{zlr} = \frac{mgl_r}{2(l_f + l_r)} + \frac{m_s a_x h_s}{2(l_f + l_r)} - \frac{m_s a_y h_s}{t_r} \\ F_{zrr} = \frac{mgl_r}{2(l_f + l_r)} + \frac{m_s a_x h_s}{2(l_f + l_r)} + \frac{m_s a_y h_s}{t_r} \end{array} \right.$$

式(2.7)中， m_s 为车辆簧载质量， h_s 为车辆簧载质量质心高度， t_f 为前轮轮距， t_r 为后轮轮距， F_{zij} 为轮胎坐标系下的轮胎垂向力（其中 i 为 l, r ，代表左轮和右轮； j 为 f, r ，代表前轮和后轮）。

2.2 轮胎侧偏模型

如式(2.1)所示，对于分布式线控底盘车辆动力学模型，准确的轮胎侧偏模型式求取车身坐标系下侧向力的关键基础。因此，本节选取有效的轮胎模型以表示车辆各车轮轮胎力与轮胎参数之间的函数关系，准确表征车辆动力学。目前常用的轮胎模型主要可以分为：物理模型、经验-半经验轮胎模型和有限元轮胎模

型，每种类型的轮胎模型各有其优缺点。

2.2.1 轮胎模型简介

常见的物理模型主要包括刷子模型、梁模型和弦模型。其中物理模型基于明确的物理表达式但其在多数行驶工况下精度较低^[103]。有限元模型能够准确表达轮胎在行驶过程中瞬态和稳态的动力学性能，但同时具有模型建模难度大，计算复杂度高的缺点。经验-半经验模型在模型精度较高同时轮胎力计算较为简便。

2.2.2 Pacejka 轮胎模型

基于上节所介绍的各种轮胎模型的特性，本文选用经验-半经验模型中的 Pacejka 轮胎模型。Pacejka 轮胎模型的计算公式为^[104]：

$$y = D \sin \left\{ C \arctan \left[Bx - E \left(Bx - \arctan Bx \right) \right] \right\} \dots\dots\dots (2.8)$$

Pacejka 轮胎模型的部分曲线如图 2.2 所示。




图 2.2 Pacejka 轮胎模型示意图

其中， y 代表该公式所考察的轮胎力，在本文中为轮胎侧向力， x 代表轮胎侧偏角， B 代表轮胎刚度系数， C 代表轮胎形状系数， D 代表最大值点， E 代表轮胎曲率系数。进一步，基于式 (2.9) 中所示车辆运动学与车轮转角关系可以计算得到个车轮的行驶方向角。

$$\begin{bmatrix} \theta_{lf} \\ \theta_{rf} \\ \theta_{lr} \\ \theta_{rr} \end{bmatrix} = \begin{bmatrix} \arctan\left(\frac{V_y + \dot{\phi}l_f}{V_x - \dot{\phi}t/2}\right) \\ \arctan\left(\frac{V_y + \dot{\phi}l_f}{V_x + \dot{\phi}t/2}\right) \\ \arctan\left(\frac{V_y - \dot{\phi}l_f}{V_x - \dot{\phi}t/2}\right) \\ \arctan\left(\frac{V_y - \dot{\phi}l_f}{V_x + \dot{\phi}t/2}\right) \end{bmatrix} \dots\dots\dots (2.9)$$

根据式 (2.7) 得到轮胎的垂直载荷, 结合式 (2.8) 和式 (2.9) 求出轮胎滑移角, 最后基于 Pacejka 轮胎模型求出轮胎侧向力。

2.3 CarSim 车辆模型

CarSim 软件是一种专门的车辆动力学仿真软件, 主要被应用于对汽车整车操纵稳定性、制动性、平顺性、动力性和燃油经济性进行仿真。目前, CarSim 软件被各汽车厂商广泛的应用于与车辆控制相关的系统开发。

为验证本文所建立的分布式线控底盘车辆非线性动力学模型的准确性, 在模型层面上保证本文后续章节所建立的车辆状态估计算法的准确性。本章建立车辆行驶特征工况将非线性车辆动力学模型与 CarSim 中车辆模型在相同行驶工况下进行对比, 并在 CarSim 中进行如下设置: 车身设置为 “D-Class, Sedan”; 轮胎选择为 “215/55 R17”; 制动系统和悬架系统设定为该车型默认设置。CarSim 中车辆模型的主要参数如表 2.1 所示:

表 2.1 CarSim 车辆模型的主要参数

参数	单位	值
轴距 L	m	2.866
前轴轮距 t_f	m	1.55
后轴轮距 t_r	m	1.55
车辆质心到车辆前轴距离 l_f	m	1.11
车辆质心到车辆后轴距离 l_r	m	1.766

簧载质量质心高度 h_s	m	0.52
簧载质量 m_s	kg	1660
簧载质量绕车身坐标系 z 轴转动惯量 I_z	$kg \cdot m^2$	2315.3
车轮滚动半径 R_f	m	0.325
车辆总质量 m	kg	1980

2.4 模型准确性仿真验证

为验证本文所建立的分布式线控底盘车辆非线性动力学模型，本节在 MATLAB/Simulink 中搭建车辆动力学模型，并按照如表 2.1 所示的车辆参数对 CarSim 中车辆模型进行设置。同时，为满足模型验证实验的需求，对 CarSim 和 MATLAB/Simulink 中输入输出接口设置为：

- (1) 输入 CarSim 参数：各车轮转角，纵向速度。
- (2) CarSim 输出参数：纵向速度、侧向速度、纵向加速度、横摆角速度。
- (3) 输入 MATLAB/Simulink 参数：各车轮转角，纵向速度。
- (4) MATLAB/Simulink 输出参数：纵向速度、侧向速度、纵向加速度、横摆角速度。

并对 CarSim 中选取的车辆模型进行改装，使其满足分布式线控底盘车辆模型特点：取消发动机和各传动系统，由 MATLAB/Simulink 直接控制四轮驱动力矩、制动力矩和车轮转角。


同时为保证仿真工况的一致性，在模型验证仿真实验中，设定输入 CarSim 和 MATLAB/Simulink 中的分布式线控底盘车辆各车轮转角和车速相同。

由于分布式线控底盘车辆相对于传统车辆可以在车辆低速行驶时控制后轮与前轮转向方向相反提高车辆灵活性，车辆高速行驶时控制后轮与前轮转向方向相同提高车辆行驶稳定性。为保证本文所建立的车辆状态估计器在分布式线控底盘车辆多种工况下的有效性。本章选择不同车速和车轮转角的典型工况，包括分

布式线控底盘车辆低速车轮转角正弦输入、中速前轮转角正弦输入和高速四轮转角阶跃输入三种工况进行仿真验证。由于本章所建立的分布式线控底盘车辆主要用于车辆状态估计算法建立,不涉及车轮转向过程中角闭环控制相关研究。所以在车辆模型验证仿真实验中,车轮转角值直接作用于各车轮。

2.4.1 低速四轮转角正弦输入仿真

分布式线控底盘车辆在低速行驶转向时,车辆后轮可以与前轮转向相反方向,从而提高车辆低速行驶时的灵活性。为验证车辆动力学模型在该工况下有效性,设定低速四轮转角正弦输入仿真中选择车速为 20km/h,车轮转角为初始转角 0° 、幅值 15° 、周期为 10 秒的正弦输入,后轮转角与前轮转角相反。将 MATLAB/Simulink 中分布式线控底盘车辆非线性动力学模型输出的车身坐标系下质心位置的车辆状态参数与 CarSim 模型的输出参数对比,仿真结果如图 2.3 所示。






图 2.3 低速四轮转角正弦输入工况

由图 2.3(a)和图 2.3(c)可知,由于四轮转角正弦输入车辆纵向速度在 20km/h 附近波动,车辆纵向加速度在 0 附近波动,车辆非线性动力学模型和 CarSim 保持一致;在图 2.3 (b) 中,分布式线控底盘车辆模型和 CarSim 模型车辆质心侧向速度数值与趋势基本保持一致;车辆横摆角速度曲线如图 2.3 (d) 所示,分布式线控底盘车辆横摆角速度曲线与 CarSim 车辆模型间误差较小。从而证明本文基于 MATLAB/Simulink 中搭建的分布式线控底盘车辆非线性动力学模型与 CarSim 模型在该仿真工况下的模型精度接近。

2.4.2 中速前轮转角正弦输入仿真

分布式线控底盘车辆在中速行驶工况下需要同时考虑车辆的操纵稳定性和灵活性。因此在本工况下选择车速为 50km/h,前轮转角为初始转角 0° 、幅值 6° 、周期为 10 秒的正弦输入,后轮转角为 0 度。仿真结果如图 2.4 所示。




图 2.4 中速前轮转角正弦输入仿真

图 2.4 中分别为中速前轮转角正弦输入仿真中车辆质心位置下的纵向速度、侧向速度、纵向加速度和横摆角速度曲线。本文所建立的模型与 CarSim 模型在相同的中速前轮转角正弦输入仿真工况下的瞬态表现相近。因此,认为在该工况下本文所建立的非线性车辆动力学模型与 CarSim 模型精度基本一致,进一步证明本文所建立的车辆模型在中速前轮转角正弦输入工况下可以用于车辆状态估计算法的设计。

2.4.3 高速四轮转角阶跃输入仿真

车辆在高速行驶时主要考虑车辆行驶稳定性,因此分布式线控底盘车辆在高

速行驶转向时可以控制后轮转向方向与前轮相同,从而提高车辆行驶稳定性。因此,建立仿真工况为:车速恒定为 80km/h,在仿真开始第 2 秒时,在 0.1 秒内对前后轮同时施加 3 度的车轮转角阶跃输入信号,前后轮转角方向相同。仿真结果如图 2.5 所示。




图 2.5 高速四轮转角阶跃输入仿真

通过图 2.5 (a) 和图 2.5 (c) 可知,在车轮四轮转角阶跃输入之前,本文所建立的车辆动力学模型与 CarSim 模型在纵向速度和纵向加速度之间存在较小偏差。但当车轮转角阶跃变化后,本文所建立的分布式线控底盘车辆模型的质心位置下的车辆状态参数与 CarSim 模型基本一致。证明本文所建立的非线性车辆动力学模型在瞬态相应下的模型准确性较好。保证了基于该车辆模型建立的车辆状

态估计算法的准确性。

通过仿真对比试验结果可知，本章所建立的分布式线控底盘车辆非线性动力学模型准确性与 CarSim 模型精度基本一致，保证了后续章节建立的车辆状态估计算法的模型准确性。

2.5 本章小结

本章建立了双无迹粒子滤波算法中分布式线控底盘车辆非线性动力学模型并将所建立的车辆非线性动力学模型与 CarSim 模型进行联合仿真和模型验证。首先，建立了基于模型的分布式线控底盘车辆状态估计算法所使用的车辆非线性动力学模型，并引入了 Pacejka 轮胎模型作为获取分布式线控底盘车辆轮胎侧向力的方式；其次，设置 CarSim 车辆模型相关参数，并在 MATLAB/Simulink 软件中搭建分布式线控底盘车辆非线性动力学模型；最后，为验证模型准确性，选取分布式线控底盘车辆典型行驶工况，将分布式线控底盘车辆非线性动力学模型与 CarSim 车辆模型进行联合仿真实验验证模型准确性，从而保证第 4 章建立的车辆状态估计算法的模型准确性。

第3章 分布式线控底盘车辆车轮转角传感器故障诊断算法研究

本文在第2章中已经对分布式线控底盘车辆状态估计算法中车辆非线性动力学模型进行了建立与验证。本章以分布式线控底盘车辆车轮转角传感器故障诊断作为主要研究内容,实现对转角传感器常见故障类型的诊断,并基于诊断结果输出车轮转角传感器容错补偿估计结果,从而保证车辆行驶安全性。在本章的研究中,采用扩展卡尔曼滤波算法建立分布式线控底盘车辆车轮转角实时估计器。通过残差卡方检验法对车轮转角传感器测量值与车轮转角估计值之间的残差序列统计学信息进行分析,以实现分布式线控底盘车辆车轮转角传感器故障诊断算法的设计。当车轮转角传感器故障诊断算法识别到传感器故障时,警示驾驶员,并向第4章所建立的车辆状态估计算法输出车轮转角估计值以替代转角传感器测量值,保证车辆状态估计算法的准确性。

3.1 分布式线控底盘车辆车轮转角传感器故障诊断算法框架

分布式线控底盘车辆的机械结构优势可以通过在转向电机旁安装车轮转角传感器,从而实现对车轮转角直接测量,避免传统车辆对车轮转角估计过程中由解算过程和机械系统传动带来的误差。但同时,安装在车身保护环境之外、转向电机附近的车轮转角传感器容易受到传感器发热、外部极端环境等影响造成传感器故障。准确、可靠的获取车轮转角值是精准的车辆底盘控制和准确的车辆状态的基础。因此,通过传感器故障诊断算法实时估计分布式线控底盘车辆车轮转角,诊断车轮转角传感器故障对保证车辆形式安全性具有重要意义。

目前,基于模型的线控底盘车轮转角传感器故障诊断研究有基于车辆动力学模型估计车轮转角和基于转向电机模型估计车轮转角等方法^[105]。由于分布式线控底盘车辆转向电机通常为低阶非线性模型,考虑到EKF算法在处理低阶非线性模型状态估计问题具有良好的准确性和实时性。本文选择基于EKF算法通过建立转向电机数学模型估计车轮转角,将车轮转角估计值与车轮转角传感器测量

值基于残差卡方检验法进行对比,从而实现车轮转角传感器故障诊断。当残差卡方检验法诊断车轮转角传感器为故障情况下时,将传输至车辆状态估计算法的车轮转角值由传感器估计值切换为 EKF 算法估计值,从而保证车辆状态估计算法的准确性。本文所建立的传感器故障诊断算法框架如图 3.1 所示。




图 3.1 传感器故障诊断算法框架图

3.2 基于扩展卡尔曼滤波的转向电机转角传感器故障诊断算法设计

本节建立分布式线控底盘车辆转向电机转角传感器故障诊断策略,建立转角

电机数学模型,并基于该模型建立扩展卡尔曼滤波算法,对车轮转角估计值与转角传感器输出值进行残差卡方检验实现对转角传感器故障诊断。

3.2.1 转角电机数学模型建立

EKF 算法属于一种基于模型的状态估计算法,准确的转角电机数学模型能够降低由于模型不确定度造成的车轮转角估计误差。建立三相电机静止坐标系下的电压电流模型作为 EKF 算法模型^[106]。

三相永磁同步电机(Permanent Magnet Synchronous Motor, PMSM)静止坐标系下电学方程中,电压方程为:

$$\begin{cases} u_{\alpha} = R_s i_{\alpha} + L_s \frac{di_{\alpha}}{dt} - \omega_e \psi_f \sin \theta_e \\ u_{\beta} = R_s i_{\beta} + L_s \frac{di_{\beta}}{dt} - \omega_e \psi_f \cos \theta_e \end{cases} \quad (3.1)$$

电流方程为:

$$\begin{cases} \frac{di_{\alpha}}{dt} = -\frac{R_s}{L_s} i_{\alpha} + \frac{\psi_f}{L_s} \omega_e \sin \theta_e + \frac{u_{\alpha}}{L_s} \\ \frac{di_{\beta}}{dt} = -\frac{R_s}{L_s} i_{\beta} + \frac{\psi_f}{L_s} \omega_e \cos \theta_e + \frac{u_{\beta}}{L_s} \end{cases} \quad (3.2)$$

其中, u_{α} , u_{β} , i_{α} , i_{β} 分别为 α 轴和 β 轴的电压和电流; L_s 为电感; R_s 为绕组电阻; ω_e 为转子角速度; θ_e 为转子角度; ψ_f 为转子磁链。

选取 α 轴和 β 轴电流、转子角速度和转子角度建立系统状态变量为:

$$x = [i_{\alpha} \quad i_{\beta} \quad \omega_e \quad \theta_e]^T \quad (3.3)$$

假设 PMSM 转向电机惯性时间常数远大于系统采样周期,即转子角加速度趋近于 0,则有:

$$\frac{d\omega_e}{dt} = 0 \quad (3.4)$$

则建立基于扩展卡尔曼滤波算法系统状态方程形式为:

$$\begin{cases} \frac{dx}{dt} = f(x) + Bu \\ y = Cx \end{cases} \dots\dots\dots (3.5)$$

将式 (3.1)、式 (3.2) 所示的转向电机数学模型转化为如式 (3.5) 所示的形式, 则各参数可以表示为:

$$f(x) = \begin{bmatrix} -\frac{R_s}{L_s} i_\alpha + \frac{\psi_f}{L_s} \omega_e \sin \theta_e \\ -\frac{R_s}{L_s} i_\beta + \frac{\psi_f}{L_s} \omega_e \cos \theta_e \\ 0 \\ \omega_e \end{bmatrix} \dots\dots\dots (3.6)$$

$$B = \begin{bmatrix} \frac{1}{L_s} & 0 & 0 & 0 \\ 0 & \frac{1}{L_s} & 0 & 0 \end{bmatrix}^T \dots\dots\dots (3.7)$$

$$C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \dots\dots\dots (3.8)$$

$$u = \begin{bmatrix} u_\alpha & u_\beta \end{bmatrix}^T \dots\dots\dots (3.9)$$

$$y = \begin{bmatrix} i_\alpha & i_\beta \end{bmatrix} \dots\dots\dots (3.10)$$

基于式 (3.9) - 式 (3.14), 建立离散转向电机电学方程, 从而基于该模型建立基于 EKF 算法的传感器故障诊断算法。

3.2.2 扩展卡尔曼滤波算法建立

由本章所建立的转向电机数学模型可知, 该模型为一低阶非线性模型。EKF 算法在处理非高阶非线性系统时具有良好的实时性和准确性。因此, 本文基于 EKF 算法建立车轮转角估计算法。EKF 算法处理非线性系统状态估计问题的主要思想是将非线性系统状态方程进行离散化与线性化处理, 算法估计过程的主要运算过程可以分为预测步与校正步^[107]。将式 (3.6) - 式 (3.10) 带入式 (3.5) 线性化离散化后有转向电机数学模型为:

$$\begin{cases} x(k+1) = A(k)x(k) + BTu(k) + V(k) \\ y(k+1) = CTx(k+1) + W(k) \end{cases} \dots\dots\dots (3.11)$$

式(3.15)中 T 为系统采样周期; $V(k)$ 为第 k 步计算时系统噪声; $W(k)$ 为第 k 步计算时测量噪声; 本文假设驱动电机系统噪声与测量噪声相互独立且服从正态分布。则可以表示为:

$$E\{V(k)\} = 0 \dots\dots\dots (3.12)$$

$$E\{W(k)\} = 0 \dots\dots\dots (3.13)$$

式(3.11)中, $A(k)$ 为系统转移矩阵, 则 $A(k)$ 可表达为:

$$A(k) = \text{diag}([1 \quad 1 \quad 1]) + TF(k) \dots\dots\dots (3.14)$$

式(3.14)中:

$$F(k) = \left. \frac{\partial f(k)}{\partial x} \right|_{x=x(k)} \dots\dots\dots (3.15)$$

即, $F(k)$ 为 $f(k)$ 在 $x=x(k)$ 时对 x 的偏导值。进一步可得 $F(k)$ 为:

$$F(k) = \begin{bmatrix} -\frac{R_s}{L_s} & 0 & \frac{\psi_f}{L_s} \sin \theta_e(k) & \frac{\psi_f}{L_s} \omega_e(k) \cos \theta_e(k) \\ 0 & -\frac{R_s}{L_s} & -\frac{\psi_f}{L_s} \cos \theta_e(k) & \frac{\psi_f}{L_s} \omega_e(k) \sin \theta_e(k) \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \dots\dots\dots (3.16)$$

同时, 分布式线控底盘车辆车轮转角电机的系统噪声和测量噪声的协方差矩阵 Q , R 可表示为:

$$Q = E\{VV^T\} \dots\dots\dots (3.17)$$

$$R = E\{WW^T\} \dots\dots\dots (3.18)$$

在将非线性系统基于泰勒展开法线性化后, EKF 算法步骤可以表示为:

(一) 预测步: 通过对状态变量进行预测, 基于第 k 步输入的控制变量 $u(k)$ 和第 k 步状态变量的后验估计 $\hat{x}(k)$ 预测第 $k+1$ 步的状态变量的先验估计 $\tilde{x}(k+1)$ 并计算对应的观测变量先验估计 $\tilde{y}(k+1)$:

$$\tilde{x}(k+1) = \hat{x}(k) + T[f(\hat{x}(k)) + Bu(k)] \dots\dots\dots (3.19)$$

$$\tilde{y}(k+1) = C\tilde{x}(k+1) \dots\dots\dots (3.20)$$

(二) 校正步: 计算先验估计的系统噪声和测量噪声协方差矩阵 $\tilde{p}(k+1)$ 和卡尔曼增益矩阵 $K(k+1)$:

$$\tilde{p}(k+1) = A\tilde{p}(k)A^T + Q \dots\dots\dots (3.21)$$

$$K(k+1) = \frac{\tilde{p}(k+1)C^T}{C\tilde{p}(k+1)C^T + R} \dots\dots\dots (3.22)$$

基于卡尔曼增益矩阵对第 $k+1$ 步的状态变量先验估计 $\tilde{x}(k+1)$ 进行更新校正, 得到第 $k+1$ 步的状态变量后验估计 $\hat{x}(k+1)$ 和协方差矩阵。

$$\hat{x}(k+1) = \tilde{x}(k+1) + K(k+1)[y(k+1) - \tilde{y}(k+1)] \dots\dots\dots (3.23)$$

$$\hat{p}(k+1) = \tilde{p}(k+1) - K(k+1)C\tilde{p}(k+1) \dots\dots\dots (3.24)$$

本文所建立的分布式线控底盘车辆转向电机周期为 360° 转向电机减速器减速比为 110, 转子角度与转向电机机械角度相同。即通过对 EKF 算法估计转子角度和转向电机减速比解算车轮转角估计值后续重复各循环步骤的预测步至校正步, 实现对分布式线控底盘车辆转向电机转角估计。

3.2.3 基于残差卡方检验的传感器故障诊断策略

为准确检验车轮转角传感器故障, 本文选择在通过 EKF 算法估计车轮转角后, 将估计值与传感器测量值通过残差卡方检验法进行故障诊断, 当传感器状态被诊断为故障时, 采用 EKF 算法所估计的车轮转角参数作为车辆状态估计算法所需的车轮转角值, 实现对车辆状态的准确估计, 保证车辆行驶安全。

残差卡方检验是一种将观测值和真实值之间进行卡方检验, 比较两个变量之间差异, 判断两个变量之间关联度的统计方法, 这种方法较为广泛的应用于故障诊断的相关研究中。在传感器发生故障时, 传感器测量值的偏差会影响系统参数的统计学特性, 基于残差卡方检测法可以实时监控、诊断传感器故障, 保障车辆

行驶安全。

建立残差值 $r(k)$ 为分布式线控底盘车辆转角传感器测量值 $y(k)$ 与该时刻基于 EKF 转向电机转角后验估计值 $\hat{y}(k)$ 的差值, 带入式 (3.25) 可得:

$$r(k) = y(k) - C\hat{x}(k) \dots\dots\dots (3.25)$$

因为转向电机系统噪声与测量噪声为相互独立的高斯噪声, 所以当车轮转角传感器无故障时, 残差值 $r(k)$ 应服从各时刻相互独立均值为 0, 方差为 $A(k)$ 的正态分布, 即 $r(k) \sim N(0, A(k))$ 。其中 $A(k)$ 可以表示为:

$$A(k) = C\hat{p}(k)C^T + R \dots\dots\dots (3.26)$$

当车轮转角传感器发生故障时, 传感器测量值的统计学特征发生变化, 通过 N 个时刻内的残差值构造残差函数, 当残差函数超过设定的残差阈值后, 认为传感器发生故障并报警, 则构建残差函数 $J_R(k)$ 为:

$$J_R(k) = \sum_{i=k-N+1}^k r^T(i) A^{-1}(i) r(i) \dots\dots\dots (3.27)$$

基于残差序列的统计学特性, 当转角传感器无故障时, 残差函数 $J_R(k)$ 服从自由度为 $4N$ 的卡方分布。建立转角传感器故障报警阈值为 J_{TV} , 为避免由于传感器测量过程中数值波动或其它临时数据传输产生的传感器故障误报, 设定 ε 为误报率。则有报警状态为:

$$P\{J_R(k) > J_{TV}\} = \varepsilon \dots\dots\dots (3.28)$$

因此, 在传感器故障诊断中, 将残差函数 $J_R(k)$ 与故障误报阈值 J_{TV} 进行对比, 即可以判断并诊断传感器故障, 即:

$$\begin{cases} J_R(k) \geq J_{TV} & \text{传感器故障} \\ J_R(k) < J_{TV} & \text{传感器正常} \end{cases} \dots\dots\dots (3.29)$$

3.3 传感器常见故障分析

本章所建立的车轮转角传感器故障诊断算法的基本思想是通过分析车轮转角估计值与传感器测量值残差序列的统计学特性, 识别车轮转角传感器故障。因此, 对传感器的任意故障形式, 当传感器测量值与估计值间残差函数超过故障误

报阈值,传感器故障诊断算法即诊断车轮转角传感器为故障状态。为验证本章所建立的车轮转角传感器故障诊断算法的有效性,本节简要分析三种常见车轮转角传感器常见故障形式,并对各故障形式进行建模。

由于车辆中绝大部分传感器通过信号线路或 CAN 线路与车辆 ECU 连接,当线路出现断路等故障时也会造成传感器测量精度降低或传感器失效。而本章的主要研究针对传感器自身的故障诊断算法,因此传感器故障建模中对传感器外部线路短路或断路造成的传感器故障问题不进行深入研究与建模。但同时,传感器外部线路故障也可以通过本文所建立的残差卡方检验法进行诊断。

车辆传感器内部故障常见形式主要包括传感器卡死、传感器增益变化和传感器偏差三种形式^[108]。则传感器故障形式可以表示为:

(1) 传感器卡死: 传感器卡死主要指在测量过程中,传感器测量值始终保持定值,而不随被测变量变化而变化。当非接触式车轮转角传感器内部电极或电容断路时,传感器测量值将卡死在传感器表显最大值或最小值。传感器卡死的主要故障模式为:

$$y_m = a \cdots \cdots \cdots (3.30)$$

其中, y_m 为传感器测量值, a 为常数。

(2) 传感器增益变化: 传感器增益变化主要指在传感器测量过程中,传感器测量值与被测变量真实值存在一定倍数关系。当非接触式车轮转角传感器在极端环境温度、湿度和压力条件下,或受电磁场和放射性干扰情况下,传感器测量值将产生增益变化。传感器增益变化的主要故障模式可以表示为:

$$y_m = k \cdot y_{mr} \cdots \cdots \cdots (3.31)$$

其中, y_{mr} 为被测变量真实值, k 为增益常数。

(3) 传感器偏差: 传感器偏差主要指在测量过程中,传感器测量值与被测变量真实值之间有一固定的差值。当非接触式车轮转角传感器在内部电极或电容老化绝缘或底线故障情况下,传感器测量值会产生表显测量值波动的故障。因此传感器偏差的主要故障模式为:

$$y_m = y_{mr} + \Delta \cdots \cdots \cdots (3.32)$$

Δ 为传感器偏差值，通常为常数。

上述三种传感器内部故障具体形式示意图如图 3.2 所示。




图 3.2 传感器故障示意图

当传感器正常工作时，其信号值为：

$$y_m = y_{mr} + X \dots\dots\dots (3.33)$$

其中 $X \sim N(0, \sigma_0^2)$ 。

3.4 传感器故障诊断算法仿真验证

为验证本章所建立的车轮转角传感器故障诊断算法的有效性，本文基于 MATLAB/Simulink 搭建 PMSM 转向电机模型与基于 EKF 算法的传感器转角估计算法，并基于本章之前所介绍的传感器故障形式建立仿真工况。该仿真实验中，转向电机周期为 360° ，转向电机减速器减速比为 110，PMSM 额定电压为 12V，磁极对数为 3，定子电阻为 0.09Ω ，d 轴电感与 q 轴电感均为 $7.2 \times 10^{-5} \text{H}$ ，转子磁链为 $1.03 \times 10^{-2} \text{Wb}$ ，转子转动惯量为 $8.95 \times 10^{-5} \text{kgm}^2$ 。建立残差卡方检验算法误报率为 0.5%，则通过查表可知故障阈值 J_{TV} 为 39.997。当残差函数 $J_R(k)$ 小于故障误报阈值时，传感器故障状态为 0，证明传感器工作正常；当残差函数 $J_R(k)$ 大于故障误报阈值 J_{TV} 时，传感器故障状态为 1，传感器状态为故障。当传感器状态诊断为故障状态后，传感器故障诊断算法停止工作，车轮转角值由基于 EKF 的车轮转角估计算法估计值替代车轮转角传感器测量值，直到对传感器故障检修后手动复位。

3.4.1 基于 EKF 的分布式线控底盘车辆车轮转角估计算法验证

为保证车轮转角故障诊断算法准确性，首先对基于 EKF 的分布式线控底盘车辆车轮转角估计算法进行验证。设定该仿真工况下，仿真总时长 1 秒，车轮转角输入为周期 2 秒，幅值为 10 度的正弦曲线。则仿真结果如图 3.3 所示。




图 3.3 车轮转速、转角估计结果

图 3.3 (a) 为车轮转速，图 3.3 (b) 为车轮转角，由仿真曲线可以看出，基于 EKF 算法对车轮转速和转角估计结果与车轮实际转速与转角间误差较小，算法准确性较高。因此，验证了基于 EKF 算法建立的车轮转角传感器故障诊断算法的准确性。

3.4.2 传感器卡死仿真实验验证

建立传感器卡死故障下仿真工况为：仿真总时长 1 秒，车轮转角输入为周期 2 秒，幅值为 10 度的正弦曲线。当仿真时间为 0.3 秒时，将假定传感器内部电极、电容短路，传感器输出值卡死为 0 度。传感器故障诊断算法仿真实验结果如图 3.4 所示。




图 3.4 传感器卡死仿真图线

由图 3.4 (a) 可知, 在第 0.3 秒车轮转角传感器发生故障后, 传感器内部电极电容发生短路, 测量值突变至 0 并保持不变。但基于 EKF 的车轮转角估计算法保持跟踪车轮转动角度, 验证 EKF 算法在该工况下具有准确性和鲁棒性。而由图 3.4 (b) 可知, 在传感器发生卡死故障时, 残差函数上升至约 85.624, 超过传感器故障阈值, 传感器状态由正常状态下的 0 上升至 1。在传感器发生故障的第 0.3 秒之后, 传感器状态保持故障状态 1 不变, 残差函数置为 0, 传感器故障诊断算法需等待排查故障后手动归位。在传感器故障期间, 向车辆状态估计算法传递的车轮转角值由传感器测量值替换为基于 EKF 算法的车轮转角估计值。

3.4.3 传感器增益变化仿真实验验证

建立传感器增益变化故障仿真工况为: 仿真总时长为 1 秒, 车轮转角输入为周期 2 秒, 幅值为 10 度的正弦曲线。当仿真时间为 0.3 秒时, 将传感器输出值设定为周期为 1 秒, 幅值为 20 度的正弦曲线。仿真结果如图 3.5 所示。




图 3.5 传感器增益变化仿真图线

由图 3.5 (a) 可知, 假设车轮转角传感器受外界温度和压强变化影响产生传感器测量值突变。在第 0.3 秒车轮转角传感器发生故障后, 车轮转角传感器测量值按照周期为 1 秒, 幅值为 20 度的正弦曲线变化。而基于 EKF 的车轮转角估计算法持续准确估计车轮转角, 与实际转角误差较小。由图 3.5 (b) 可知, 当第 0.3 秒传感器发生增益变化故障时, 残差函数值上升至 69.8921 超过故障阈值, 传感器状态变为代表故障状态的 1 并保持不变。当传感器状态变为故障状态后, 残差函数变为 0 并保持不变, 待排查传感器故障后手动归位。在传感器故障期间, 传感器故障诊断算法向车辆状态估计算法传递基于 EKF 算法的车轮转角估计值。

3.4.4 传感器偏差仿真实验验证

传感器偏差仿真实验验证工况为: 仿真总时长 1 秒, 车轮转角为周期 2 秒, 幅值为 10 度的正弦曲线。当仿真时间为 0.3 秒时, 将传感器故障测量值设定为比原测量值减去 5 度的值, 并按照原车轮转角周期和幅值继续变化。仿真结果如图 3.6 所示。




图 3.6 传感器偏差仿真图线

由图 3.6 (a) 所示, 在第 0.3 秒车轮转角传感器在内部电极或电容线老化绝缘或底线故障情况下发生传感器测量值偏差故障。传感器测量值突变, 并继续按照周期为 1 秒的正弦曲线变化, 基于 EKF 算法的车轮转角估计器保持跟踪车轮转角数值。由图 3.6 (b) 可知, 在第 0.3 秒传感器发生故障时, 残差函数突变至 62.1291, 超过故障阈值 39.997, 传感器状态变为故障。在传感器故障期间向车辆状态估计算法传递车轮转角估计值, 保证车辆状态估计算法的准确性。

3.5 本章小结

本章主要研究了分布式线控底盘车辆车轮转角传感器故障诊断, 保证第 4 章所建立的车辆状态估计算法获取的车轮转角值的准确性。首先, 介绍了本章所建立的分布式线控底盘车辆车轮转角故障诊断算法框架; 其次, 搭建了分布式线控底盘车辆转向电机数学模型, 并基于该模型建立了基于扩展卡尔曼滤波的车轮转角估计算法。为实现对线控转向车辆车轮转角传感器故障诊断, 将车轮转角估计值与车轮转角传感测量值通过残差卡方检验法进行检验; 然后, 为验证算法有效性, 介绍了传感器常见故障模型; 最后, 利用 MATLAB/Simulink 搭建 PMSM 模型和传感器故障诊断算法, 验证了算法对车轮转角估计的准确性以及在传感器常见故障下的有效性。

第4章 分布式线控底盘车辆状态估计算法研究

本章基于第2章所建立的分布式线控底盘车辆模型,利用分布式线控底盘车辆具有四轮转角与驱动力矩精确可控可知的特性,并基于第3章所建立的分布式线控底盘车辆车轮转角传感器故障诊断策略,建立了基于双无迹粒子滤波算法的车辆状态估计器。这种车辆状态估计算法融合了双卡尔曼滤波算法的架构和无迹粒子滤波算法特性,在解决了粒子滤波算法粒子枯竭问题的同时,保证传感器测量值准确性,实现了对分布式线控底盘车辆状态估计。双观测器算法架构能够充分利用分布式线控底盘车辆四轮驱动转矩和转角精确可知的优势。同时,本文融合 RLS 和 KNN 算法建立车辆质量预估计算法,准确估计车辆质量,解决了基于模型的车辆状态估计算法所具有的对车辆质量参数准确性高度依赖和基于车辆纵向动力学的 RLS 算法在车辆转向时估计结果失真的缺点,保证了在车辆转向过程中的车辆质量状态估计准确性。并设计了 KNN 算法数据集更新策略,提高算法准确性。

4.1 分布式线控底盘车辆状态估计算法框架

本文所设计的分布式线控底盘车辆状态估计算法框架如图 4.1 所示。

首先,收集不同质量标签下分布式线控底盘车辆在特定行驶工况中四轮悬架长度和对应的车辆纵向加速度和侧向加速度建立数据集,并基于该数据集训练 KNN 分类器。在车辆实际行驶过程中通过 KNN 分类器估计车辆质量所处的范围 m_k ; 其次,基于车辆纵向动力学模型,建立基于 RLS 算法的车辆质量估计器,估计当前车辆状态对应的车辆质量 m_r 。并通过本文所建立的车辆质量融合估计算法融合估计当前状态下车辆质量 m_f ; 同时,在基于 DUPF 算法建立车辆状态估计器中,为解决基于模型的车辆状态估计器在车辆质量变化的情况下准确性降低的问题,模型质量设置为融合质量估计算法的估计结果,并在车辆稳定状态下进行更新,降低由模型误差造成的车辆状态估计结果的不准确度。

车辆状态估计器中的车轮转角值,由第3章所设计的车轮转角传感器故障诊

断算法实时诊断输出传感器测量值或车轮转角估计值,保证车辆状态估计结果的准确性。




图 4.1 分布式线控底盘车辆状态估计算法框架

4.2 车辆纵向动力学模型

如第 1 章所介绍的车辆质量估计算法的研究现状所述,基于 RLS 算法的车辆质量估计算法由于其计算简便,准确性高,收敛速度快的优势,是目前较为常用的车辆质量估计算法。为了简化基于 RLS 的车辆质量估计算法模型复杂度,提高计算速度。在车辆质量与估计算法中,建立车辆纵向动力学模型。考虑如图 4.2 所示的车辆受力图,车辆纵向动力学可以表示为如式 (4.1) 所示:

$$F_i = F_p - F_d - F_g - F_r \dots\dots\dots (4.1)$$

由于本文所研究的车辆为四轮独立驱动、独立转向的分布式线控底盘车辆。因此,假设四个轮毂电机直接驱动车轮产生驱动力矩驱动车辆行驶。驱动力可以

表示为:

$$F_p = \frac{T_p}{r} \dots\dots\dots (4.2)$$

其中, T_p 为轮毂电机驱动力矩, r 为车轮转动半径。




图 4.2 车辆纵向动力学模型示意图

式 (4.1) 中车辆行驶过程中空气阻力可由式 (4.3) 进一步计算得出:

$$F_d = \frac{1}{2} \rho C_d A v_x^2 \approx \frac{1}{2} \rho C_a v_x^2 = \frac{1}{2} \rho C_a \dot{x}^2, C_a = C_d A \dots\dots\dots (4.3)$$

式 (4.3) 中, C_a 是阻力系数。本研究中忽略风速对车辆纵向动力学模型的影响。

假设路面坡度为 γ , 路面滚动阻力系数为 C_r 。则有式 (4.1) 中坡道阻力如式 (4.4) 所示:

$$F_g = mg \sin(\gamma) \dots\dots\dots (4.4)$$

式 (4.1) 中, 滚动阻力可表示为:

$$F_r = m C_r g \cos(\gamma) \dots\dots\dots (4.5)$$

车辆实际行驶过程中, 车辆滚动阻力系数 C_r 与车速、车轮轮胎胎压和路面条件有关, 并不是一个恒定值。但在本文中, 为简化算法, 提高算法实时性, 滚动阻力系数在同一种路面行驶过程中假定为常数。

式 (4.1) 中, 车辆的惯性力与车辆及其各总成系统中旋转部件加速度相关,

则有：

$$F_i = M\ddot{x} \dots\dots\dots (4.6)$$

其中， $\ddot{x}$ 为车辆纵向加速度， M 为车辆质量和车辆各总成内转动部件转动惯量而造成的等效质量的总和。由于本文所研究的分布式线控底盘车辆由轮毂电机直接驱动车轮，因而忽略变速器、差速器等相关传动系统的转动惯量。则等效质量可以表示为：

$$M = m + I_1 \frac{1}{r^2} \dots\dots\dots (4.7)$$

其中， I_1 为车轮、制动盘等轮边总成和制动系统中旋转部件的转动惯量总和。

则将式（4.7）带入式（4.6）可得车辆行驶过程中惯性力为：

$$F_i = M\ddot{x} = \left(m + I_1 \frac{1}{r^2} \right) \ddot{x} \dots\dots\dots (4.8)$$

将式（4.2）-式（4.8）带入式（4.1）可得，车辆纵向动力学模型为：

$$\left(m + I_1 \frac{1}{r^2} \right) \ddot{x} = \frac{T_p}{r} - \frac{1}{2} \rho C_d A \dot{x}^2 - m C_r g \cos(\gamma) - mg \sin(\gamma) \dots\dots\dots (4.9)$$

式（4.9）中， $\dot{x}$ 为车辆纵向速度，本文假设分布式线控底盘车辆行驶于水平路面，即假设 $\gamma = 0$ ，因此 $\cos(\gamma) = 1$ ， $\sin(\gamma) = 0$ 。即式（4.9）可改写为：

$$\left(m + I_1 \frac{1}{r^2} \right) \ddot{x} = \frac{T_p}{r} - \frac{1}{2} \rho C_d A \dot{x}^2 - mg C_r \dots\dots\dots (4.10)$$

进一步将式（4.10）改写为：

$$m(\ddot{x} + g C_r) = \frac{T_p}{r} - \frac{1}{2} \rho C_d A \dot{x}^2 - I_1 \frac{1}{r^2} \ddot{x} \dots\dots\dots (4.11)$$

即对车辆质量可得：

$$m = \frac{\frac{T_p}{r} - \frac{1}{2} \rho C_d A \dot{x}^2 - I_1 \frac{1}{r^2} \ddot{x}}{\ddot{x} + g C_r} \dots\dots\dots (4.12)$$

4.3 KNN 与 RLS 融合车辆质量估计算法建立

由于 RLS 车辆质量估计算法基于车辆纵向动力学模型建立,主要基于车辆纵向动力学信息。当车辆在转向过程中,基于 RLS 的车辆质量估计算法的估计结果会出现失真情况。在车辆稳定状态下,车辆质量变化与车辆悬架长度有着明显的映射关系。因此,本文建立基于 KNN 算法的车辆质量范围估计器,对车辆垂向信息进行聚类分析,估计车辆质量信息,与 RLS 算法融合估计车辆质量,提高车辆质量估计算法精度,从而避免由于车辆质量参数不准而影响车辆状态估计算法精度。

4.3.1 KNN 算法建立

KNN 分类算法是最基本、最简单的分类算法之一,在对数据分布了解较少或对分类系统无先验知识的情况下具有良好的分类性能^[109]。

本文选择基于分布式线控底盘车辆四轮悬架长度和车身纵向、侧向加速度数据建立数据集,车辆质量为标签对 KNN 分类器进行训练。

KNN 算法的基本原理为:

$$S=(X_1,Y_1),(X_2,Y_2),\cdots,(X_i,Y_i),\cdots,(X_N,Y_N)\cdots\cdots\cdots (4.13)$$

在本研究中, $X_i=[s_{lf},s_{lr},s_{rf},s_{rr},a_x,a_y]^T$, $Y_i=[m_i]$, s_{ij} 为悬架当前长度,(其中 i 为 l,r , 代表左轮和右轮; j 为 f,r , 代表前轮和后轮)。 X_i 代表第 i 组车辆状态信息, m_i 代表第 i 组车辆信息对应的车辆质量。通过预先收集车辆在特定行驶条件下的车辆状态信息和车辆质量,对 KNN 分类器进行训练。

在建立基于 KNN 分类器的车辆质量估计算法过程中,采集车辆行驶状态参数 $X_i=[s_{lf},s_{lr},s_{rf},s_{rr},a_x,a_y]^T$ 。通过式(4.14)所示的欧几里得距离公式计算需分类数据点 X_j 与 X_i 间距离最近的 K 个 X_i 中的样本点,其中比例最大的点所对应的 Y_i 值即为该车辆状态对应的车辆质量估计值。

$$D_{st}=\sqrt[p]{\sum_{s=1}^n|X_{is}-X_{js}|^p}\cdots\cdots\cdots (4.14)$$

其中 p 为对应的状态维数，在本文 $p=6$ 。

4.3.2 RLS 算法建立

(一) RLS 算法原理及简介

最小二乘法由 Gauss 首先提出，发展至今成为了一种应用广泛的系统辨识方法，其在处理序列估计问题中无序对输入变量序列的相关统计学特性进行假设^[110]。RLS 估计算法通过最小二乘估计结果推导出递归最小二乘的递归公式，本质思想是减小估计值与真实值间误差的平方和，并采用递归的形式进行更新^[111]。相较于 LMS 算法，RLS 算法具有更快的收敛速度和跟踪性能。

(二) RLS 质量估计算法建立

分布式线控底盘车辆传感器具有噪声等测量误差，同时由于车辆纵向动力学模型建立时对模型进行了部分简化产生了模型误差，直接基于式 (4.12) 对分布式线控底盘车辆进行计算相对真实值会产生较大偏差。因此，本文基于 RLS 算法建立车辆质量估计器。

将式 (4.12) 所表示的分布式线控底盘车辆质量方程改写为式 (4.15) 中离散时间方程形式可以有：

$$\phi_k^T \theta_k = y_k + \varepsilon_k \cdots \cdots \cdots (4.15)$$

其中，在第 k 步时：

$$\theta_k = m_k \cdots \cdots \cdots (4.16)$$

$$\phi_k = \ddot{x}_k + gC_r \cdots \cdots \cdots (4.17)$$

$$y_k = \frac{T_p}{r} - \frac{1}{2} \rho C_d A \dot{x}_k^2 - I_1 \frac{1}{r^2} \ddot{x}_k \cdots \cdots \cdots (4.18)$$

式 (4.18) 中 $\dot{x}_k$, $\ddot{x}_k$ 为第 k 步中车辆纵向速度和纵向加速度。基于 RLS 算法的车辆质量估计算法的主要步骤可以表示为：

第 1 步：基于上一步车辆质量估计值计算当前估计误差 ε_k ：

$$\varepsilon_k = y_k - \phi_k^T \theta_{k-1} \cdots \cdots \cdots (4.19)$$

第2步：更新误差协方差矩阵：

$$P_k = \frac{1}{\lambda} \left(P_{k-1} - \frac{P_{k-1} \phi_k \phi_k^T P_{k-1}}{\lambda + \phi_k^T P_{k-1} \phi_k} \right) \dots\dots\dots (4.20)$$

其中，遗忘因子 $0 < \lambda \leq 1$ ， λ 的值越接近于 1，表示基于 RLS 算法建立的车辆质量估计算法对最近采样的车辆信息样本越不敏感，车辆质量估计结果波动越小。在本文中 $\lambda = 0.99$ 。

第3步：更新增益：

$$L_k = P_k \phi_k \dots\dots\dots (4.21)$$

第4步：更新车辆质量估计值：

$$\theta_k = \theta_{k-1} + L_k \varepsilon_k \dots\dots\dots (4.22)$$

后续计算重复第1步至第4步，实现对车辆质量的估计与更新。

4.3.3 车辆质量融合策略

由于本文所建立 RLS 算法基于车辆纵向动力学模型，当车辆侧向加速度较大时，车辆质量估计结果存在较大误差。另一方面，基于 KNN 的车辆质量估计算法只能进行聚类分析获取车辆质量范围，获得精确质量估计结果的数据成本过高，且会降低算法精度。因此，本文融合 KNN 与 RLS 算法，从而提高在车辆侧向加速度增加情况下的车辆质量估计结果的准确性，并降低 KNN 算法训练成本。

（一）车辆行驶稳定性判断

基于 RLS 的车辆质量估计结果的准确性与车辆侧向加速度具有强相关性，同时车辆侧向加速度可以通过传感器直接测量或通过车辆状态估计算法进行较精确的估计。因此，为提高车辆质量估计算法的准确性，本文基于车辆纵向加速度和侧向加速度信息划分车辆行驶稳定区域，建立车辆质量融合估计策略。本文选定如式（4.23）所示的车辆状态为稳定状态，其中 μ 为路面附着系数。稳定状态可表示为如图 4.3 所示：

$$a \leq \sqrt{\frac{a_x^2}{(0.4\mu g)^2} + \frac{a_y^2}{(0.1\mu g)^2}} \dots\dots\dots (4.23)$$




图 4.3 车辆稳定状态范围示意图

如图 4.3 所示，当基于式（4.23）所计算的车辆稳定状态判断的结果 a 处于阴影部分时，代表车辆行驶状态稳定；反之，认为车辆在该行驶状态下不稳定。

（二）KNN 与 RLS 质量估计算法融合策略

本文所建立的基于 KNN 的车辆质量估计算法基于四轮悬架长度的车辆垂向信息和车身加速度信息，基于 RLS 的车辆质量估计算法基于车辆纵向动力学信息。两种算法考虑不同方向上车辆的动态性能，估计车辆质量，提高质量估计结果准确性。本文融合基于 KNN 与 RLS 质量估计算法的结果，KNN 通过预学习车辆质量信息数据集，每 40kg 建立一组数据。则 RLS 估计值与 KNN 估计值融合策略为：

（1）当车辆状态稳定，RLS 估计值在 KNN 估计范围内：

$$m_f = m_r \dots\dots\dots (4.24)$$

当前状态可以视为 RLS 算法和 KNN 算法均估计准确，即输出车辆质量融合估计值为基于 RLS 算法的车辆质量估计值。

（2）当车辆状态稳定，RLS 估计值不在 KNN 估计范围内：

$$m_f = m_r \dots\dots\dots (4.25)$$

当前状态视为 RLS 算法估计准确，KNN 算法估计不准确。因此，车辆质量

融合估计值为基于 RLS 算法的车辆质量估计值。收集当前车辆状态，更新 KNN 数据集，在后续对 KNN 算法进行更新，提高算法准确性。

(3) 当车辆状态不稳定，RLS 估计值在 KNN 估计范围内：

$$m_f = m_r \dots\dots\dots (4.26)$$

当前状态视为 RLS 算法和 KNN 算法均估计准确，因此输出车辆质量为 RLS 算法质量估计值。

(4) 当车辆状态不稳定，RLS 估计值不在 KNN 估计范围内：

$$m_f = \frac{m_{k,max} + m_{k,min}}{2} \dots\dots\dots (4.27)$$

当前状态视为 KNN 算法估计准确，RLS 算法估计不准确。因此，车辆质量融合估计值为 KNN 算法质量估计范围中位数。其中 $m_{k,max}$ 为 KNN 估计质量范围的上限值， $m_{k,min}$ 为 KNN 估计质量范围的下限值， m_k 代表 KNN 估计质量范围中位数。

车辆质量估计融合策略如图 4.4 所示：




图 4.4 车辆质量融合估计策略

（三） KNN 算法数据集更新策略

基于 KNN 算法实现车辆质量估计需要预先建立数据集，数据集的准确性和对车辆行驶工况全面性对质量估计结果的准确性有着重要影响。但在对基于 KNN 的车辆质量估计算法进行训练时，考虑训练时间成本和数据成本，算法数据集无法全面涵盖每一辆分布式线控底盘车辆全生命周期下的车辆行驶状态。为提高算法在车辆实际行驶过程中的准确性，本文建立了一种收集车辆实际行驶过程中车辆状态和车辆信息更新 KNN 算法数据集和模型的策略。具体更新策略如表 4.1 所示：

当车辆数据分类为 4 时，记录当前状态下分布式线控底盘车辆四轮悬架长度和车身纵向和侧向加速度信息，存储至 KNN 更新数据集中。车辆质量标签设置为当前 KNN 算法质量范围的上限值与下限值的平均值。并更新基于 KNN 的车辆质量估计算法的数据集和模型。

表 4.1 车辆质量融合估计算法数据分类

KNN 与 RLS 车辆质量估计值间关系	车辆状态	数据分类
$RLSmass \in KNNmass$	不稳定	1
$RLSmass \notin KNNmass$	不稳定	2
$RLSmass \in KNNmass$	稳定	3
$RLSmass \notin KNNmass$	稳定	4（更新数据集）

表 4.1 中 $RLSmass$ 代表基于 RLS 算法估计的车辆质量值， $KNNmass$ 代表基于 KNN 算法的车辆质量估计范围。车辆状态由式（4.23）计算判断。

4.4 基于 DUPF 的分布式线控底盘车辆状态估计算法建立

目前，针对分布式线控底盘车辆的状态估计研究中，双滤波器算法架构一方面可以充分利用分布式线控底盘车辆四轮转角和驱动力矩可知的优势。另一方面，两个车辆状态观测器互相传递车辆状态参数估计结果，降低模型不确定度对车辆状态估计算法的估计精度的影响，提高算法鲁棒性。本文所采用的 DUPF 算法架构如图 4.5 所示。




图 4.5 DUPF 算法框架图

DUPF 算法框架主要由两个 UPF 算法构成，两个 UPF 算法在车辆状态估计过程中分别独立、同步运行。在本文中，基于 DUPF 算法的车辆状态估计器中两个 UPF 算法互相传递和校正车辆状态信息，提高车辆状态估计结果的准确性。同时，UPF 算法相较于其它算法在处理分布式线控底盘车辆这种高阶非线性系统的车辆状态估计问题时具有良好的性能。本文所建立 DUPF 算法中的 UPF 观测器算法计算过程主要由粒子采样、UT 变换、预测更新和计算权重采样组成。

4.4.1 UPF 算法建立

本文所建立的基于 DUPF 算法的车辆状态估计器主要考虑车辆在水平面上的运动。根据第 2 章所建立的分布式线控底盘车辆模型在水平面上纵向、侧向和横摆方向上的车辆状态信息，建立 DUPF 观测器的状态变量为：

$$x_s = [V_x \ V_y \ \dot{\varphi} \ a_x \ a_y \ \ddot{\varphi}]^T \cdots \cdots \cdots (4.28)$$

虽然由于分布式线控底盘车辆行驶过程中具有车轮驱动力矩精确可知的优

势，但直接通过驱动力矩解算轮胎纵向力和侧向力会由于轮胎滚动力矩等影响，产生误差。因而，本文对轮胎纵向力和侧向力进行估计，同时与车辆状态观测器交互估计结果，提高车辆状态估计精度。车辆轮胎力参数向量为：

$$x_p = [F_{xlf} \quad F_{xrf} \quad F_{xlr} \quad F_{xrr} \quad F_{ylf} \quad F_{yrf} \quad F_{ylr} \quad F_{yrr}]^T \dots\dots\dots (4.29)$$

由于分布式线控底盘车辆每个车轮的转角和驱动力矩均为独立控制的，因此建立 DUPF 算法的输入矢量为：

$$u = [T_{wij} \quad \delta_{ij} \quad \omega_{ij} \quad \dot{\omega}_{ij}]^T \dots\dots\dots (4.30)$$

观测向量为：

$$y = [\dot{\phi} \quad a_x \quad a_y]^T \dots\dots\dots (4.31)$$

则建立系统离散方程为：

$$x_s(k+1) = f_s[x_s(k), x_p(k), u(k)] + Q_s(k) \dots\dots\dots (4.32)$$

$$y_s(k) = H_s x_s(k) + v(k) \dots\dots\dots (4.33)$$

$$H_s = \begin{bmatrix} 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \end{bmatrix} \dots\dots\dots (4.34)$$

$$\begin{cases} x_p(k+1) = f_p[x_p(k), u(k)] + Q_p(k) \\ y_p(k) = h_p[x_p(k), u(k)] + R(k) \end{cases} \dots\dots\dots (4.35)$$

其中 Q_s ， Q_p 和 R 为过程噪声和测量噪声，均为对角矩阵。

$$\begin{cases} V_x(k+1) = V_x(k) + \Delta T a_x(k) \\ V_y(k+1) = V_y(k) + \Delta T a_y(k) \\ \dot{\phi}(k+1) = \dot{\phi}(k) + \Delta T \ddot{\phi}(k) \end{cases} \dots\dots\dots (4.36)$$

从先验分布 $p_s(x_{s0})$ ， $p_p(x_{p0})$ 中提取 N 个粒子 $\{x_{s0}^{(i)}\}_{i=1}^N$ ， $\{x_{p0}^{(i)}\}_{i=1}^N$ 。得到 DUPF 车辆状态估计算法的状态向量的初始值 $x_{s0}^{(i)}$ ， $x_{p0}^{(i)}$ 以及初始协方差 $P_{s0}^{(i)}$ ， $P_{p0}^{(i)}$ 。并相应的可以表示为：

$$\bar{x}_s^{(i)}(0) = E[x_s^{(i)}(0)] \dots\dots\dots (4.37)$$

$$P_s^{(i)}(0) = E \left[\left(x_s^{(i)}(0) - \bar{x}_s^{(i)}(0) \right) \left(x_s^{(i)}(0) - \bar{x}_s^{(i)}(0) \right)^T \right] \dots\dots\dots (4.38)$$

4.4.2 计算 Sigma 点集

Sigma 点集的计算方法可以分为单边采样法和对称采样法, 本文基于对称采样法建立 Sigma 点集。通过式 (4.39) 计算 Sigma 点集:

$$\begin{cases} \chi_s^{(i)a}(k-1) = \begin{bmatrix} \bar{x}_s^{(i)a}(k-1) \\ \bar{x}_s^{(i)a}(k-1) \pm \sqrt{(n_a + \lambda_s) P_s^{(i)a}(k-1)} \end{bmatrix} \\ \chi_p^{(i)a}(k-1) = \begin{bmatrix} \bar{x}_p^{(i)a}(k-1) \\ \bar{x}_p^{(i)a}(k-1) \pm \sqrt{(n_p + \lambda_p) P_p^{(i)a}(k-1)} \end{bmatrix} \end{cases} \dots\dots\dots (4.39)$$

本文选取二次调整系数 $\kappa=0$, 从而保证方差矩阵半正定性; 参数 $\alpha=0.001$ 其意义为调节各粒子到粒子均值的分布距离; 参数 $\beta=2$ 代表 UPF 算法对高斯噪声的适用类型。

$$\lambda = \alpha^2(n + \kappa) - n \dots\dots\dots (4.40)$$

则基于式 (4.41) 和式 (4.42) 建立 UPF 算法中各 Sigma 点权重值为:

$$\begin{cases} W_0^{(m)} = \lambda / (L + \lambda) \\ W_i^{(m)} = \lambda / 2(L + \lambda), i = 1, 2, \dots, 2L \end{cases} \dots\dots\dots (4.41)$$

$$\begin{cases} W_0^{(c)} = \lambda / (L + \lambda) + (1 - \alpha^2 + \beta) \\ W_i^{(c)} = \lambda / 2(L + \lambda), i = 1, 2, \dots, 2L \end{cases} \dots\dots\dots (4.42)$$

更新 Sigma 点集的值后, $x_s^{(i)x}$, $x_p^{(i)x}$ 可表示为:

$$x_s^{(i)x}(k|k-1) = f_s \left[x_s^{(i)x}(k-1), \hat{x}_p^{(i)}(k-1), u(k-1) \right] \dots\dots\dots (4.43)$$

$$x_p^{(i)x}(k|k-1) = f_h \left[\hat{x}_s^{(i)}(k-1), u(k-1) \right] \dots\dots\dots (4.44)$$

则有, 通过加权计算得到状态向量 x_s , x_p 的预测值为:

$$\bar{x}_s^{(i)}(k|k-1) = \sum_{j=0}^{2n_s} W_{s,j}^{(m)} x_{s,j}^{(i)x}(k|k-1) \dots\dots\dots (4.45)$$

$$\bar{x}_p^{(i)}(k|k-1) = \sum_{j=0}^{2n_p} W_{p,j}^{(m)} x_{p,j}^{(i)x}(k|k-1) \dots\dots\dots (4.46)$$

车辆系统状态预测值和对应的协方差矩阵预测值为:

$$\bar{y}_s^{(i)}(k|k-1) = \sum_{j=0}^{2n_s} W_{s,j}^{(m)} y_s^{(i)x}(k|k-1) \dots \dots \dots (4.47)$$

$$P_{s(x,x)}^{(i)}(k|k-1) = \sum_{j=0}^{n_s} W_{s,j}^{(c)} \left[x_{s,j}^{(i)}(k|k-1) - \bar{x}_s^{(i)}(k|k-1) \right] \left[x_{s,j}^{(i)}(k|k-1) - \bar{x}_s^{(i)}(k|k-1) \right]^T \dots \dots (4.48)$$

更新车辆系统状态预测值和协方差矩阵预测值后的 UPF 算法的增益矩阵、后验估计和后验方差为:

$$K_s(k) = P_{s(x,y)}(k) \left[P_{s(\bar{y},\bar{y})}(k) \right]^{-1} \dots \dots \dots (4.49)$$

$$\bar{x}_s^{(i)}(k) = \bar{x}_s^{(i)}(k|k-1) + K_s(k) \left[y_s(k) - \bar{y}_s^{(i)}(k|k-1) \right] \dots \dots \dots (4.50)$$

$$\hat{P}_s^{(i)}(k) = P_{s(x,x)}^{(i)}(k|k-1) - K_s(k) P_{s(\bar{y},\bar{y})}(k) \left[K_s(k) \right]^T \dots \dots \dots (4.51)$$

用同样的方法可以得到 $\hat{x}_p^{(i)}(k)$, $\hat{P}_p^{(i)}(k)$ 。

对于 UPF 算法中的每一个粒子的后验估计可以表示为:

$$\hat{x}_s^{(i)}(k) \sim q\left(\hat{x}_s^{(i)}(k) \middle| x_s^{(i)}(0:k-1), y_s(1:k)\right) = N\left(\bar{x}_s^{(i)}(k), \hat{P}_s^{(i)}(k)\right) \dots (4.52)$$

$$\hat{x}_s^{(i)}(0:k) \triangleq \left(x_s^{(i)}(0:k-1), \hat{x}_s^{(i)}(k)\right) \dots \dots \dots (4.53)$$

则, 每个粒子的权重为:

$$\omega_s^{(i)}(k) \propto \frac{p\left(y_s(k) \middle| \hat{x}_s^{(i)}(k)\right) p\left(\hat{x}_s^{(i)}(k) \middle| x_s^{(i)}(k-1)\right)}{q\left(\hat{x}_s^{(i)}(k) \middle| x_s^{(i)}(0:k-1), y_s(1:k)\right)} \dots \dots \dots (4.54)$$

最后, 需要基于式 (4.54) 对 UPF 算法中所有粒子对应的权重值进行标准化和归一化。

$$\tilde{\omega}_s^{(i)}(k) = \omega_s^{(i)}(k) / \sum_{j=1}^N \omega_s^{(j)}(k) \dots \dots \dots (4.55)$$

4.4.3 重采样算法

UPF 算法具有良好的处理非线性系统状态估计问题的能力, 但经过多次迭代, UPF 算法中粒子权重会逐渐变小, 最后趋向于 0。因此, 需要通过重采样来复制

车辆动态系统中质量较高的粒子,并消除质量较低的粒子。目前应用较为广泛的粒子滤波算法的重采样方法包括随机重采样法、多项式重采样法和残差重采样法等。本文采用残差重采样法。其具体计算过程可以表示为:重采样后记录每个粒子的权重为:

$$\omega_s^{(i)}(k) = 1/N \cdots \cdots \cdots (4.56)$$

(1) 由多项式算法 $Multi(N - R; \bar{\omega}^2, \dots, \bar{\omega}^N)$ 计算得到 $\{\bar{N}^i\}_{1 \leq i \leq N}$ 。

其中:

$$R = \sum_{i=1}^N [N\omega^i] \cdots \cdots \cdots (4.57)$$

$$\bar{\omega}^i = \frac{N\omega^i - [N\omega^i]}{N - R}, i = 1, \dots, N \cdots \cdots \cdots (4.58)$$

$[N\omega^i]$ 代表对 $N\omega^i$ 进行取整计算。

(2) 令 $N^i = [N\omega^i] + \bar{N}^i$ 。

(3) 基于式 (4.56) 重新分配各粒子权重值, 即:

$$\bar{\omega}^i = 1/N \cdots \cdots \cdots (4.59)$$

重采样更新输出状态向量为:

$$\hat{x}_s^{(i)}(k) = \sum_{i=1}^N \omega_s^{(i)}(k) \bar{x}_s^{(i)}(k) \cdots \cdots \cdots (4.60)$$

$$\hat{P}_s(k) = \sum_{i=1}^N \omega_s^{(i)}(k) [x_s^{(i)}(k) - \bar{x}_s^{(i)}(k)] [x_s^{(i)}(k) - \bar{x}_s^{(i)}(k)]^T \cdots \cdots \cdots (4.61)$$

用同样的方法可以得到 $\hat{x}_p^{(i)}(k)$, $\hat{P}_p(k)$ 重采样后的更新值。

4.5 车辆状态估计算法仿真实验验证

为验证本章所提出的分布式线控底盘车辆状态估计算法的准确性, 本节采用 CarSim 与 MATLAB/Simulink 建立离线联合仿真平台对算法进行验证。针对分布式线控底盘车辆结构上的特征, 对 CarSim 中车辆模型进行修改:

(1) 由于本文所建立的分布式线控底盘车辆由轮毂电机直接驱动车轮, 则模型中取消发动机和传动系统。

(2) 取消 CarSim 模型中的转向传动系统，四个车轮转角由设定的仿真工况各自独立控制。

同时，由于 CarSim 输出的车辆状态参数均为真值，为模拟车辆实际行驶过程中传感器自身噪声，在 CarSim 信号输出端对各车轮驱动转矩、车轮转速、车轮转动角加速度、车轮转角、车身纵向加速度、车身侧向加速度和横摆角速度依据目前市面传感器噪声均值，施加高斯噪声信号。各车辆状态参数噪声方差水平如表 4.2 所示：

表 4.2 CarSim 输出端施加噪声方差水平


车辆状态参数	方差
纵向加速度	10^{-3}
侧向加速度	10^{-3}
横摆角速度	10^{-5}
驱动力矩	1
轮速	10^{-3}
车轮转动加速度	10^{-3}
车轮转角	5×10^{-7}

4.5.1 KNN 数据集收集与分析

本文所提出的基于 KNN 的车辆质量估计算法需要预先基于车辆行驶过程中的车辆状态信息 $X_i = [s_{lf}, s_{lr}, s_{rf}, s_{rr}, a_x, a_y]^T$ 和当前车辆质量 m_i 建立数据集进行预训练。KNN 分类器在实际应用中的估计精度与训练算法时数据集所包含的车辆行驶工况数据的全面性有关。为保证基于 KNN 的车辆质量估计算法的准确性，本文通过 CarSim 和 MATLAB/Simulink 软件收集每 40kg 一个区间的 1570kg-2290kg 内的车辆悬架长度与车身纵向加速度和侧向加速度。数据采集工况中驾驶员模型为 0.7/0.3 Max Ax/Ay，即在路面附着系数为 0.85 的条件下，该驾驶员模型驾驶的车辆，车辆最大纵向加速度为 0.595g 最大侧向加速度为 0.255g。


同时，为进一步保证数据集包含车辆行驶工况，提高车辆质量估计准确性。

在本文所建立的 KNN 数据集中增加 40km/h, 60km/h, 80km/h, 100km/h 下的双移线行驶工况的车辆状态信息。单一质量范围下的车辆行驶轨迹信息和部分车辆状态信息如图 4.6 所示。




(a) 环形道路行驶轨迹


(b) 双移线工况行驶轨迹



(c) 1750kg-1790kg 质量范围内悬架位移图



(d) 车辆纵向加速度



(e) 车辆侧向加速度

图 4.6 KNN 数据集中车辆状态信息

收集各质量范围内车辆状态参数时，将同一质量范围内一圈环形道路行驶中车辆状态参数与四种车速下的车辆参数拼接至同一图线中显示。如图 4.6 (c) 所示，车辆四轮悬架长度在 19mm-62mm 之间变化。图 4.6 (d) 中车辆加速时最大纵向加速度为 0.5g。图 4.6 (e) 中车辆转向过程中最大侧向加速度为 0.76g。数据集涵盖了大部分车辆行驶过程中车辆状态参数。KNN 算法数据集的具体信息如表 4.3 所示：

如表 4.3 所示，本文共收集 4011773 组数据，相较于其它机器学习方法，数据集样本较少，降低了对训练算力和算法训练时间成本的要求。

表 4.3 KNN 数据集信息

质量标签（中位数）	数据时间长度	数据数量
1570 kg	3min30s470ms	210470
1610 kg	3min30s266ms	210266
1650 kg	3min30s897ms	210897
1690 kg	3min30s346ms	210346
1730 kg	3min31s230ms	211230
1770 kg	3min30s917ms	210917
1810 kg	3min 30s 909ms	210909
1850 kg	3min 31s 116ms	211116
1890 kg	3min 30s 167ms	210167
1930 kg	3min 31s 497ms	211497
1970 kg	3min 31s 179ms	211179
2010 kg	3min 31s 475ms	211475
2050 kg	3min 30s 669ms	210669
2090 kg	3min 31s 465ms	211465
2130 kg	3min 31s 841ms	211841
2170 kg	3min 31s 534ms	211534
2210 kg	3min 31s 867ms	211867
2250 kg	3min 31s 251ms	211251
2290 kg	3min 32s 677ms	212677
数据总量	66min 51s 773ms	4011773

将基于表4.3中数据所建立的KNN算法数据集通过权重KNN算法进行训练，训练后算法准确率如图4.8所示，KNN算法训练总时长小于5分钟。




图 4.7 KNN 训练后准确率

由图 4.7 可知，横轴为该车辆状态数据所处的车辆质量范围，本图中以中位数形式表示，纵轴为车辆质量范围估计结果，同样采用中位数形式表示。本文所建立的 KNN 算法在数据集的各质量范围内训练准确度均大于 99.9%，可以用于本章所建立的车辆质量融合估计算法。

4.5.2 车辆状态估计算法验证

为验证本章所建立的分布式线控底盘车辆状态估计算法在车辆在行驶过程中的准确性和稳定性，本节设计了如图 4.8 所示的仿真实验工况进行验证，避免了与 KNN 数据集中数据重合，影响算法准确性验证结果。该工况下车辆初始速度为 50km/h，路面附着系数为 0.8，





图 4.8 仿真实验工况车辆行驶轨迹图


在如图 4.8 所示的车辆行驶轨迹中,当车辆行驶至横向位置 175m 时进入双移线工况转向过程;在第 175m-280m 之间进行最远纵向位移 3.5m 的类换道行驶工况;在第 280m 后,车辆保持直线行驶,直至仿真实验结束。仿真实验行驶轨迹与建立数据集时收集车辆数据轨迹重合度低,从而起到算法准确性验证效果。

(一) 分布式线控底盘车辆质量融合估计算法验证


仿真实验工况中,基于 KNN 算法的车辆质量估计范围和分布式线控底盘车辆质量融合估计算法估计结果如图 4.9 所示:



(a) KNN 算法质量估计结果



(b) RLS 算法质量估计结果



(c) 融合质量估计结果

图 4.9 分布式线控底盘车辆质量融合估计结果


为避免车辆质量值于 KNN 数据集重合，建立车辆质量真实值为 1980kg，处于 KNN 数据集中标签为 1950kg-1990kg 范围内，且不等于该标签质量范围的中位数，避免仿真实验数据与 KNN 数据集重合对算法准确性仿真验证的影响。

如图 4.9 (a) 所示为基于 KNN 算法的车辆质量估计结果，在该工况下，基于 KNN 的车辆质量估计算法精度较高；图 4.9 (b) 和图 4.9 (c) 为基于 RLS 的车辆质量估计结果、基于 KNN 的车辆范围估计结果、融合质量估计结果和车辆质量真实值的对比。在第 0-2 秒间，车辆行驶稳定，但由于 RLS 算法缺乏车辆质量先验信息，RLS 算法车辆质量估计初值与车辆质量真实值不同，但 RLS 算

法估计的车辆质量结果快速收敛至车辆质量真实值附近；在第 2-9 秒内，车辆保持直线行驶，基于 RLS 的车辆质量估计结果与车辆质量真实值保持一致，车辆质量融合估计值为基于 RLS 的车辆质量估计值；在第 9-17 秒内，车辆进入仿真实验工况的转向过程，基于 RLS 的车辆质量估计结果出现失真。但由于本文设计了考虑车辆稳定性判断的车辆质量融合估计策略，当车辆状态不稳定且基于 RLS 的车辆质量估计值与基于 KNN 的车辆质量范围估计器的估计结果不一致时，车辆质量融合估计策略输出基于 KNN 算法的车辆质量估计范围的中位数。在车辆转向过程中，基于 RLS 算法的车辆质量估计结果与车辆质量真实值最大误差达到 58.63%，但基于车辆质量融合估计策略的将车辆质量估计的最大误差降低至 9.28%，显著减低基于纵向动力学模型建立的 RLS 算法在车辆转向过程中的估计误差；在第 17-36 秒之间，车辆从转向过程回归至直线行驶过程，基于 RLS 估计的车辆质量估计结果快速收敛至 KNN 估计车辆质量范围内，融合质量估计结果与车辆质量真实值间误差较小。

（二）车辆状态估计算法验证

将图 4.9（c）中基于 RLS 和 KNN 融合估计车辆质量信息作为 DUPF 车辆状态估计器中车辆模型的车辆质量。则基于 DUPF 算法估计得到车辆状态估计结果如图 4.10 所示：






图 4.10 车辆状态估计结果

在图 4.10 中, 基于 DUF 算法的车辆状态估计算法中车辆质量值为车辆质量融合估计结果; 在图 4.10 (a) 和图 4.10 (c) 中, 车辆纵向速度和纵向加速度相对与真实值存在一定误差, 但是其变化趋势和估计范围均在噪声水平以内, 且对传感器噪声具有明显的减弱, 结果较为准确; 而图 4.10 (b)、图 4.10 (d) 和图 4.10 (e) 中 DUF 算法估计的车辆侧向速度、侧向加速度和横摆角速度值较为准确, 与真实值之间误差较小, 且相对与传感器噪声值有明显的降噪效果。

为进一步量化表示车辆状态估计算法的准确性和实时性, 本文引入真绝对误差值 (True Absolute Error, TASE) 作为参考指标^[112]。TASE 值可用于表示和比较

每步蒙特卡罗计算时,所建立的车辆状态估计算法的估计性能。TASE 值的原理是在单位时间内,计算估计值与真值间差值的平方的均值。TASE 值越小代表算法估计值与真值之间误差越小,同时算法实时性也越好。TASE 值的计算方式如式(4.62)所示:

$$TASE = \frac{1}{T} \sum_{k=1}^T (x_k^s - \hat{x}_k^s)^2, \quad s = 1, \dots, M \quad (4.62)$$

其中, x_k^s 、 $\hat{x}_k^s$ 分别为第 s 次蒙特卡罗计算中的参考向量和估计向量。在本研究中即对应为车辆状态真实值和车辆状态估计值。在本文中采样周期为 0.001 秒,即 T 取该仿真工况下样本总数。则有仿真实验工况下各个车辆状态参数的 TASE 值如表 4.4 所示:

表 4.4 DUPF 算法 TASE 值

车辆状态参数	TASE 值
纵向加速度	1.8548×10^{-4}
侧向加速度	7.77266×10^{-5}
纵向速度	2.7804×10^{-5}
侧向速度	3.77327×10^{-6}
横摆角速度	1.4058×10^{-4}

如表 4.4 所示,与图 4.10 中仿真结果曲线一致,车辆纵向加速度、侧向加速度、纵向加速度、侧向加速度和横摆角速度的 TASE 值较小。在仿真实验工况整体数据中, DUPF 算法估计值与传感器实际测量值最大误差小于 0.5%。同时,由于基于模型的车辆状态估计的准确性与车辆质量信息具有强相关性,在仿真实验工况的变道过程中,车辆质量融合估计结果发生波动,而基于 DUPF 的车辆状态估计值与真实值之间误差较小。证明本文所建立的车辆质量融合估计算法和基于 DUPF 的车辆状态估计算法具有良好的实时性、准确性和鲁棒性。

4.6 本章小结

本章在第 2 章建立的分布式线控底盘车辆模型的基础上,主要研究了分布式线控底盘车辆状态估计算法。首先,为解决基于模型的车辆状态算法中质量参数

变化对车辆状态算法估计算法精度的影响，建立了融合递归最小二乘算法和 K-最邻近算法的车辆质量预估计器。其中，递归最小二乘算法基于车辆纵向动力学模型建立，K-最邻近算法数据集基于车辆悬架和车身加速度数据；其次，建立了基于车辆行驶稳定性判断的车辆质量融合估计策略，结合递归最小二乘算法估计值和 K-最邻近算法估计质量范围，融合估计车辆质量。并建立数据集更新策略，实现车辆行驶过程中收集关键数据实现对 K-最邻近算法数据集的更新，提高算法准确性；然后，建立了基于 DUPF 算法的车辆状态估计器，车辆参数中车辆质量由融合递归最小二乘算法和 K-最邻近算法的车辆质量预估计器实时估计，实现对车辆纵向速度、侧向速度、纵向加速度、侧向加速度和横摆角速度的估计；最后，为验证算法准确性，基于 CarSim 和 MATLAB/Simulink 搭建联合仿真平台，验证算法准确性和有效性，并引入真绝对误差值作为参考指标。通过仿真实验证明算法准确性和实时性较好。

第5章 驾驶模拟器仿真实验验证

为验证第3章所建立的分布式线控底盘车辆车轮转角传感器故障诊断算法和第4章所建立的分布式线控底盘车辆状态估计算法的准确性和有效性。本章基于实验室现有驾驶模拟器设备，进行仿真实验。

5.1 驾驶模拟器仿真实验设备

本文基于实验室现有转向试验台，搭建驾驶模拟器硬件环境架构如图5.1所示。驾驶模拟器试验台主要包括：PC、显示器、12V 蓄电池方向盘和踏板组件。通过方向盘和踏板组件生成模拟信号，其它车辆子系统由 CarSim RT 实时模拟。驾驶员通过方向盘和踏板实现对仿真车辆的转向、加速和制动进行控制。分布式线控底盘车辆传感器故障诊断算法、车辆质量估计算法和基于 DUPF 算法的车辆状态估计器在 MATLAB/Simulink 中搭建，并通过自动代码编译为在 NI PXI 工控机中运行的代码，从而满足驾驶模拟器实验要求。




图 5.1 驾驶模拟器硬件环境图

5.1.1 NI PXI 工控机

本实验台采用的 PXI e-1071 型工控机是美国国家仪器有限公司 (National Instruments, NI) 的模块化自动测试设备, 具有四个 PXI 插槽和最高 3Gb/s 的高带宽背板。在本实验中, CarSim RT 车辆模型在运行频率为 2.6GHz 的 Intel core i3 双核嵌入式控制器中实时运行。

工控机中 PXI 模块为 PXI-8512。PXI-8512 具有一个高速 CAN 通讯端口, 传输 CAN 报文并与各硬件设备实时传输数据, 实现信号收发和执行器控制。

5.1.2 转向和踏板总成

转向和踏板总成是由国内某供应商处采购, 安装至试验台架。其主要结构包括: 方向盘、减速机构、转向轴、油门及制动踏板和 ECU 控制器。转向、踏板总成由 12V 蓄电池供电。ECU 控制器基于标准帧 CAN 通讯, 报文周期 10ms, 通讯速率 500kb/s。

5.2 驾驶模拟器实验算法验证

基于 5.1 节中介绍的驾驶模拟器实验硬件环境, 搭建的分布式线控底盘车辆驾驶模拟器如图 5.2 所示。并在试验台验证传感器故障诊断与车辆状态估计算法。

为验证本文所提出的传感器故障诊断与车辆状态估计算法的准确性, 本节基于实验室现有驾驶模拟器硬件设计传感器正常情况和传感器故障情况下车辆状态估计算法仿真实验。其中, 传感器正常情况下, 车轮转角值由 CarSim 模拟传感器测量值获取; 传感器故障情况下, 通过 MATLAB/Simulink 向 CarSim 输出的模拟车轮转角传感器值注入故障信号。当故障诊断算法识别车轮转角传感器故障后, 向基于 DUF 的车辆状态估计算法输出基于 EKF 算法的车轮转角估计值替代车轮转角传感器测量值, 保证车辆状态估计结果的准确性。驾驶模拟器仿真实验中, 车辆速度由驾驶员自行控制, 驾驶员操控方向盘在车辆行驶任意时刻进行接近双移线工况行驶轨迹的驾驶动作。



图 5.2 驾驶模拟器仿真实验硬件

5.2.1 传感器正常情况下车辆状态估计实验

本节验证传感器正常情况下，车辆质量融合估计算法和车辆状态估计算法的准确性与实时性。同时，基于驾驶模拟器实验中收集的车辆状态数据，验证车辆质量融合估计算法数据集更新策略有效性。

（一）车辆质量融合估计结果

在传感器正常状态下，本文所设计的车轮转角故障诊断算法输出由车轮转角传感器直接测量值。驾驶模拟器仿真实验中车辆模型结构参数与第2章中 CarSim 车辆模型设置相同，方向盘转角与车轮转角间传动比为 17.9，车辆质量为 1980kg，仿真总时长为 25 秒。分布式线控底盘车辆的方向盘转角与车速如图 5.3 所示：






图 5.3 传感器正常条件下实验方向盘转角与车速

由图 5.3 (a) 可知, 在第 10 秒附近, 驾驶员修正车辆方向, 车辆方向盘转角最大值为 -20° , 在调整车身姿态后, 方向盘转角回归到 0° 附近, 准备进入驾驶模拟器实验工况的转向过程; 在第 10 秒至第 20 秒之间, 驾驶员所控制的方向盘转角相较于第 4 章车辆状态估计仿真实验中方向盘转角变化率较大且不稳定; 在第 20 秒至仿真结束, 驾驶员控制车辆保持直线行驶, 除第 21 秒时驾驶员对车辆方向进行修正, 改变方向盘转角外, 方向盘转角与车轮转角变化不大。由图 5.3 (b) 可知, 在驾驶模拟器实验过程中, 驾驶员控制车辆速度保持在 16.66m/s 附近。该仿真工况于训练 KNN 算法的数据集重复度低。


在如图 5.3 所示的驾驶员控制输入下, 车辆质量估计结果为:



(a) KNN 质量估计值



(b) RLS 质量估计值



(c) 融合质量估计结果

图 5.4 车辆质量估计结果

如图 5.4 (a) 所示, 由于驾驶模拟器仿真实验下, 分布式线控底盘车辆悬架长度与车身纵向加速度、侧向加速度信息与 KNN 训练集数据差别较大。使得基于 KNN 算法的车辆质量范围估计器准确性降低。基于 KNN 的车辆质量估计算法的准确率相较于第 4 章仿真实验结果降低至 79.81%。


而由图 5.4 (b) 所示, 在第 13 秒至第 20 秒之间车轮转角较大、车身侧向速度和车身侧向加速度增加的情况下, 基于 RLS 的车辆质量估计算法计算结果相较于车辆质量真实值误差增加, 基于 RLS 算法的车辆质量估计结果失真。第 20 秒后, 车辆保持直线行驶, 基于 RLS 算法的车辆质量估计算法结果收敛, 估计

结果与车辆质量真实值间误差较小。

如图 5.4 (c) 所示, 在第 0-2 秒之间, 车辆行驶状态稳定, 但基于 RLS 的车辆质量估计算法初值与车辆真实值之间存在差距, RLS 算法快速收敛至车辆质量真实值附近; 在第 2-13 秒之间, 车辆行驶稳定, 但基于 KNN 算法的车辆质量范围估计算法由于数据集不全面, 产生估计误差, 但车辆质量融合估计策略输出基于 RLS 算法的车辆质量估计值, 估计结果与车辆质量真实值之间误差较小; 在第 13 秒至第 20 秒之间, 车辆进入转向阶段, 车辆行驶状态不稳定, 车辆质量融合估计策略输出基于 KNN 的车辆质量估计范围中位数; 在第 20 秒后, 车辆由转向过程进入直线行驶过程, 车辆行驶状态基本稳定, 车辆质量融合估计算法主要输出基于 RLS 算法的车辆质量估计值, 车辆质量估计结果与车辆质量真实值之间偏差较小。相较于基于 RLS 算法的车辆质量估计器, 通过车辆质量融合估计算法将车辆质量估计结果处于车辆实际质量 $\pm 20\text{kg}$ 范围内的准确率提升至 84.19%, 同时将基于 RLS 算法的车辆质量估计结果最大误差由 154.53% 降低至 5.66%, 显著提高车辆质量估计结果准确性, 保证车辆行驶安全。

(二) 车辆状态估计结果

将图 5.4 (c) 中车辆质量融合估计结果 m_f 作为车辆质量信息实时传输至基于 DUPF 算法的车辆状态估计器中。在如图 5.2 所示的驾驶模拟器仿真实验的驾驶员操控条件下, 验证车辆状态估计算法的有效性。驾驶模拟器仿真实验中传感器噪声方差水平如表 4.2 所示。车辆状态估计结果如图 5.5 所示。






图 5.5 车辆状态估计结果

在驾驶模拟器仿真实验中，基于 DUF 算法的车辆状态估计算法中车辆质量为图 5.4 (c) 中车辆质量融合估计算法估计值。如图 5.5 (a) 和图 5.5 (c) 所示，车辆纵向速度和纵向加速度估计结果相较于传感器测量值噪声水平显著降低，且估计结果较为稳定；如图 5.5 (b)、图 5.5 (d) 和图 5.5 (e) 所示，车辆侧向速度、侧向加速度和横摆角速度估计结果较为准确，噪声水平显著降低，证明了在传感器正常情况下，车辆质量估计算法的有效性和准确性。同时在较为波动的车辆质量估计结果下获取准确的车辆状态估计结果也验证了双滤波器架构的车辆状态估计算法的鲁棒性。

为进一步量化体现基于 DUF 的分布式线控底盘车辆状态估计算法的准确性

和实时性。基于第 4 章中式 (4.62) 计算的在传感器正常状态下的驾驶模拟器仿真实验中各车辆状态估计结果的 TASE 值如表 5.1 所示:


表 5.1 传感器正常下 DUPF 算法 TASE 值

车辆状态	TASE 值
纵向加速度	3.2363×10^{-4}
侧向加速度	7.2979×10^{-5}
纵向速度	1.2×10^{-3}
侧向速度	4.1964×10^{-4}
横摆角速度	3.1704×10^{-4}

如表 5.1 所示, 传感器正常状态下的驾驶模拟器仿真实验中, 各车辆状态参数的 TASE 值均较低且水平接近, 证明本文所提出的车辆状态估计算法具有较强的实时性和准确性。并进一步验证了基于双滤波器架构建立的 DUPF 算法的车辆状态估计算法在模型参数不确定性下的强鲁棒性

(三) K-最邻近算法数据集更新验证

为降低 KNN 算法数据集收集成本与算法训练成本, 同时保证 KNN 车辆质量范围估计算法准确性, 本文建立了 KNN 数据集自更新算法。基于图 5.4 中车辆质量融合估计结果, 参考表 4.1 中数据分类方法, 计算各时刻下车辆状态数据分类如图 5.6 (a) 所示。



(a) 数据分类




图 5.6 更新数据

由图 5.3 (a) 可知, 车辆实际行驶过程中的车辆状态与训练 KNN 算法所建立的数据集中数据差别较大, 基于 KNN 算法的车辆质量估计结果的准确性降低。为提高基于 KNN 的车辆质量估计算法的准确性, 本文基于表 4.1 建立 KNN 算法数据集更新策略。为验证算法有效性, 本节对驾驶模拟器仿真实验中, KNN 算法估计失效数据进行收集, 并更新 KNN 数据集和算法。

图 5.6 中, 图 5.6 (a) 为在该驾驶模拟器实验中车辆状态数据分类, 图 5.6 (b)、图 5.6 (c) 和图 5.6 (d) 为数据分类为 4 的车辆状态数据对应的车辆悬架长度、纵向加速度和侧向加速度。

根据表 4.1 所建立的 KNN 数据集更新策略, 提取在驾驶模拟器仿真实验中

车辆状态数据分类为 4 的车辆悬架和车身纵向、侧向加速度信息。将提取出的数据标签设置为基于 RLS 算法质量估计值 m_r 所处的 KNN 数据集质量范围，并更新至 KNN 数据集中。对基于 KNN 的车辆质量估计算法进行重新训练后，车辆质量估计结果如图 5.7 所示：




图 5.7 更新后 KNN 质量估计值

如图 5.7 所示，重新训练后的 KNN 质量估计值 m_k 的准确率由重新训练前的 79.81%提高至 97.64%。在第 16 秒时，车辆行驶状态不稳定，基于 RLS 的车辆质量估计值 m_r 和基于 KNN 的车辆质量估计结果 m_k 与车辆质量真实值相比误差均较大，使得融合质量估计结果误差较大。后续研究中将通过丰富数据集或更新算法解决算法误差问题。

5.2.2 传感器故障下车辆状态估计实验

为保证本文第 4 章所建立的基于 DUPF 算法分布式线控底盘车辆状态估计器中获取的车轮转角的准确性，本文在第 3 章建立了车轮转角传感器故障诊断算法。当车轮转角传感器故障时，显示传感器故障状态，并向车辆状态估计算法输出车轮转角估计值替代车轮转角传感器测量值，保证车辆状态估计结果的准确性。

为进一步验证分布式线控底盘车辆车轮转角传感器故障诊断算法的实时性和有效性，同时在验证在车轮转角故障下，基于 EKF 算法的车轮转角估计结果对车辆状态估计算法精度的影响。驾驶员采用如图 5.8 所示的方向盘转角和车速

进行驾驶模拟器仿真实验，仿真总时长为 20 秒。





图 5.8 传感器故障条件下实验方向盘转角与车速


在如图 5.8 所示的驾驶员输入情况下，方向盘转角在正负 40° 之间变化，车速由初始的 67km/h 降低至 53km/h。车辆行驶轨迹近似于双移线工况实验中车辆驾驶轨迹。

(一) 车辆质量融合估计结果


在如图 5.8 所示的驾驶员输入下，车辆质量估计结果如图 5.9 所示。车辆质量真实值为 1980kg



(a) KNN 质量估计值



(b) RLS 质量估计值



(c) 融合质量估计结果

图 5.9 车辆质量估计结果

如图 5.9 所示，为该行驶工况下车辆质量估计结果。图 5.9 (a) 中基于 KNN 算法的车辆质量估计结果较为准确，在车辆行驶过程中，基于 KNN 的车辆质量范围估计结果始终包含车辆质量真实值。图 5.9 (b) 中，在第 0-9 秒之间，车辆直线行驶，基于 RLS 算法的车辆质量估计值较为准确。在第 9-15 秒中，驾驶员控制车辆转向，RLS 算法估计结果失真。在第 15-20 秒，车辆保持直线行驶，基于 RLS 算法的车辆质量估计值收敛到真实值附近。如图 5.9 (c) 所示，在第 0-9 秒之间，车辆直线行驶，车辆质量融合估计值与基于 RLS 的车辆质量估计算法结果接近。在第 9-15 秒中，当基于 RLS 算法的车辆质量估计值失真时，车辆质

量融合估计算法将基于 RLS 算法的车辆质量估计结果的最大误差由 39.87% 降低至 12.74%，保证车辆行驶安全。在第 15 秒之后，车辆保持直线行驶，车辆质量融合估计值主要输出基于 RLS 算法的车辆质量估计值。

（二）传感器故障诊断算法验证

在该工况下，假定车辆右前轮转角传感器在仿真第 2 秒发生传感器卡死故障，传感器测量值变为 1 度。则对于分布式线控底盘车辆右前轮转角传感器故障诊断算法驾驶模拟器仿真实验结果如图 5.10 所示。




图 5.10 右前轮转角传感器故障诊断

由图 5.10 (a) 可知，在第 2 秒时，向分布式线控底盘车辆右前轮转角传感器注入传感器卡死故障，传感器测量值突变为 1 并保持不变。由于基于 EKF 算法的车轮转角传感器基于转向电机模型建立，所以车轮转角估计值不受传感器值突变影响，估计准确。由图 5.10 (b) 可知，第 2 秒时残差函数值突变至 43.571，大于故障阈值，传感器故障状态变为 1 且保持不变，等待传感器修复后手动对故障状态复原。当传感器故障状态为 1 时，传输至车辆状态估计算法的各车轮转角由车轮转角传感器测量值变为基于 EKF 算法的估计值。

（三）车辆状态估计结果

在如图 5.8 所示的驾驶员输入、如图 5.10 (a) 所示的车轮转角估计值和车辆质量为图 5.10 (c) 中车辆质量融合估计值的情况下，基于 DUPF 算法的车辆状态估计结果如图 5.11 所示：




图 5.11 传感器故障状态下车辆状态估计

车辆纵向方向上,由图 5.11 (a)可知,纵向加速度的估计结果准确;而由图 5.11 (c)可知,车辆纵向速度处在第 12 秒之后车辆纵向速度估计值与传感器测量真实值存在一定偏差,但整体误差小于 1%。在侧向方向上,由图 5.11 (b)可知,在车辆行驶过程中,侧向加速的估计结果较为准确。而在图 5.11 (d)中,车辆侧向速度在第 14 秒后传感器真实值出现一些偏差。如图 5.11 (e)所示,车辆的横摆角速度估计结果均较为准确。虽然纵向速度和侧向速度与对应的真实值存在一些偏差,但误差较小。

在传感器故障情况下,车辆状态估计结果的 TASE 值如表 5.2 所示:

表 5.2 车轮转角传感器故障下 DUF 算法 TASE 值

车辆状态参数	TASE 值
纵向加速度	9.525×10^{-4}
侧向加速度	4.057×10^{-6}
纵向速度	1.95×10^{-2}
侧向速度	4.1×10^{-3}
横摆角速度	6.7×10^{-3}

由表 5.2 可知,车辆纵向速度 TASE 相较于其他车辆状态参数数量级较高,但总体上车辆状态估计结果的 TASE 值较小。证明车辆状态估计算法实时性和准确性较好。

5.3 本章小结

本章主要对第 3 章所建立的分布式线控底盘车辆车轮转角传感器故障诊断算法和第 4 章所建立的分布式线控底盘车辆状态估计算法进行驾驶模拟器仿真实验验证。首先,介绍了驾驶模拟器硬件设备;其次,在传感器正常状态下进行融合递归最小二乘算法和 K-最邻近算法的车辆质量估计器和基于双无迹粒子滤波算法车辆状态估计算法的验证,并验证了 K-最邻近数据集更新和算法自学习功能。实验结果证明了车辆质量融合估计算法的有效性和双观测器架构的双无迹粒子滤波车辆状态估计器的准确性和鲁棒性;最后,进行了传感器故障条件下的车轮转角传感器故障诊断算法和车辆状态估计算法验证仿真实验。当传感器故障后

车辆状态估计算法中车轮转角为基于扩展卡尔曼滤波的车轮转角估计值, 保证准确的车辆状态估计结果的准确性。验证了车轮转角传感器故障诊断算法的有效性、实时性和基于双无迹粒子滤波的车辆状态估计算法的有效性和鲁棒性。

第6章 全文总结与展望

6.1 全文总结

随着对分布式线控底盘车辆的研究日益深入,准确、可靠的获取分布式线控底盘车辆状态参数,为分布式线控底盘车辆进一步研究的提供了良好的平台。本文基于此研究背景,针对分布式线控底盘车辆传感器故障诊断和车辆状态估计展开研究。本文的具体研究内容为:

(1) 为保证基于模型的车辆状态估计算法的模型准确性,建立了分布式线控底盘车辆非线性动力学模型,从而保证第4章建立的车辆状态估计器的模型准确性。引入 Pacejka 轮胎模型求取轮胎侧向力。为验证模型准确性,本文基于 MATLAB/Simulink 搭建车辆动力学模型并在分布式线控底盘车辆典型行驶工况下与 CarSim 车辆模型进行对比。仿真对比实验结果表明模型精度与 CarSim 车辆模型接近,保证了车辆状态估计算法的模型准确性。

(2) 为准确诊断分布式线控底盘车辆车轮转角传感器故障,并在传感器故障情况下获取车轮转角,保证车辆行驶安全性。本文介绍了基于扩展卡尔曼滤波算法的车辆传感器故障诊断算法:首先,建立了分布式线控底盘车辆转向电机数学模型,并基于该模型建立了基于扩展卡尔曼滤波的车轮转角估计算法;其次,利用残差卡方检验法对车轮转角估计值与传感器测量值进行比照检验,实现车轮转角传感器的故障诊断;最后,为验证传感器故障诊断算法的有效性,介绍并建模了车轮转角传感器常见故障形式,并基于 MATLAB/Simulink 搭建转向电机模型和故障诊断算法模型,验证了基于扩展卡尔曼滤波算法的车轮转角估计器的准确性及传感器故障诊断算法在传感器不同故障下的实时性和有效性。

(3) 为准确获取车辆行驶过程中状态参数,针对车辆质量参数变化对车辆状态估计算法精度的影响问题,提出了结合车辆质量融合估计算法的双无迹粒子滤波车辆状态估计器:首先,建立车辆纵向动力学模型,并基于该模型建立了递归最小二乘车辆质量估计器,同时建立了基于 K-最邻近算法的车辆质量范围估计器并介绍了数据集建立方法;其次,建立了递归最小二乘算法和 K-最邻近算

法估计质量融合策略，并且为了保证 K-最邻近算法准确性，设计了数据集自更新与功能；然后，建立了基于双无迹粒子滤波的车辆状态双观测器架构估计算法，该算法能够有效的降低传感器噪声，降低模型不确定性对车辆状态估计精度的影响，状态估计算法中车辆质量参数由车辆质量融合估计算法获取；最后，通过 CarSim 和 MATLAB/Simulink 联合仿真平台验证了车辆状态估计算法的准确性和有效性。

（4）对本文所提出的车轮转角传感器故障诊断算法和车辆状态估计算法进行驾驶模拟器仿真验证：首先，介绍了驾驶模拟器仿真实验设备；其次，在传感器正常和传感器故障两种实验条件下验证本文所设计的车辆状态估计算法；同时，在传感器正常仿真实验中对本文所建立的车辆质量融合估计算法的数据集自更新功能的有效性进行验证。通过驾驶模拟器仿真实验，验证了本文所建立的分布式线控底盘车辆传感器故障诊断与结合车辆质量融合估计算法的车辆状态估计器的精度与有效性。

6.2 研究展望

本文搭建线控底盘传感器故障诊断与车辆状态估计算法，并建立车辆质量融合估计策略，保证准确、实时获取车辆状态。在本文已有研究结果的基础上，后续可以针对以下内容进行进一步研究：

（1）由于传感器可靠性对底盘控制算法的重要性，考虑到实验安全性限制，本文对传感器故障诊断和车辆状态估计算法仅进行了驾驶模拟器中的仿真实验。在后续的研究中，可以选择具有线控转向和线控驱动执行器的试验台架进行进一步验证。或在保证安全的前提下，采用具有四轮独立驱动、独立转向的分布式线控底盘车辆进行实车实验。

（2）本文在车辆状态估计算法研究之中，认为轮胎相关参数和路面附着系数等均为已知，且在车辆行驶过程中不会发生变化。但在车辆行驶过程中，轮胎参数会随轮胎磨损发生变化，路面附着系数会随路面条件变化。这些参数的变化会对车辆状态估计算法的估计精度产生影响。因此，在后续的研究中需要考虑轮胎参数和路面附着系数的变化。

(3) 本文在模型建立过程中忽略车辆侧倾运动和俯仰运动，从而简化车辆模型，提高算法实时性。但是在车辆实际行驶过程中车辆侧倾与俯仰会对车辆状态估计结果产生一定影响。后续的研究中可以在保证算法实时性的前提下，考虑省略这部分模型简化。

参考文献

- [1] Zhang L, Wang Q, Chen J, et al. Brake-by-wire system for passenger cars: A review of structure, control, key technologies, and application in X-by-wire chassis[J]. eTransportation, 2023, 18: 100292(1-15).
- [2] 中华人民共和国国家统计局.年度数据[DB/OL].[2024-3-8].
<https://data.stats.gov.cn/easyquery.htm?cn=C01>.
- [3] Viktor Skrickij, Paulius Kojis, Eldar Šabanovič, Barys Shyrokau, Valentin Ivanov. Review of Integrated Chassis Control Techniques for Automated Ground Vehicles[J]. Sensors, 2024, 24(2): 600(1-40).
- [4] 李克强, 戴一凡, 李升波, 边明远. 智能网联汽车(ICV)技术的发展现状及趋势[J]. 汽车安全与节能学报, 2017, 8(1): 1-14.
- [5] Ni J, Hu J, Xiang C. A review for design and dynamics control of unmanned ground vehicle[J]. Proceedings of the Institution of Mechanical Engineers, Part D: Journal of Automobile Engineering, 2021, 235(4): 1084-1100.
- [6] Song P, Zong C F, Zheng H Y, et al. Rapid prototyping for the vehicle control unit of a full drive-by-wire electric vehicle [J]. Advanced Materials Research, 2013, 694: 1573-1581.
- [7] Wang K, Yang M, Li Y, et al. Multidirectional motion coupling based extreme motion control of distributed drive autonomous vehicle[J]. Scientific Reports, 2022, 12(1): 13203(1-19).
- [8] Zhang D, Zong C, Chen G, et al. Study on Dynamic Characteristics and Control Methods for Drive-by-Wire Electric Vehicle[C]// SAE. Proceedings of the 2014 Commercial Vehicle Engineering Congress Experience. San Francisco: SAE, 2014: 1-8.
- [9] Abe M, Mokhiamar O. An integration of vehicle motion controls for full drive-by-wire vehicle[J]. Proceedings of the Institution of Mechanical Engineers, Part K: Journal of Multi-body Dynamics, 2007, 221(1): 116-127.
- [10] 张友朋. 全线控四轮独立电动汽车状态估计与路径跟踪控制研究[D]. 长春: 吉林大学, 2019.
- [11] Van Zanten A T. Evolution of electronic control systems for improving the vehicle dynamic behavior[C] // AVEC. Proceedings of the 6th International Symposium on Advanced Vehicle Control. Hiroshima: AVEC, 2002, 2(2): 1-9.
- [12] Gao Z, Yang L, Wang H, et al. Active fault tolerant control of electric power steering system with sensor fault[C] // IEEE. 2017 36th Chinese Control Conference (CCC). Dalian: IEEE, 2017: 9630-9636.
- [13] 党瑞捷. 集成式电控制动系统传感器故障诊断与容错控制研究[D]. 长春: 吉林大学,

- 2023.
- [14] Frank P M, Ding S X, Marcu T. Model-based fault diagnosis in technical processes[J]. Transactions of the Institute of Measurement and Control, 2000, 22(1): 57-101.
 - [15] Wang Z, Ding X, Zhang L. Chassis Coordinated Control for Full X-By-Wire Four-Wheel-Independent-Drive Electric Vehicles[J]. IEEE Transactions on Vehicular Technology, 2022, 72(4): 4394-4410.
 - [16] Zhang Y, Lu G. Research on Control Method of Four-Wheel-Independent-Driving System Based on X-by-Wire Chassis[C] // Springer. Proceedings of China SAE Congress 2020. Singapore: Springer Nature, 2022, 769: 603-626.
 - [17] Kauhanen, Mikko-Matti. Drive-by-wire Control for the Longitudinal Motion of an Autonomous Electric Vehicle[D]. Helsinki: Aalto University, 2021.
 - [18] 宗长富, 李刚, 郑宏宇等. 线控汽车底盘控制技术研究进展及展望[J]. 中国公路学报, 2013, 26(02): 160-176.
 - [19] 屈翔, 陈豪, 张君等. 车辆线控转向系统关键技术研究综述[J]. 重庆理工大学学报(自然科学), 2023, 37(8): 74-84.
 - [20] 蒋权. 基于人机共驾的智能汽车线控转向系统路感控制研究[D]. 长春: 吉林大学, 2022.
 - [21] 吕皓玉, 王翔宇, 谢斌等. 分布式电驱动汽车原地转向机理与控制方法研究[J/OL]. 中国公路学报, 1-21.
 - [22] 任周强. 分布式驱动电动汽车整车控制系统设计与实现[D]. 西安: 长安大学, 2022.
 - [23] 袁所贤. 分布式驱动电动汽车关键技术分析[J]. 内燃机与配件, 2022, (16): 112-114.
 - [24] 王震坡, 陈辛波, 张雷等. 分布式驱动电动汽车关键技术及产业化展望[J]. 科技导报, 2020, 38(8): 99-100.
 - [25] ALISON. 代步首选 日产 PIVO 3 电动概念车[J]. 汽车与驾驶维修(汽车版), 2011, (12): 78.
 - [26] 爱车人. 日产 Pivo——村上隆笔下的都市精灵[J]. 当代汽车, 2007, (02): 36-39.
 - [27] 汲安志. 智能“三板斧” 长城汽车大“闯关”[J]. 智能网联汽车, 2021, (05): 91-93.
 - [28] 仰望携“易四方”技术正式亮相比亚迪以颠覆性技术打造高端品牌[J]. 中国经济周刊, 2023, (Z1): 92-93.
 - [29] 比亚迪发布云辇系统, 用新技术重新定义车身控制[J]. 汽车维修技师, 2023(05): 21.
 - [30] Zhang L, Zhang Z, Wang Z, et al. Chassis coordinated control for full X-by-wire vehicles-A review[J]. Chinese Journal of Mechanical Engineering, 2021, 34: 1-25.
 - [31] 张雷, 徐同良, 李嗣阳等. 全线控分布式驱动电动汽车底盘协同控制研究综述[J]. 机械工程学报, 2023, 59(20): 261-280.

- [32] Shuai Z, Zhang H, Wang J, et al. Combined AFS and DYC control of four-wheel-independent-drive electric vehicles over CAN network with time-varying delays[J]. IEEE Transactions on vehicular technology, 2013, 63(2): 591-602.
- [33] Stanford University, Dynamic Design Lab. Driver Assistance and Augmentation Systems [EB/OL]. <https://ddl.stanford.edu/content/driver-assistance-and-augmentation-systems>.
- [34] Stanford University, Dynamic Design Lab. Driver Vehicle Dynamics and Control At The Limits of Handling [EB/OL]. <https://ddl.stanford.edu/content/vehicle-dynamics-and-control-limits-handling>
- [35] 陈国迎. 四轮独立线控电动汽车试验平台搭建与集成控制策略研究[D]. 长春: 吉林大学, 2013.
- [36] 李全通. 全矢量线控滑板底盘设计与控制方法研究[D]. 长沙: 湖南大学, 2022.
- [37] Yang S, Chen Y, Shi R, et al. A Survey of Intelligent Tires for Tire-Road Interaction Recognition Toward Autonomous Vehicles[J]. IEEE Transactions on Intelligent Vehicles, 2022, 7(3): 520-532.
- [38] Korayem A H, Khajepour A, Fidan B. A review on vehicle-trailer state and parameter estimation[J]. IEEE Transactions on intelligent transportation systems, 2021, 23(7): 5993-6010.
- [39] Liu Y H, Li T, Yang Y Y, et al. Estimation of tire-road friction coefficient based on combined APF-IEKF and iteration algorithm[J]. Mechanical Systems and Signal Processing, 2017, 88: 25-35.
- [40] Guo H, Cao D, Chen H, et al. Vehicle dynamic state estimation: State of the art schemes and perspectives[J]. IEEE/CAA Journal of Automatica Sinica, 2018, 5(2): 418-431.
- [41] Teng C, Cai Y, Sun X, et al. Multistep Ahead Prediction of Vehicle Lateral Dynamics Based on Echo State Model[J]. IEEE Sensors Journal, 2022, 23(1): 620-631.
- [42] Zhang B, Zhao W, Zou S, et al. A reliable vehicle lateral velocity estimation methodology based on SBI-LSTM during GPS-outage[J]. IEEE Sensors Journal, 2020, 21(14): 15485-15495.
- [43] Xing Y, Lv C. Dynamic state estimation for the advanced brake system of electric vehicles by using deep recurrent neural networks[J]. IEEE Transactions on Industrial Electronics, 2019, 67(11): 9536-9547.
- [44] Chindamo D, Lenzo B, Gadola M. On the vehicle sideslip angle estimation: a literature review of methods, models, and innovations[J]. applied sciences, 2018, 8(3): 18633-18642.
- [45] Korayem A H, Khajepour A, Fidan B. A review on vehicle-trailer state and parameter estimation[J]. IEEE Transactions on intelligent transportation systems, 2021, 23(7):

5993-6010.

- [46] Xing Y, Lv C, Wang H, et al. Driver lane change intention inference for intelligent vehicles: Framework, survey, and challenges[J]. IEEE Transactions on Vehicular Technology, 2019, 68(5): 4377-4390.
- [47] Hu J N, Hu J J, Lin H B, et al. State-of-charge estimation for battery management system using optimized support vector machine for regression[J]. Journal of Power Sources, 2014, 269: 682-693.
- [48] Teng C, Cai Y, Sun X, et al. Multistep ahead prediction of vehicle lateral dynamics based on echo state model[J]. IEEE Sensors Journal, 2022, 23(1): 620-631.
- [49] 高振海, 温文昊, 唐明弘等. 基于混合神经网络的汽车运动状态估计[J]. 汽车工程, 2022, 44(10): 1527-1536.
- [50] Zhang B, Zhao W, Zou S, et al. A reliable vehicle lateral velocity estimation methodology based on SBI-LSTM during GPS-outage[J]. IEEE Sensors Journal, 2020, 21(14): 15485-15495.
- [51] Chu Q, Sun W, Zhang Y. A Data-Driven Method for the Estimation of Truck-State Parameters and Braking Force Distribution[J]. Sensors, 2022, 22(21): 8358.
- [52] 郑阳俊, 贺帅, 帅志斌, 等. 基于 DRL 的四轮独立驱动电动车辆的侧向车速估计[J]. 汽车安全与节能学报, 2022, 13(2): 309-316.
- [53] Chemali E, Kollmeyer P J, Preindl M, et al. Long short-term memory networks for accurate state-of-charge estimation of Li-ion batteries[J]. IEEE Transactions on Industrial Electronics, 2017, 65(8): 6730-6739.
- [54] Xing Y, Lv C. Dynamic state estimation for the advanced brake system of electric vehicles by using deep recurrent neural networks[J]. IEEE Transactions on Industrial Electronics, 2019, 67(11): 9536-9547.
- [55] Shin J, Baek Y, Lee J, et al. Cyber-physical attack detection and recovery based on RNN in automotive brake systems[J]. Applied Sciences, 2018, 9(1): 82.
- [56] Napolitano Dell'Annunziata G, Arricale V M, Farroni F, et al. Estimation of Vehicle Longitudinal Velocity with Artificial Neural Network[J]. Sensors, 2022, 22(23): 9516.
- [57] Viehweger M, Vaseur C, van Aalst S, et al. Vehicle state and tyre force estimation: demonstrations and guidelines[J]. Vehicle system dynamics, 2021, 59(5): 675-702.
- [58] Ko N Y, Kim T G. Comparison of Kalman filter and particle filter used for localization of an underwater vehicle[C] // IEEE. 2012 9th international conference on ubiquitous robots and ambient intelligence. Daejeon: IEEE, 2012: 350-352.
- [59] Tong G, Fang Z, Xu X. A particle swarm optimized particle filter for nonlinear system state

- estimation[C] //IEEE. 2006 IEEE International Conference on Evolutionary Computation. Orlando: IEEE, 2006: 438-442
- [60] 宗长富, 潘钊, 胡丹等. 基于扩展卡尔曼滤波的信息融合技术在车辆状态估计中的应用[J]. 机械工程学报, 2009, 45(10): 272-277.
- [61] 宗长富, 胡丹, 杨肖等. 基于扩展 Kalman 滤波的汽车行驶状态估计[J]. 吉林大学学报(工学版), 2009, 39(01): 7-11.
- [62] XIA X, XIONG L, HUANG Y, et al. Estimation on IMU yaw misalignment by fusing information of automotive onboard sensors[J]. Mechanical Systems and Signal Processing, 2022, 162: 107993(1-17).
- [63] CUI Q, DING R, ZHOU B, et al. Path-tracking of an autonomous vehicle via model predictive control and nonlinear filtering[J]. Proceedings of the Institution of Mechanical Engineers, Part D: Journal of Automobile Engineering, 2018, 232(9): 1237-1252.
- [64] LIU D, HUANG S, WU S, et al. Direct yaw-moment control of electric vehicle with in-wheel motor drive system[J]. International Journal of Automotive Technology, 2020, 21(4): 1013-1028.
- [65] XIAO Z, XIAO D, HAVYARIMANA V, et al. Toward accurate vehicle state estimation under non-Gaussian noises[J]. IEEE Internet of Things Journal, 2019, 6(6): 10652-10664.
- [66] 汤泽鹏. 基于 MEMS 加速度传感器的智能化轮胎关键状态估计[D]. 长春: 吉林大学, 2022.
- [67] ANTONOV S, FEHN A, KUGI A. Unscented Kalman filter for vehicle state estimation[J]. Vehicle System Dynamics, 2011, 49(9): 1497-1520.
- [68] WENZEL T A, BURNHAM K J, BLUNDELL M V, et al. Dual extended Kalman filter for vehicle state and parameter estimation[J]. Vehicle system dynamics, 2006, 44(2): 153-171.
- [69] BERSANI M, VIGNATI M, MENTASTI S, et al. Vehicle state estimation based on Kalman filters[C]// IEEE. 2019 AEIT International Conference of Electrical and Electronic Technologies for Automotive. Florence: IEEE, 2019: 1-6.
- [70] REINA G, PAIANO M, BLANCO CLARACO J L. Vehicle parameter estimation using a model-based estimator[J]. Mechanical Systems and Signal Processing, 2017, 87: 227-241.
- [71] LENZO B, DE CASTRO R. Vehicle sideslip estimation for four-wheel-steering vehicles using a particle filter[C] // Springer. The IAVSD International Symposium on Dynamics of Vehicles on Roads and Tracks. Cham. Gothenburg: Springer International Publishing, 2019: 1624-1634.
- [72] ZHANG G, YU Z, WANG J. Correction of contaminated yaw rate signal and estimation of

- sensor bias for an electric vehicle under normal driving conditions[J]. Mechanical Systems and Signal Processing, 2017, 87: 64-80.
- [73] WÖBER W, NOVOTNY G, MEHNEN L, et al. Autonomous vehicles: Vehicle parameter estimation using variational bayes and kinematics[J]. Applied Sciences, 2020, 10(18): 6317(1-19).
- [74] BOADA B L, BOADA M J L, VARGAS-MELENDZ L, et al. A robust observer based on H_{∞} filtering with parameter uncertainties combined with Neural Networks for estimation of vehicle roll angle[J]. Mechanical Systems and Signal Processing, 2018, 99: 611-623.
- [75] ALSHAWI A, DE PINTO S, STANO P, et al. An adaptive unscented kalman filter for the estimation of the vehicle velocity components, slip angles, and slip ratios in extreme driving manoeuvres[J]. Sensors, 2024, 24(2): 436.
- [76] SONG Y T, SHU H Y, CHEN X B. Chassis integrated control for 4WIS distributed drive EVs with model predictive control based on the UKF observer[J]. Science China Technological Sciences, 2020, 63(3): 397-409.
- [77] CHU W, LUO Y, DAI Y, et al. In-wheel motor electric vehicle state estimation by using unscented particle filter[J]. International Journal of Vehicle Design, 2015, 67(2): 115-136.
- [78] ZHU J, WANG Z, ZHANG L, et al. State and parameter estimation based on a modified particle filter for an in-wheel-motor-drive electric vehicle[J]. Mechanism and Machine Theory, 2019, 133: 606-624.
- [79] CHEN X, LI S, LI L, et al. Longitudinal-lateral-cooperative estimation algorithm for vehicle dynamics states based on adaptive-square-root-cubature-Kalman-filter and similarity-principle[J]. Mechanical Systems and Signal Processing, 2022, 176: 109162(1-21).
- [80] CHEN T, XU X, CHEN L, et al. Estimation of longitudinal force, lateral vehicle speed and yaw rate for four-wheel independent driven electric vehicles[J]. Mechanical Systems and Signal Processing, 2018, 101: 377-388.
- [81] PEI X, CHEN Z, YANG B, et al. Estimation of states and parameters of multi-axle distributed electric vehicle based on dual unscented Kalman filter[J]. Science progress, 2020, 103(1): 1-20.
- [82] WANG Z, WU J, ZHANG L, et al. Vehicle sideslip angle estimation for a four-wheel-independent-drive electric vehicle based on a hybrid estimator and a moving polynomial Kalman smoother[J]. Proceedings of the Institution of Mechanical Engineers, Part K: Journal of Multi-body Dynamics, 2019, 233(1): 125-140.
- [83] JENSEN K M, SANTOS I F, CLEMMENSEN L K H, et al. Mass estimation of ground

- vehicles based on longitudinal dynamics using IMU and CAN-bus data[J]. Mechanical Systems and Signal Processing, 2022, 162: 107982(1-21).
- [84] JENSEN, KENNETH M, SANTOS, ILMAR F, CLEMMENSEN, LINE K.H, et al. Mass estimation of ground vehicles based on longitudinal dynamics using loosely coupled integrated navigation system and CAN-bus data with model parameter estimation[J]. Mechanical Systems and Signal Processing, 2022, 171: 108925(1-26).
- [85] ZHANG H, YANG Z, XIONG H, et al. Transformer Aided Adaptive Extended Kalman Filter for Autonomous Vehicle Mass Estimation[J]. Processes, 2023, 11(3): 887(1-18).
- [86] WANG B, WANG H, WU L, et al. Truck mass estimation method based on the on-board sensor[J]. Proceedings of the Institution of Mechanical Engineers, Part D: Journal of Automobile Engineering, 2020, 234(10-11): 2429-2443.
- [87] CHU W, CAO K, LI S, et al. Vehicle mass estimation based on high-frequency-information extraction[J]. IFAC Proceedings Volumes, 2013, 46(21): 72-76.
- [88] 胡宇, 薛卡, 史沛瑶. 车轮转角测量装置、多轴转向车辆及车轮转角测量方法[P]. 江苏省:CN106152994B, 2020-01-10.
- [89] GUO R X, GUO K, DONG J K. Fault diagnosis for sensors in a class of nonlinear systems[J]. IMA Journal of Mathematical Control and Information, 2018, 35(2): 375-391.
- [90] BEARD R V. Failure accomodation in linear systems through self-reorganization[D]. Boston: Massachusetts Institute of Technology, 1971.
- [91] FRANK P M. Fault diagnosis in dynamic systems using analytical and knowledge-based redundancy: A survey and some new results[J]. automatica, 1990, 26(3): 459-474.
- [92] WILLSKY A, JONES H. A generalized likelihood ratio approach to the detection and estimation of jumps in linear systems[J]. IEEE Transactions on Automatic control, 1976, 21(1): 108-112.
- [93] ZAREI J, SHOKRI E. Robust sensor fault detection based on nonlinear unknown input observer[J]. Measurement, 2014, 48: 355-367.
- [94] MOHAMED L, IBRAHIM A S. Model-based fault diagnosis via parameter estimation using knowledge base and fuzzy logic approach[C] // IEEE. 11th IEEE Mediterranean Electrotechnical Conference. Cairo: IEEE, 2002: 505-509.
- [95] 朱平, 黄文虎, 姜兴谓, 王日新. 基于模型的传感器故障诊断技术的研究[J]. 传感技术学报, 1999, (1): 22-28.
- [96] DONG Z, ZHAO J, DUAN J, et al. Research on agricultural machinery fault diagnosis system based on expert system[C]// IEEE. 2018 2nd IEEE Advanced Information

- Management, Communicates, Electronic and Automation Control Conference. Xian: IEEE, 2018: 2057-2060.
- [97] DA SILVA J C, SAXENA A, BALABAN E, et al. A knowledge-based system approach for sensor fault modeling, detection and mitigation[J]. Expert Systems with Applications, 2012, 39(12): 10977-10989.
- [98] HEYDARZADEH M, NOURANI M. A two-stage fault detection and isolation platform for industrial systems using residual evaluation[J]. IEEE Transactions on Instrumentation and Measurement, 2016, 65(10): 2424-2432.
- [99] JIANG Y, YIN S. Recursive total principle component regression based fault detection and its application to vehicular cyber-physical systems[J]. IEEE Transactions on Industrial Informatics, 2017, 14(4): 1415-1423.
- [100] GONZALEZ-JIMENEZ D, DEL-OLMO J, POZA J, et al. Data-driven fault diagnosis for electric drives: A review[J]. Sensors, 2021, 21(12): 4024(1-33).
- [101] CARTOCCI N, NAPOLITANO M R, COSTANTE G, et al. Aircraft robust data-driven multiple sensor fault diagnosis based on optimality criteria[J]. Mechanical Systems and Signal Processing, 2022, 170: 108668(1-21).
- [102] 吴光强, 陶义超, 曾翔. 数据驱动的变速器传感器故障诊断方法[J]. 同济大学学报(自然科学版), 2021, 49(2): 272-279.
- [103] 冯哲. 基于 Adams 的 UniTire 与 MF 轮胎模型应用对比研究[D]. 长春: 吉林大学, 2023.
- [104] PACEJKA H. Tire and vehicle dynamics[M]. Elsevier, 2005.
- [105] 李笑晨, 谭光兴. 基于扩展卡尔曼的线控转向系统转角传感器故障诊断[J]. 广西科技大学学报, 2024, 35(1): 76-83.
- [106] JIANG J, SHEN Y, JI Z. Speed and Rotor Position Estimation for PMSM Based on EKF[J]. Journal of system simulation, 2005, 17(7): 1704-1707.
- [107] 袁雷, 胡冰新, 魏克银, 等. 现代永磁同步电机控制原理及 MATLAB 仿真[M]. 北京航空航天大学出版社, 2016.
- [108] 田承伟. 线控转向汽车容错控制方法研究[D]. 长春: 吉林大学, 2010.
- [109] PETERSON L E. K-nearest neighbor[J]. Scholarpedia, 2009, 4(2): 1883.
- [110] 李远方. 重型车质量辨识及道路坡度状态估计方法研究[D]. 长春: 吉林大学, 2012.
- [111] 李传友, 任宪丰, 孙晓鹏等. 基于最小二乘法的商用车整车质量估计研究[J]. 汽车电器, 2023, (11): 48-50.
- [112] HUANG Y, ZHANG Y, LI N, et al. Design of Gaussian approximate filter and

smoother for nonlinear systems with correlated noises at one epoch apart[J]. Circuits, Systems, and Signal Processing, 2016, 35: 3981-4008.